




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



TFG del Grado en Ingeniería de la Salud

**Estudio comparativo de modelos predictivos
de glucemia a corto plazo mediante técnicas
de aprendizaje automático en pacientes con
diabetes tipo 1**

Documentación Técnica

Presentado por Guillermo de la Fuente Abajo
en Universidad de Burgos

10 de junio de 2026

Tutores: Antonio Jesús Canepa Oneto – Ruth Estefanía
Santos Mazo

Índice general

Índice general	1
Índice de figuras	3
Índice de tablas	5
Apéndice A Plan de Proyecto	7
A.1. Introducción	7
A.2. Metodología de ingeniería del software	8
A.3. Planificación temporal	8
A.4. Planificación económica	10
A.5. Viabilidad legal	13
Apéndice B Manual de especificación de diseño	15
Apéndice C Especificación de Requisitos	17
C.1. Diagrama de casos de uso	17
C.2. Casos de uso	18
C.3. Prototipos de interfaz	20
Apéndice D Documentación de usuario	23
D.1. Requisitos software y hardware	23
D.2. Instalación y puesta en marcha	24
Apéndice E Manual del investigador.	27
E.1. Estructura de directorios	27
E.2. Compilación, instalación y ejecución del proyecto	28
E.3. Pruebas del sistema	29

E.4. Instrucciones para la modificación o mejora del proyecto . . .	29
Apéndice F Descripción de adquisición y tratamiento de datos	33
F.1. Descripción formal de los datos	33
F.2. Descripción clínica de los datos	35
F.3. Descripción estadística de los datos	36
Apéndice G Estudio experimental	41
G.1. Cuaderno de trabajo	41
G.2. Configuración y parametrización de las técnicas	45
G.3. Detalle de resultados	52
Apéndice H Anexo de sostenibilización curricular	67
H.1. Introducción	67
H.2. Contextualización crítica del conocimiento (SOS1)	67
H.3. Utilización sostenible de recursos (SOS2)	68
H.4. Participación en procesos comunitarios (SOS3)	69
H.5. Aplicación de principios éticos (SOS4)	69
Apéndice I Registro de interacciones con sistemas de IA	71
I.1. Registro de interacciones con sistemas de IA	71
Bibliografía	77

Índice de figuras

A.1. Distribución temporal inicial (amarillo) y final (azul) de los milestones del trabajo.	10
A.2. Fórmula para el cálculo de la amortización durante un periodo determinado.	11
C.1. Diagrama de casos de uso del sistema.	17
C.2. Interfaz gráfica del simulador py-mgipsim	21
C.3. Línea de comandos del simulador py-mgipsim	21
C.4. Visualización de serie glucémica	22
E.1. Diagrama del pipeline de análisis del proyecto.	31
F.1. Flujo de trabajo del simulador py-mgipsim. Fuente: Siket et al. (2025).	35
G.1. Ejemplo de serie glucémica obtenida durante las pruebas previas, con episodios de hipoglucemia severa sostenida.	42
G.2. Ejemplo de serie glucémica escenario de ayuno intermitente. . . .	42
G.3. Serie glucémica del paciente de referencia (paciente 1, escenario E3) utilizado para la optimización de hiperparámetros.	44
G.4. Principales insulinas comercializadas en España (noviembre 2022), con tiempos de inicio, pico máximo y duración de acción. Fuente: redGDPS Mora Navarro et al. (2022).	49
G.5. Distribución de TIR, TAR y TBR por paciente — Escenario E1 ($HC^- E_{j_0} Er_0$).	53
G.6. Distribución de TIR, TAR y TBR por paciente — Escenario E2 ($HC^+ E_{j_0} Er_0$).	53

G.7. Distribución de TIR, TAR y TBR por paciente — Escenario E3 ($HC^- Ej^+ Er_0$).	54
G.8. Distribución de TIR, TAR y TBR por paciente — Escenario E4 ($HC^- Ej_0 Er^+$).	54
G.9. Distribución de TIR, TAR y TBR por paciente — Escenario E5 ($HC^+ Ej_0 Er^+$).	55
G.10. Distribución de TIR, TAR y TBR por paciente — Escenario E6 ($HC^- Ej^+ Er^+$).	55
G.11. Distribución del Error Absoluto Medio (MAE) por escenario. . .	56
G.12. Distribución de la Raíz Error Cuadrático Medio (RMSE) por escenario.	56
G.13. Distribución de las predicciones según la Clarke Error Grid (CEG) por escenario.	57
G.14. Correlación de Spearman entre Error Absoluto Medio (MAE) y Tiempo en rango (TIR). Horizonte 15 minutos.	58
G.15. Correlación de Spearman entre Error Absoluto Medio (MAE) y Tiempo en rango (TIR). Horizonte 30 minutos.	59
G.16. Correlación de Spearman entre la Raíz del Error Cuadrático Medio (RMSE) y Tiempo en rango (TIR). Horizonte 15 minutos. . .	60
G.17. Correlación de Spearman entre la Raíz del Error Cuadrático Medio (RMSE) y Tiempo en rango (TIR). Horizonte 30 minutos. . .	61
G.18. Correlaciones de Spearman entre Error Absoluto Medio (MAE) y Tiempo en rango (TIR) por escenario, modelo y horizonte . . .	62
G.19. Correlaciones de Spearman entre la Raíz del Error Cuadrático Medio (RMSE) y Tiempo en rango (TIR) por escenario, modelo y horizonte.	62
G.20. Test de Wilcoxon inter-simulación — MAE.	63
G.21. Test de Wilcoxon inter-simulación — RMSE.	63
G.22. Test de Wilcoxon inter-modelo — MAE.	63
G.23. Test de Wilcoxon inter-modelo — RMSE.	64

Índice de tablas

A.1. Milestones del proyecto y fechas de finalización previstas.	9
A.2. Desglose económico de los costes personales	11
A.3. Desglose económico de los costes de hardware	11
A.4. Desglose económico de los costes de computación en la nube. . .	12
A.5. Coste total del proyecto con hardware personal.	12
A.6. Coste total del proyecto con computación en la nube.	13
C.1. CU-1 Ejecutar simulación de pacientes virtuales	18
C.2. CU-2 Visualizar series temporales de glucemia	19
C.3. CU-3 Exploración interactiva de datos por selección de paciente y escenario	20
D.1. Requisitos software del proyecto.	23
D.2. Especificaciones hardware del equipo de desarrollo utilizado como referencia.	24
F.1. Variables fisiológicas de salida del simulador py-mgipsim.	33
F.2. Estadísticas glucosa pacientes Escenario 1 ($HC^- Ej_0 Er_0$) . . .	37
F.3. Estadísticas glucosa pacientes Escenario 2 ($HC^+ Ej_0 Er_0$) . . .	37
F.4. Estadísticas glucosa pacientes Escenario 3 ($HC^- Ej^+ Er_0$) . . .	38
F.5. Estadísticas glucosa pacientes Escenario 4 ($HC^- Ej_0 Er^+$) . . .	39
F.6. Estadísticas glucosa pacientes Escenario 5 ($HC^+ Ej_0 Er^+$) . . .	39
F.7. Estadísticas glucosa pacientes Escenario 6 ($HC^- Ej^+ Er^+$) . . .	40
G.1. Parámetros comunes a todos los escenarios experimentales. . . .	45
G.2. Rangos horarios de inicio de cada ingesta, comunes a todos los escenarios.	46
G.3. Cantidades objetivo de hidratos de carbono por ingesta y varia- bilidad por escenario.	47

G.4. Espacio de búsqueda de hiperparámetros para XGBoost y justificación de los rangos.	51
G.5. Hiperparámetros óptimos de XGBoost, comunes a los horizontes de 15 y 30 minutos.	52
G.6. Importancia de las 10 principales variables para XGBoost	64
G.7. Importancia de las 10 principales variables para ARIMAX	64

Apéndice A

Plan de Proyecto

A.1. Introducción

Este trabajo aborda el estudio comparativo de modelos predictivos de glucemia en pacientes con DM1 en régimen MDI. El alcance definitivo no estuvo definido desde el inicio: los primeros meses se dedicaron a explorar la viabilidad de acceder a datos reales de pacientes, lo que condicionó el arranque formal del proyecto.

A partir de octubre de 2025 se inició el contacto con la especialidad de endocrinología del Hospital Universitario de Burgos (HUBU) para identificar una cotutora clínica, valorar el tema y explorar el acceso a datos de pacientes reales. La reunión con el servicio hospitalario no pudo celebrarse hasta enero de 2026, momento en el que se constató que el acceso a datos reales presentaba barreras significativas: el proceso requería el consentimiento individualizado de cada paciente, los tiempos de respuesta dependían de las consultas clínicas y pocos pacientes disponían de registros completos de todas las variables de interés. Se exploró también la vía de la asociación local de diabetes (Asociación de Diabéticos de Burgos), con el mismo resultado. Paralelamente, desde enero de 2026 se inició la búsqueda de simuladores y datasets públicos como alternativa.

Una vez definida y aprobada la línea de trabajo, la planificación se formalizó mediante milestones e issues en [GitHub](#)¹ ([GitHub, Inc., 2026](#)), plataforma de gestión utilizada durante todo el desarrollo. No obstante, el trabajo previo de búsqueda de información, contacto con el hospital y

¹url repositorio: <https://github.com/WillyFtAb/TFG-GIS-Predictor-glucosa.git>

exploración de alternativas no quedó reflejado en GitHub ([GitHub, Inc., 2026](#)) al no haberse formalizado aún el proyecto.

A.2. Metodología de ingeniería del software

El trabajo siguió una metodología experimental iterativa, centrada en el análisis de datos y la evaluación de modelos más que en el desarrollo de un sistema software completo. Las fases se organizaron de forma secuencial pero con retroalimentación entre ellas: los resultados del preprocesamiento condicionaron decisiones de diseño experimental, y los resultados de la evaluación determinaron el alcance final de los modelos desarrollados.

La gestión de tareas se realizó mediante issues agrupadas en milestones en GitHub, lo que permitió un seguimiento incremental del progreso. Dado que el trabajo no incluye el desarrollo de un sistema software desplegable, no se aplicó ninguna metodología ágil formal.

Las fases previstas inicialmente que no pudieron completarse fueron: la validación con un segundo simulador o con datos reales, el análisis de significación de variables exógenas y la implementación de Prophet ([Taylor and Letham, 2018](#)) como modelo adicional. Estas quedan identificadas como líneas futuras en el Capítulo 8 de la memoria.

De cara a un desarrollo software futuro basado en este trabajo —por ejemplo, un sistema de soporte a la decisión clínica para pacientes MDI— se recomienda una metodología ágil con sprints cortos (Scrum), dado que el dominio clínico requiere validación iterativa con especialistas y los requisitos pueden evolucionar con los resultados experimentales.

A.3. Planificación temporal

La planificación formal del proyecto se inició en marzo de 2026, una vez definida y aprobada la línea de trabajo. Se organizó en cinco milestones principales más un milestone de seguimiento para reuniones y tareas transversales. La Tabla [A.1](#) resume los hitos y la Figura [A.1](#) muestra su distribución temporal. A continuación se detallan las tareas asociadas a cada milestone.

Fase previa (oct. 2025 – ene. 2026): contacto con el servicio de endocrinología del hospital, búsqueda de cotutora clínica, exploración de acceso a datos reales y búsqueda de simuladores y datasets públicos. Esta fase no está reflejada en GitHub al ser anterior a la formalización del proyecto.

M1 — Obtención y validación de datos (ene. – mar. 2026): configuración del entorno y simuladores, diseño experimental, generación de datasets virtuales y validación clínica de los datos generados con la cotutora especialista.

M2 — Preprocesamiento de los datos (mar. – abr. 2026): implementación de un parser multiformato para la lectura de los archivos del simulador, resampling y ajuste temporal de las series a 5 minutos, y exploración de funciones de estandarización y normalización.

M3 — Desarrollo y entrenamiento del predictor (abr. – abr. 2026): implementación de XGBoost, implementación de ARIMAX, implementación y descarte de Prophet por incompatibilidad con el entorno, y ajuste de hiperparámetros mediante búsqueda bayesiana y grid search.

M4 — Validación clínica y métricas de error (abr. – may. 2026): diseño de la estrategia de evaluación, implementación del backtesting y visualización de resultados mediante métricas de error y Clarke Error Grid.

M5 — Escritura de memoria (may. – jun. 2026): redacción de todos los capítulos de la memoria, elaboración de anexos y revisión final para la entrega.

Seguimiento: reuniones periódicas con tutores a lo largo de todo el desarrollo, envío del compromiso alumno-tutor y redacción de la propuesta de TFG.

Tabla A.1: Milestones del proyecto y fechas de finalización previstas.

Hito	Inicio previsto	Fin previsto
Fase previa	Oct 2025	Ene 2026
M1: Obtención y validación de datos	Ene 2026	Mar 2026
M2: Preprocesamiento de datos	Mar 2026	Abr 2026
M3: Desarrollo y entrenamiento de modelos	Abr 2026	Abr 2026
M4: Validación clínica y métricas de error	Abr 2026	May 2026
M5: Escritura de memoria y entrega final	May 2026	Jun 2026




Figura A.1: Distribución temporal inicial (amarillo) y final (azul) de los hitos del trabajo.

A.4. Planificación económica

La estimación económica del proyecto contempla los costes directos asociados al trabajo del alumno, la supervisión tutorial y el uso de equipamiento hardware. No se han incurrido costes de licencias de software, dado que todas las herramientas utilizadas —Python ([Python Software Foundation, 2025](#)), GitHub([GitHub, Inc., 2026](#)) y Google Colab ([Google, 2026](#)) en su modalidad gratuita— son de acceso libre.

Costes de personal

El coste del trabajo del alumno se estima a partir de las 360 horas previstas, aplicando el salario bruto promedio de un ingeniero biomédico junior según [Indeed \(2026\)](#).

Tabla A.2: Desglose económico de los costes personales

Concepto económico	Porcentaje	Coste Total
1. Salario bruto (23€/h x 360h)	Sueldo Base	8.280,00 €
2. Seguros sociales		
Contingencias comunes	18,88 %	1.563,26 €
Desempleo (Contrato temporal bonificado)	1,34 %	110,95 €
MEI (Mecanismo de Equidad Intergeneracional)	0,75 %	62,10 €
FOGASA (Fondo de Garantía Salarial Bonificado)	0,04 %	3,31 €
Contingencias Profesionales	1,50 %	124,20 €
Total cuota Seguridad Social	22,51 %	1.863,82 €
3. Obligaciones al finalizar el contrato		
Indemnización fin de contrato (12 días/año)	3,29 %	272,21 €
COSTE TOTAL		10.416,03 €

Costes de hardware

El desarrollo se realizó sobre hardware personal del alumno. Fue necesario el uso de dos dispositivos, pues la necesidad de cómputo era elevada. La amortización de cada equipo durante el periodo de uso del proyecto se calcula según la expresión recogida en la figura A.2.

$$\text{Amortización del periodo} = \frac{\text{Precio de compra}}{\text{Vida útil en años}} \times \frac{\text{Meses de uso}}{12}$$

Figura A.2: Fórmula para el cálculo de la amortización durante un periodo determinado.

Tabla A.3: Desglose económico de los costes de hardware

Concepto	Coste (€)	Vida útil (años)	Meses de uso	Amortización (€)
Ordenador personal principal	889	5	3	44,5

Concepto	Coste (€)	Vida útil (años)	Meses de uso	Amortización (€)
Ordenador personal secundario	930	6	2	25,83
Total hardware				70,33

Consideraciones sobre el uso de hardware personal

El uso de ordenadores personales para el desarrollo del proyecto implica un coste temporal significativo derivado del tiempo de cómputo requerido por el backtesting y la optimización de hiperparámetros. Se estima un mínimo de 300 horas de uso intensivo, incluyendo pruebas y reinicios por fallos. Quien desee replicar el estudio debe contemplar este coste temporal como un factor limitante, especialmente si no se dispone de acceso a infraestructura de cómputo de alto rendimiento.

Costes de infraestructura cloud (referencia)

Aunque no se ha incurrido en coste alguno por uso de Google Colab ([Google, 2026](#)), se incluye como referencia el coste que habría supuesto el uso de la modalidad Colab Pro+ durante el periodo de desarrollo intensivo de modelos (aproximadamente 3 meses), a un precio de 51,12 €/mes ([Google, 2026](#)).

Tabla A.4: Desglose económico de los costes de computación en la nube.

Concepto	Coste mensual (€)	Meses	Total (€)
Google Colab Pro+	51,12	2	102,24

Resumen económico

A continuación, se muestran las 2 opciones de contratación. La primera, (Tabla A.5) conlleva el uso del hardware personal, mientras que la segunda (Tabla A.6) utiliza la opción de Google Colab ([Google, 2026](#)).

Tabla A.5: Coste total del proyecto con hardware personal.

Concepto	Total (€)
Personal	10416,03

Concepto	Total (€)
Hardware	70,33
Software y licencias	0,00
Total del proyecto	10486,36

Tabla A.6: Coste total del proyecto con computación en la nube.

Concepto	Total (€)
Personal	10416,03
Hardware	10,00
Cloud	102,24
Total del proyecto	10528,27

A.5. Viabilidad legal

El presente trabajo no ha requerido la aprobación de la Comisión de Bioética ni de ningún comité ético de investigación, dado que no involucra datos de pacientes reales. Todos los datos utilizados han sido generados mediante el simulador py-mgipsim ([Siket et al., 2025](#)), que implementa el modelo UVA/Padova ([Man et al., 2014](#)) sobre una cohorte de pacientes virtuales. Al tratarse exclusivamente de datos sintéticos, el trabajo queda fuera del ámbito de aplicación de la normativa de protección de datos de carácter personal.

Reglamento General de Protección de Datos (RGPD)

El Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos ([Parlamento Europeo y Consejo de la Unión Europea, 2016](#)), establece el marco normativo europeo en materia de privacidad. Su ámbito de aplicación material comprende el tratamiento total o parcialmente automatizado de datos personales, así como el tratamiento no automatizado de datos personales contenidos o destinados a ser incluidos en un fichero. Los datos de salud se clasifican como categoría especial de datos, cuyo tratamiento está prohibido con carácter general, salvo en supuestos tasados como el consentimiento explícito del interesado, la protección de intereses vitales o el interés público en el ámbito de la salud pública. Dado que el

presente trabajo no trata datos personales de ningún paciente real, el RGPD no resulta de aplicación.

Ley Orgánica 3/2018 de Protección de Datos Personales

La Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales (LOPDGDD) ([Jefatura del Estado, 2018](#)) adapta el RGPD al ordenamiento jurídico español y establece garantías adicionales para el tratamiento de datos sensibles. En materia de investigación sanitaria, la disposición adicional decimoséptima de la LOPDGDD introduce previsiones encaminadas a garantizar el adecuado desarrollo de la investigación en materia de salud, ponderando los beneficios que esta aporta a la sociedad con las debidas garantías del derecho fundamental a la protección de datos. Al no existir tratamiento de datos de pacientes reales en este trabajo, tampoco resulta de aplicación esta norma.

Licencias de software

Las herramientas de software utilizadas son de código abierto o de uso libre, sin restricciones de licencia que limiten su uso académico. El simulador py-mgipsim ([Siket et al., 2025](#)) se distribuye bajo licencia MIT ([Massachusetts Institute of Technology, 1988](#)), que permite su uso, modificación y distribución sin restricciones. Las librerías de Python ([Python Software Foundation, 2025](#)) y R ([R Core Team, 2025](#)) empleadas se distribuyen bajo licencias BSD ([Regents of the University of California, 1990](#)), Apache 2.0 ([Apache Software Foundation, 2004](#)) o GPL ([Free Software Foundation, 2007](#)), todas compatibles con el uso académico y la reproducibilidad del estudio.

Apéndice B

Manual de especificación de diseño

El presente trabajo no incluye desarrollo de hardware ni de un sistema software desplegable, por lo que los apartados de planos técnicos y diseño arquitectónico no resultan de aplicación.

Especificación de Requisitos

C.1. Diagrama de casos de uso

El trabajo no desarrolla un sistema software con interfaz de usuario final, por lo que el diagrama de casos de uso (Figura C.1) se limita a las interacciones del investigador con las herramientas utilizadas durante el desarrollo. Se identifican tres casos de uso principales:

- **CU-1:** Ejecutar simulación de pacientes virtuales.
- **CU-2:** Visualizar series temporales de glucemia generadas.
- **CU-3:** Exploración interactiva de datos por selección de paciente y escenario.




Figura C.1: Diagrama de casos de uso del sistema.

C.2. Casos de uso

CU-1	Ejecutar simulación de pacientes virtuales
Versión	1.0
Autor	Investigador
Descripción	El investigador ejecuta el simulador py-mgipsim para generar series temporales de glucemia bajo un escenario experimental definido.
Precondición	Python 3.12 instalado y dependencias del simulador instaladas mediante <i>pip install -r requirements.txt</i>
Acciones	El investigador selecciona la modalidad de ejecución (GUI o CLI). - Modalidad GUI: ejecutar <code>streamlit run interface_gui.py</code> en terminal, configurar los parámetros del escenario mediante la interfaz web y lanzar la simulación. - Modalidad CLI interactiva: ejecutar <code>interface_cmd.py</code>, cargar un escenario predefinido con <code>load -sn <nombre_escenario></code> y ejecutar <code>simulate</code>. - Modalidad CLI comando único: ejecutar <code>interface_cli.py [OPTIONS]</code> con los parámetros definidos en línea de comandos.
Postcondición	Los resultados se almacenan en <code>./SimulationResults/<carpetacondatettime>/. </code>
Excepciones	Versión de Python incompatible; dependencias no instaladas.
Importancia	Alta

Tabla C.1: CU-1 Ejecutar simulación de pacientes virtuales

CU-2	Ejecutar función de visualizado de las series temporales
Versión	1.0
Autor	Investigador
Descripción	El investigador ejecuta una función de visualización sobre los datos generados por el simulador para inspeccionar la serie glucémica de los paciente en un escenario determinado.
Precondición	Datos del simulador disponibles; entorno Python con matplotlib activo.
Acciones	1. El investigador abre el notebook de visualización. 2. Especifica la ruta de los archivos con los datos generados por el simulador. 3. Ejecuta la función de visualización. 4. Se generan las gráficas con las series temporales de glucemia de los pacientes.
Postcondición	La/s gráfica/s se muestra en pantalla y puede/n exportarse como imagen
Excepciones	Ficheros de datos no encontrados
Importancia	Media

Tabla C.2: CU-2 Visualizar series temporales de glucemia

CU-3	Exploración interactiva de datos por selección de paciente y escenario
Versión	1.0
Autor	Investigador
Descripción	El investigador selecciona por teclado el escenario y el paciente de interés para obtener una visualización directa de la serie glucémica, sin necesidad de modificar el notebook.
Precondición	Datos del simulador disponibles; entorno Python con matplotlib activo.
Acciones	1. El investigador ejecuta la función interactiva. 2. El sistema solicita por teclado el número de escenario (1–6) y el identificador de paciente (0–19). 3. El sistema valida la entrada. 4. Se genera y muestra la gráfica correspondiente.
Postcondición	La gráfica se muestra en pantalla.
Excepciones	Entrada no válida; datos del escenario no disponibles.
Importancia	Media

Tabla C.3: CU-3 Exploración interactiva de datos por selección de paciente y escenario

C.3. Prototipos de interfaz

Las siguientes capturas muestran las dos modalidades de interacción con el simulador py-mgipsim (Siket et al., 2025) disponibles para el investigador y la salida de la ejecución de la función de visualizado de las series temporales de glucosa.




Figura C.2: Interfaz gráfica del simulador py-mgipsim




Figura C.3: Línea de comandos del simulador py-mgipsim




Figura C.4: Visualización de serie glucémica

Apéndice *D*

Documentación de usuario

D.1. Requisitos software y hardware

Requisitos software

Tabla D.1: Requisitos software del proyecto.

Software	Versión	Descripción
Python	3.12.0	Lenguaje de programación principal
conda	23.x o superior	Gestor de entornos y dependencias
Git	Reciente	Control de versiones y clonado del repositorio
py-mgipsim	Última versión (descargada en 2026)	Simulador de pacientes virtuales (opcional)

Las dependencias de Python del proyecto se recogen en el fichero `environment.yml` del repositorio, que permite reproducir el entorno de forma completa. Las versiones exactas de cada librería se especifican en dicho fichero.

Requisitos hardware

El proyecto no presenta requisitos estrictos de almacenamiento: los datos generados por el simulador ocupan menos de 10 GB en disco, una cantidad asumible para el estándar de almacenamiento actual.

El factor limitante es la capacidad de procesamiento y la memoria RAM disponibles. El backtesting con refit sobre 120 series temporales requiere tiempos de cómputo elevados; equipos con procesadores poco potentes o RAM insuficiente pueden hacer inviable la ejecución en tiempos razonables. El trabajo se ha desarrollado sobre un equipo con las siguientes especificaciones, que se proponen como referencia orientativa en la Tabla D.2:

Tabla D.2: Especificaciones hardware del equipo de desarrollo utilizado como referencia.

Componente	Especificación
Procesador	AMD Ryzen 7 5700U (1,80 GHz, 8 núcleos)
RAM	16,0 GB (15,4 GB usable)
Tarjeta gráfica	AMD Radeon Graphics (496 MB / 7,7 GB)
Sistema operativo	Windows 11

D.2. Instalación y puesta en marcha

Los pasos siguientes describen el proceso completo para reproducir el entorno y ejecutar el pipeline de análisis. Con la estructura del repositorio tal como se entrega, es posible replicar el estudio completo a partir de los datos serializados incluidos. Los pasos 3 y 4 son opcionales y solo necesarios si se desean generar nuevos datos con el simulador.

Paso 1 — Clonar el repositorio

```
git clone https://github.com/WillyFtAb/TFG-GIS-Predictor-glucosa.git
cd TFG-GIS-Predictor-glucosa
```

Paso 2 — Crear el entorno conda e instalar dependencias

```
conda env create -f environment.yml
conda activate tfg-glucosa
```

Paso 3 — Instalar el simulador py-mgipsim (opcional)

Si se desea generar nuevos datos con el simulador, es necesario instalarlo de forma independiente:

```
git clone https://github.com/illinoistech-itm/py-mgipsim.git
cd py-mgipsim
pip install -r requirements.txt
```

Paso 4 — Generar nuevos datos con el simulador (opcional)

Una vez instalado el simulador, los datos pueden generarse mediante la interfaz gráfica o la interfaz de línea de comandos, tal como se describe en el Anexo C (CU-1). Los ficheros de resultados (XLSX y JSON) deben colocarse en las subcarpetas correspondientes de `py-mgipsim-main/SimulationResults/`. A continuación, debe ejecutarse el script `guardar_df.py` desde la carpeta `Analisis_y_resultados/` para generar los archivos serializados en `Simulaciones/`. Si se utilizan datos distintos a los originales, será necesario ajustar las rutas definidas en dicho script.

Paso 5 — Visualizar los datos generados

Abrir y ejecutar el notebook de visualización desde la carpeta `Analisis_y_resultados/`:

```
jupyter notebook Analisis_y_resultados/Comprobar_simulaciones.ipynb
```

El notebook permite inspeccionar las series temporales de glucemia generadas por el simulador. El usuario debe especificar el número de escenario (1–6) y el identificador de paciente (0–19) para obtener la gráfica correspondiente. Las gráficas pueden exportarse como imagen en la carpeta `Series_glucosa/`.

Paso 6 — Ejecutar el pipeline de análisis

Abrir y ejecutar el notebook principal con las celdas en orden:

```
jupyter notebook Analisis_y_resultados/Pipeline.ipynb
```

El notebook está organizado en secciones secuenciales que corresponden a las fases del análisis: preprocesamiento, ingeniería de características, optimización de hiperparámetros, backtesting y evaluación. Las celdas deben ejecutarse en orden. Algunas celdas están marcadas como opcionales e incluyen comprobaciones básicas de funcionamiento que pueden omitirse. Los resultados se almacenan automáticamente en `Analisis_y_resultados/Resultados/`.

Los parámetros configurables por el usuario se encuentran en la celda de configuración al inicio del notebook, e incluyen la selección de escenarios a evaluar, los horizontes de predicción y las rutas de entrada y salida de datos.

Apéndice *E*

Manual del investigador.

E.1. Estructura de directorios

La estructura de carpetas y archivos del repositorio es la siguiente:

```
TFG-GIS-Predictor-glucosa/
|-- py-mgipsim-main/
|   |-- SimulationResults/
|       |-- Simulacion_1/
|           |-- [nombre_simulacion].json
|           |-- [nombre_simulacion].xlsx
|       |-- Simulacion_2/
|       |-- Simulacion_3/
|       |-- Simulacion_4/
|       |-- Simulacion_5/
|       |-- Simulacion_6/
|-- Simulaciones/
|   |-- Perfiles.ods
|   |-- sim_1_data.pkl
|   |-- ...
|   |-- sim_6_data.pkl
|   |-- Simulacion_1.txt
|   |-- ...
|   |-- Simulacion_6.txt
|-- Memoria/
|-- Analisis_y_resultados/
    |-- Comprobar_simulaciones.ipynb
```

```
|-- guardar_df.py
|-- Pipeline.ipynb
|-- Funciones.py
|-- Series_glucosa/
`-- Resultados/
    |-- ARIMA_resultados/
    |-- Boost_resultados/
    |-- figs/
    |   `-- TIR/
    |-- resultados_modelos.csv
    `-- TIR.csv
```

La carpeta `py-mgipsim-main/SimulationResults/` contiene únicamente los archivos de salida del simulador necesarios para ejecutar el notebook de visualización, dado que el resto de archivos del simulador no se incluyen en el repositorio por restricciones de tamaño. La carpeta `Simulaciones/` contiene los dataframes serializados listos para el pipeline, junto con los documentos de referencia del diseño experimental. La carpeta `Memoria/` contiene todos los archivos necesarios para la redacción del documento. La carpeta `Analisis_y_resultados/` agrupa el código, los notebooks y los resultados del análisis.

E.2. Compilación, instalación y ejecución del proyecto

El proceso de instalación y ejecución del entorno se describe en detalle en el Anexo D (apartado D.2). Desde el punto de vista del investigador, se señalan los siguientes aspectos técnicos adicionales:

El entorno de desarrollo se gestiona mediante conda ([Anaconda, Inc., 2023](#)). El fichero `environment.yml` del repositorio recoge todas las dependencias con sus versiones exactas, garantizando la reproducibilidad del entorno. Para activar el entorno:

```
conda env create -f environment.yml
conda activate tfg-glucosa
```

Las funciones de preprocesamiento, ingeniería de características y evaluación están implementadas en el módulo `Funciones.py`, importado por los

notebooks principales. Cualquier modificación sobre estas funciones se propagará automáticamente a todos los notebooks que las utilicen, sin necesidad de duplicar código.

E.3. Pruebas del sistema

El proyecto no incorpora un sistema formal de pruebas unitarias. La validación del correcto funcionamiento de las funciones de preprocesamiento, ingeniería de características y backtesting se realizó de forma manual durante el desarrollo, mediante la visualización de las series temporales de glucemia, la inspección de los dataframes intermedios y la comprobación de coherencia con los ficheros de origen (XLSX y JSON) generados por el simulador.

El notebook `Comprobar_simulaciones.ipynb` constituye la herramienta principal para verificar visualmente que los datos preprocesados son correctos antes de ejecutar el pipeline de análisis. Las celdas marcadas como opcionales en `Pipeline.ipynb` incluyen comprobaciones básicas de funcionamiento que pueden ejecutarse para validar pasos intermedios del flujo de trabajo.

E.4. Instrucciones para la modificación o mejora del proyecto

El diagrama de la figura [E.1](#) ilustra el flujo completo del pipeline de análisis, desde la generación de datos hasta la evaluación de resultados.

Las principales extensiones y modificaciones que pueden realizarse sobre el proyecto son las siguientes:

Incorporación de nuevos modelos predictivos: para añadir un nuevo modelo al pipeline, es necesario implementar la función de entrenamiento y predicción, definir la estrategia de búsqueda de hiperparámetros y añadir el modelo al bucle de backtesting en `Pipeline.ipynb` y en las funciones correspondientes de `Funciones.py`. Si el modelo no es compatible con la interfaz de `skforecast` ([Amat Rodrigo and Escobar Ortiz, 2024](#)), será necesario adaptar el código de backtesting y evaluación. El resto del pipeline (preprocesamiento, métricas y visualización de resultados) es reutilizable sin modificaciones.

Nuevos escenarios experimentales: la generación de nuevos escenarios se realiza directamente desde el simulador `py-mgipsim` ([Siket et al., 2025](#)), modificando los parámetros de variabilidad en la ingesta, ejercicio

y error en la dosis. Los nuevos ficheros de salida deben colocarse en las subcarpetas correspondientes de `py-mgipsim-main/SimulationResults/` y procesarse con `guardar_df.py` para generar los archivos serializados. Las funciones del pipeline deberán ajustarse para que los bucles incluyan la búsqueda de los nuevos ficheros.

Validación con datos reales: la sustitución de los datos simulados por datos reales requiere adaptar el parser de lectura al formato del dataset utilizado (por ejemplo, OhioT1DM ([Marling and Bunescu, 2020](#))) y verificar que las variables exógenas disponibles son compatibles con las esperadas por las funciones de ingeniería de características en `Funciones.py`.

Análisis de explicabilidad: la integración de SHAP o de la extracción sistemática de importancia de características puede incorporarse al bucle de backtesting añadiendo una llamada a las funciones correspondientes tras cada paso de refit, almacenando los valores de importancia junto con las métricas de evaluación en las carpetas `ARIMA_resultados/` y `Boost_resultados/`.




Figura E.1: Diagrama del pipeline de análisis del proyecto.

Apéndice F

Descripción de adquisición y tratamiento de datos

F.1. Descripción formal de los datos

Los datos utilizados en el trabajo son series temporales de variables fisiológicas y de control generadas mediante el simulador py-mgipsim ([Siket et al., 2025](#)), que implementa el modelo metabólico UVA/Padova ([Man et al., 2014](#)) sobre una cohorte de 20 pacientes virtuales con DM1 en régimen MDI.

Para cada paciente y escenario experimental (E1–E6), el simulador genera un fichero XLSX con una resolución de muestreo de 1 minuto, que contiene 16 variables fisiológicas y de control (Tabla F.1), y un archivo JSON que registra todos los eventos de entrada al simulador con su marca temporal ([Siket et al., 2025](#)). El flujo de trabajo interno del simulador se ilustra en la Figura F.1. El conjunto de datos bruto comprende 120 series temporales independientes (20 pacientes $\times$ 6 escenarios), cada una con una duración de 30 días simulados.

Tabla F.1: Variables fisiológicas de salida del simulador py-mgipsim.

Variable	Unidades	Descripción
S1	mU/min	Compartimento de absorción de insulina subcutánea (1)
S2	S2	Compartimento de absorción de insulina subcutánea (2)

Descripción de adquisición y tratamiento de datos

Variable	Unidades	Descripción
I	I	Concentración de insulina en plasma
x1	x1	Efecto de la insulina sobre la distribución de glucosa
x2	x2	Efecto de la insulina sobre la producción hepática de glucosa
x3	x3	Efecto de la insulina sobre la captación periférica de glucosa
Q1	Q1	Masa de glucosa en el compartimento central
Q2	Q2	Masa de glucosa en el compartimento periférico
IG	mmol/L	Glucosa intersticial (variable de interés principal)
D1Slow	mmol/min	Absorción intestinal lenta de glucosa (compartimento 1)
D2Slow	mmol/min	Absorción intestinal lenta de glucosa (compartimento 2)
D1Fast	mmol/min	Absorción intestinal rápida de glucosa (compartimento 1)
D2Fast	mmol/min	Absorción intestinal rápida de glucosa (compartimento 2)
EEfast	EEfast	Efecto del ejercicio de corta duración sobre la glucosa
EEhighintensity	EEhighintensity	Efecto del ejercicio de alta intensidad
EElongeffect	EElongeffect	Efecto prolongado del ejercicio sobre la sensibilidad a la insulina




Figura F.1: Flujo de trabajo del simulador py-mgipsim. Fuente: Siket et al. (2025).

La documentación oficial del simulador no describe de forma explícita el significado de cada variable de salida. Para su comprensión se recurrió al análisis del código fuente mediante la herramienta de inteligencia artificial Antigravity (Google Antigravity Team, 2026), que permitió interpretar las variables en el contexto del modelo fisiológico subyacente. El detalle del uso de esta herramienta se recoge en el Anexo I.

De entre las 16 variables disponibles en el XLSX, se seleccionó para el análisis la glucosa intersticial (IG, convertida de mmol/L a mg/dL). Las variables de control —insulina en bolo, insulina basal, ingesta de comidas y tentempiés, y ejercicio físico— se obtienen del fichero JSON del escenario. Ambas fuentes se integraron en un único dataframe por paciente y escenario antes de aplicar el preprocesamiento. Las series resultantes se remuestrearon a 5 minutos, resolución habitual de los dispositivos MCG comerciales (Rizos et al., 2025), reduciendo el volumen de datos en un factor de 5 sin pérdida de información relevante para el horizonte de predicción analizado.

Para garantizar la coherencia de los datos generados en los escenarios con error en la dosis de insulina (E4, E5 y E6), fue necesario modificar un parámetro interno del simulador que regula el error estocástico en la insulina. Esta modificación no está incluida en el repositorio del proyecto al tratarse de un fichero perteneciente al código fuente del simulador. Quien desee reproducir exactamente estos escenarios deberá aplicar el mismo ajuste sobre su instalación local de py-mgipsim (Siket et al., 2025). El detalle de las pruebas realizadas hasta obtener datos coherentes se recoge en el Anexo G.

F.2. Descripción clínica de los datos

Las variables seleccionadas para el análisis tienen el siguiente significado clínico en el contexto de la DM1 en régimen MDI:

Glucosa intersticial (IG): es la variable objetivo del estudio. Representa la concentración de glucosa en el líquido intersticial, medida por los dispositivos MCG. Presenta un retardo fisiológico de aproximadamente 5–15 minutos respecto a la glucemia capilar ([Rizos et al., 2025](#)). Los valores de referencia clínica son: rango normoglucémico 70–180 mg/dL (TIR), hipoglucemia <70 mg/dL (TBR) e hiperglucemia >180 mg/dL (TAR).

Insulina en bolo: dosis de insulina de acción rápida administrada antes de cada ingesta, calculada en función de los hidratos de carbono consumidos y la glucemia preprandial mediante la ratio insulina/ración (I:R) ([Calvo Ferrer et al., 2004](#); [Grupo de trabajo de la Guía de Práctica Clínica sobre Diabetes Mellitus Tipo 1, 2026](#)). Constituye la principal perturbación exógena controlable por el paciente y tiene un perfil de acción con inicio a los 15–30 minutos y pico a los 60–90 minutos de su administración.

Insulina basal: dosis de insulina de acción prolongada administrada generalmente una vez al día, cuyo objetivo es mantener la glucemia estable en ausencia de ingesta ([Calvo Ferrer et al., 2004](#); [Grupo de trabajo de la Guía de Práctica Clínica sobre Diabetes Mellitus Tipo 1, 2026](#)). Su perfil de acción se extiende durante 20–24 horas, lo que justifica su acumulación sobre las últimas 24 horas en la ingeniería de características del modelo.

Hidratos de carbono (comidas y tentempiés): cantidad de hidratos de carbono ingeridos en cada evento de ingesta, expresada en gramos. Constituyen el principal determinante de la excursión glucémica postprandial. Los tentempiés generados por el simulador no conllevan administración de insulina en bolo, a diferencia de las comidas principales ([Siket et al., 2025](#)).

Ejercicio físico: variable de intensidad que indica la presencia y características de la actividad física realizada. El ejercicio modifica la sensibilidad a la insulina de forma aguda y prolongada, pudiendo inducir tanto hipoglucemia durante o tras su práctica como hiperglucemia en ejercicio de alta intensidad ([Helleputte et al., 2023](#)).

F.3. Descripción estadística de los datos

Las tablas Tabla [F.2](#) a Tabla [F.7](#) recogen las estadísticas descriptivas de la glucemia (en mg/dL) de los 20 pacientes virtuales para cada escenario

experimental, calculadas sobre las series completas de 30 días a resolución de 5 minutos. El valor mínimo común de 108 mg/dL en la mayoría de pacientes refleja el valor basal de glucemia en ayunas del simulador. Los pacientes con media superior a 200 mg/dL presentan un TIR cercano al 0 %, lo que corresponde a perfiles glucémicos sistemáticamente desplazados hacia la hiperglucemia, tal como se discute en el apartado 6.4 de la memoria.

Tabla F.2: Estadísticas glucosa pacientes Escenario 1 (HC^- E_{j_0} Er_0)

Paciente	Media	Desv. típica	Mín.	Máx.
0	167.55	14.66	108.0	199.0
1	152.14	15.20	108.0	185.0
2	217.82	49.21	108.0	314.0
3	211.00	29.19	108.0	273.0
4	233.19	30.29	108.0	303.0
5	136.42	7.27	108.0	154.0
6	149.41	22.01	108.0	192.0
7	143.88	18.39	108.0	182.0
8	230.39	27.29	108.0	282.0
9	262.25	34.92	108.0	326.0
10	203.64	24.22	108.0	253.0
11	185.58	29.06	108.0	250.0
12	181.83	17.82	108.0	216.0
13	145.60	9.35	107.0	163.0
14	168.41	13.21	108.0	200.0
15	258.91	36.51	108.0	324.0
16	238.63	42.74	108.0	318.0
17	168.15	17.22	108.0	205.0
18	158.00	18.03	108.0	196.0
19	195.86	20.34	108.0	227.0

Tabla F.3: Estadísticas glucosa pacientes Escenario 2 (HC^+ E_{j_0} Er_0)

Paciente	Media	Desv. típica	Mín.	Máx.
0	167.17	15.41	108.0	208.0
1	151.70	16.06	108.0	189.0
2	216.72	50.73	108.0	340.0
3	211.04	29.72	108.0	282.0
4	232.31	31.38	108.0	322.0
5	135.34	7.92	108.0	159.0

Paciente	Media	Desv. típica	Mín.	Máx.
6	149.09	22.38	108.0	203.0
7	143.38	18.80	108.0	189.0
8	228.52	29.29	108.0	299.0
9	261.98	36.54	108.0	346.0
10	203.32	24.91	108.0	268.0
11	186.07	29.82	108.0	278.0
12	181.48	18.38	108.0	224.0
13	145.13	10.43	106.0	168.0
14	169.70	14.07	108.0	207.0
15	258.16	37.54	108.0	337.0
16	237.89	43.85	108.0	333.0
17	168.49	17.78	108.0	216.0
18	158.11	18.52	108.0	202.0
19	196.61	21.53	108.0	232.0

Tabla F.4: Estadísticas glucosa pacientes Escenario 3 ($\text{HC}^- \text{Ej}^+ \text{Er}_0$)

Paciente	Media	Desv. típica	Mín.	Máx.
0	161.92	13.71	108.0	197.0
1	149.33	14.56	108.0	185.0
2	211.66	45.49	108.0	304.0
3	202.41	27.16	108.0	272.0
4	224.84	29.60	108.0	298.0
5	136.13	7.09	108.0	154.0
6	150.75	22.11	108.0	194.0
7	144.19	18.80	108.0	182.0
8	219.41	27.77	108.0	278.0
9	250.33	32.21	108.0	320.0
10	194.55	23.12	108.0	246.0
11	178.91	26.99	108.0	245.0
12	170.68	16.68	108.0	210.0
13	143.23	9.55	105.0	162.0
14	166.80	13.25	108.0	201.0
15	248.88	33.67	108.0	318.0
16	231.75	40.85	108.0	314.0
17	167.69	16.83	108.0	207.0
18	158.53	17.79	108.0	196.0
19	186.31	21.59	106.0	220.0

Tabla F.5: Estadísticas glucosa pacientes Escenario 4 (HC^- Ej_0 Er^+)

Paciente	Media	Desv. típica	Mín.	Máx.
0	165.96	19.01	108.0	219.0
1	152.83	19.02	108.0	206.0
2	212.22	50.01	108.0	315.0
3	217.60	34.07	108.0	298.0
4	230.79	35.48	108.0	317.0
5	136.90	9.22	108.0	166.0
6	149.81	22.73	108.0	201.0
7	143.18	19.67	108.0	191.0
8	235.56	32.80	108.0	310.0
9	268.00	38.47	108.0	350.0
10	202.68	28.83	108.0	269.0
11	184.57	31.11	108.0	277.0
12	182.21	21.23	108.0	235.0
13	147.60	13.03	94.0	179.0
14	169.51	17.76	108.0	217.0
15	258.03	40.05	108.0	339.0
16	238.67	44.17	108.0	327.0
17	170.56	19.70	108.0	230.0
18	157.65	18.86	108.0	202.0
19	194.61	23.28	108.0	244.0

Tabla F.6: Estadísticas glucosa pacientes Escenario 5 (HC^+ Ej_0 Er^+)

Paciente	Media	Desv. típica	Mín.	Máx.
0	162.52	18.34	108.0	216.0
1	150.50	17.41	108.0	198.0
2	220.98	52.29	108.0	349.0
3	210.29	33.52	108.0	295.0
4	232.59	35.36	108.0	331.0
5	133.53	10.33	108.0	163.0
6	149.50	22.68	107.0	211.0
7	144.01	19.28	108.0	194.0
8	223.61	34.74	108.0	304.0
9	258.73	38.97	108.0	358.0
10	205.90	26.37	108.0	274.0
11	184.61	31.86	108.0	274.0

Paciente	Media	Desv. típica	Mín.	Máx.
12	183.23	21.22	108.0	234.0
13	144.64	12.37	102.0	182.0
14	172.67	17.40	108.0	228.0
15	258.11	42.50	108.0	373.0
16	240.41	46.02	108.0	354.0
17	169.21	19.57	108.0	231.0
18	158.11	19.82	108.0	202.0
19	198.09	24.23	108.0	246.0

Tabla F.7: Estadísticas glucosa pacientes Escenario 6 ($\text{HC}^- \text{Ej}^+ \text{Er}^+$)

Paciente	Media	Desv. típica	Mín.	Máx.
0	161.17	17.96	108.0	216.0
1	148.13	16.74	108.0	193.0
2	211.09	47.79	108.0	331.0
3	203.63	29.23	108.0	283.0
4	227.97	33.21	108.0	316.0
5	135.21	9.48	108.0	162.0
6	149.39	22.39	108.0	208.0
7	143.22	19.37	108.0	193.0
8	222.97	31.47	108.0	303.0
9	247.01	39.31	108.0	358.0
10	193.89	25.41	108.0	259.0
11	183.71	30.61	108.0	275.0
12	169.39	20.95	108.0	223.0
13	144.05	12.40	107.0	181.0
14	167.27	16.07	108.0	211.0
15	239.66	35.63	108.0	327.0
16	234.90	43.30	108.0	330.0
17	166.83	19.78	108.0	217.0
18	159.17	18.69	108.0	204.0
19	188.70	23.92	105.0	235.0

Apéndice *G*

Estudio experimental

G.1. Cuaderno de trabajo

Diseño experimental inicial

El diseño experimental inicial contemplaba la creación de distintos grupos de pacientes virtuales con perfiles de control glucémico diferenciados —buen control y mal control— mediante la modulación del error estocástico en las unidades de insulina administradas, con el objetivo de estudiar el efecto del perfil del paciente sobre el rendimiento predictivo de los modelos.

Para implementar este diseño se modificaron las variables `basal_uncertainty` y `bolus_uncertainty`¹ del simulador, ensayando distintas combinaciones de valores para ambas variables. Se exploró también la incorporación de un escenario de ayuno intermitente como caso de estudio adicional.

Resultados no exitosos

Las pruebas con valores no nulos de `basal_uncertainty` generaron de forma sistemática series glucémicas con periodos prolongados de hipoglucemia severa, con valores continuos e iguales que evidenciaban un estado fisiológico irreal. La introducción de incertidumbre en la insulina basal resultó incompatible con la estabilidad del simulador para la mayoría de los pacientes virtuales de la cohorte (ver Figura G.2).

¹archivo `pymgipsim/Controllers/StochasticOpenLoop/controller.py`




Figura G.1: Ejemplo de serie glucémica obtenida durante las pruebas previas, con episodios de hipoglucemia severa sostenida.

El escenario de ayuno (Figura ??) intermitente fue descartado porque su inclusión habría incrementado de forma significativa el número de combinaciones a evaluar, haciendo inviable su ejecución dentro de las restricciones de tiempo y capacidad de cómputo disponibles.




Figura G.2: Ejemplo de serie glucémica escenario de ayuno intermitente.

Diseño experimental definitivo

La identificación de las causas de los episodios críticos no fue inmediata. La escasa documentación oficial del simulador —limitada a una descripción funcional de las interfaces de usuario y sin referencia al significado de las variables internas ni a los parámetros fisiológicos de los pacientes virtuales— dificultó significativamente la comprensión del sistema. Para interpretar el

código fuente y entender el origen de los resultados anómalos fue necesario recurrir al análisis mediante herramientas de inteligencia artificial, como se detalla en el Anexo I.

Una vez analizado el comportamiento del simulador, se identificaron dos limitaciones estructurales que hacían inviable el diseño experimental inicial:

- La cohorte del simulador está fijada en 20 pacientes virtuales cuyos parámetros fisiológicos no pueden modificarse directamente sin crear nuevos perfiles desde cero. La creación de nuevos pacientes requeriría definir manualmente todos los parámetros del modelo metabólico subyacente, una tarea que constituye en sí misma un trabajo de investigación independiente y que excede el alcance del presente TFG.
- El simulador no contempla la ingesta de hidratos de carbono de rescate ante hipoglucemia ni la administración de bolos correctores ante hiperglucemia. Esto provoca que, al introducir error estocástico en la insulina, algunos pacientes no sean capaces de estabilizarse dentro del patrón de variables establecido para ellos, generando los episodios críticos sostenidos observados.

Ante estas limitaciones, se optó por fijar `basal_uncertainty` a 0 para garantizar la estabilidad de las simulaciones, y establecer `bolus_uncertainty` en un valor equivalente al 10 % de error. Los valores definitivos utilizados en los escenarios con error en la dosis (E4, E5 y E6) son:

```
self.basal_uncertainty = 0
self.bolus_uncertainty = 2.0/20.0
```

Para los escenarios sin error en la dosis (E1, E2 y E3), ambas variables se establecieron a 0. El diseño experimental definitivo se basó en la variabilidad de las condiciones de manejo —variabilidad en la ingesta de HC, presencia de ejercicio y error en el cálculo de la ratio insulina/ración— manteniendo los parámetros fisiológicos de los 20 pacientes virtuales sin modificar, tal como se describe en el Capítulo 4.

Desarrollo e implementación de los modelos

El desarrollo de los modelos se abordó de forma secuencial. En primer lugar se implementó XGBoost, dado su carácter no paramétrico y la disponibilidad de herramientas de optimización bayesiana en `skforecast` ([Amat Rodrigo and Escobar Ortiz, 2024](#)). A continuación se implementó ARIMAX,

cuya búsqueda de hiperparámetros mediante `grid_search_stats` resultó computacionalmente más costosa que la optimización bayesiana de XGBoost. Se valoró la incorporación de Prophet (Taylor and Letham, 2018) como tercer modelo —representando una familia distinta de predictores— pero fue descartado por incompatibilidades entre las versiones de las dependencias del entorno de desarrollo.

La optimización de hiperparámetros de ambos modelos se realizó de forma independiente sobre el paciente 1 del escenario E3. La elección de este paciente de referencia respondió a dos criterios: presentar un perfil glucémico con un tiempo en rango adecuado y una variabilidad glucémica ni excesivamente reducida ni elevada (Figura G.3); e incluir la variable de ejercicio físico, garantizando que el modelo pudiera capturar la importancia de dicha variable durante el entrenamiento. Se descartó utilizar el mismo paciente en el escenario E6 —que incluye tanto ejercicio como error en la dosis— para evitar que el modelo se entrenase sobre condiciones perturbadas, prefiriendo entrenar sobre el caso ideal y evaluar posteriormente el efecto de las perturbaciones de forma controlada.




Figura G.3: Serie glucémica del paciente de referencia (paciente 1, escenario E3) utilizado para la optimización de hiperparámetros.

Optimización del tiempo de cómputo

Los tiempos iniciales del backtesting superaban la hora por ejecución, lo que hacía inviable completar las 240 evaluaciones por modelo en un tiempo razonable. Para reducir el tiempo de cómputo se adoptaron las siguientes medidas:

- Configuración del parámetro `n_jobs = -1` en `skforecast` ([Amat Rodrigo and Escobar Ortiz, 2024](#)), permitiendo la paralelización del backtesting sobre todos los núcleos del procesador disponibles.
- Configuración del sistema operativo en modo de alto rendimiento, evitando la limitación de frecuencia del procesador.
- Uso de un dispositivo de ventilación externa para reducir la temperatura del procesador y evitar el throttling térmico.
- Conexión continua a la corriente eléctrica y desactivación del modo de suspensión, que en las primeras ejecuciones pausaba el proceso de forma inesperada.

Con estas medidas se consiguió una reducción aproximada del 30–40 % del tiempo de cómputo. El uso del equipo para otras tareas de forma paralela durante las ejecuciones resultó prácticamente inviable.

G.2. Configuración y parametrización de las técnicas

Parámetros de configuración comunes a todos los escenarios

Todos los escenarios comparten los siguientes parámetros de simulación:

Tabla G.1: Parámetros comunes a todos los escenarios experimentales.

Parámetro	Valor	Justificación
Días de simulación	30	Máximo permitido por el simulador
Semilla aleatoria	402	Valor por defecto; garantiza reproducibilidad
Modelo metabólico	T1DM.ExtHovorka	Modelo de referencia del simulador
Tiempo de muestreo	1 min	Resolución máxima del simulador
Función renal	1	Estado por defecto; sin deterioro renal

Estudio experimental

Parámetro	Valor	Justificación
Rango de peso corporal	60–80 kg	Valor por defecto; no modificado para evitar efectos no controlados en los resultados
Exportación a Excel	True	Necesario para extraer los datos de glucemia

Horarios de ingesta

los rangos horarios de inicio de cada ingesta se establecieron modificando el archivo `py-mgipsim-main/scenarios_default.py` del simulador:

```
scenario["input_generation"]['breakfast_time_range'] = [495, 525]
scenario["input_generation"]['am_snack_time_range']   = [645, 675]
scenario["input_generation"]['lunch_time_range']      = [855, 885]
scenario["input_generation"]['pm_snack_time_range']   = [1035, 1065]
scenario["input_generation"]['dinner_time_range']     = [1245, 1275]
```

desde el inicio de la simulación, son comunes a todos los escenarios: Estos valores son comunes a todos los escenarios y se recogen en la Tabla G.2 con su equivalencia horaria:

Tabla G.2: Rangos horarios de inicio de cada ingesta, comunes a todos los escenarios.

Ingesta	Inicio mínimo (min)	Inicio máximo (min)	Equivalencia horaria
Desayuno	495	525	08:15 – 08:45
Media mañana	645	675	10:45 – 11:15
Comida	855	885	14:15 – 14:45
Merienda	1035	1065	17:15 – 17:45
Cena	1245	1275	20:45 – 21:15

La duración de cada ingesta no fue modificada respecto a los valores por defecto del simulador.

Cantidad de hidratos de carbono

Las cantidades de hidratos de carbono se establecieron a partir de una dieta de referencia de 2.000 kcal diarias para población adulta, valor coherente con las referencias para mujeres adultas españolas ([Biblioteca Nacional de Medicina de los EE. UU., 2026](#)). La Autoridad Europea de Seguridad Alimentaria (EFSA) establece que los hidratos de carbono deben aportar entre el 45 y el 60 % de la energía total consumida ([Agencia Española de Seguridad Alimentaria y Nutrición, 2010](#), [Biblioteca Nacional de Medicina de los EE. UU. \(2026\)](#)). Se adoptó el límite inferior del rango (45 %), que corresponde a 900 kcal y equivale a 225 g de HC diarios (a razón de 4 kcal/g). La distribución porcentual por ingesta se basó en las recomendaciones del Ministerio de Sanidad ([Ministerio de Sanidad, 2022b](#)):

Tabla G.3: Cantidades objetivo de hidratos de carbono por ingesta y variabilidad por escenario.

Ingesta	Distribución (%)	HC objetivo (g)	Variabilidad E1,E3,E4,E6	Variabilidad E2,E5
Desayuno	20	45,0	± 5 %	± 25 %
Media mañana	10	22,5	± 5 %	± 25 %
Comida	35	78,8	± 5 %	± 25 %
Merienda	10	22,5	± 5 %	± 25 %
Cena	25	56,2	± 5 %	± 25 %
Total	100	225,0		

Dado que los pacientes virtuales tienen pesos, sexos y niveles de actividad física distintos, y que la talla y la edad no están disponibles en el simulador, no fue posible calcular un requerimiento energético individualizado para cada paciente. La dieta de 2.000 kcal se adoptó como valor de referencia común para toda la cohorte, priorizando la comparabilidad entre escenarios sobre la precisión individual.

Ejercicio físico

Para los escenarios con ejercicio (E3 y E6), la actividad física se configuró como carrera continua diaria de 30 minutos, con inicio entre las 16:00 y las 16:30, y una intensidad de 1,7 a 2,5 m/s (6,1 a 9,0 km/h).

Según las recomendaciones del Ministerio de Sanidad, la actividad física vigorosa —categoría en la que se encuadra correr a esta velocidad en población adulta— produce beneficios adicionales para la salud cuando se superan los 150 minutos semanales, incluyendo fortalecimiento muscular y mayor mejora cardiovascular ([Ministerio de Sanidad, 2022a](#)). Con 30 minutos diarios se alcanzan 210 minutos semanales de actividad vigorosa, dentro del rango de máximo beneficio recomendado. Se eligió esta configuración para representar el caso de mayor impacto fisiológico del ejercicio sobre la glucemia, garantizando que su efecto fuese detectable en el rendimiento de los modelos predictivos.

Para los escenarios sin ejercicio (E1, E2, E4 y E5), la duración e intensidad de la actividad física se establecieron a 0.

Ingeniería de características

La construcción de las variables de entrada de los modelos se basó en los tiempos de acción de los distintos tipos de insulina disponibles ([Mora Navarro et al., 2022](#), [CDCespanol \(2024\)](#)). La figura G.4 recoge las principales insulinas comercializadas en España con sus tiempos de inicio, pico máximo y duración de acción.

Para la insulina en bolo (de acción rápida o ultrarrápida), el pico de efecto se produce entre 1 y 2 horas tras la administración y la duración total es de 2 a 4 horas ([Mora Navarro et al., 2022](#), [CDCespanol \(2024\)](#)). Para los hidratos de carbono, la absorción intestinal y el pico glucémico postprandial se producen en una ventana similar. Sobre esta base, se estableció la generación de variables acumuladas en intervalos de 20 minutos durante las últimas 4 horas (240 minutos) para la insulina en bolo, los hidratos de carbono y el ejercicio físico, capturando así el perfil temporal completo de acción de cada variable sobre la glucemia.

La insulina basal es el único caso especial, se administra a las 00:00 de cada día, y tiene una duración entorano a un día completo. Por este motivo, la acumulación de los datos se estableció sobre las últimas 24 horas.

Insulinas comercializadas en España. Noviembre 2022								
Autores: Gustavo Mora Navarro. Rosario Iglesias González. Julio Sagrero Pérez.								
TIPO DE INSULINA			VIALES	PLUMAS	Inicio	Pico máx	Duración	Aspecto
P R A N D I A L	ULTRARRÁPIDAS	FAST ASPART	Fiasp®	Fiasp FlexTouch®	5-10 min			
		ASPART	NovoRapid®	NovoRapid Flexpen®				
		GLULISINA	Apidra®	Apidra Solostar®				
		LISPRO	100	Humalog®	10-15 min	1-2 h	2-4 h	Claro
			200	Humalog Junior KwikPen®				
			(No disponible)	Humalog KwikPen® 200				
B A S A L	RÁPIDAS		Actrapid® Humulina Regular®	Actrapid Innolet®	30 min	2 – 4 h	5-8 h	Claro
	INTERMEDIAS	NPH	Insulatard® Humulina NPH®	Insulatard FlexPen® Humulina NPH KwikPen®	2 h	4 – 8 h	12 h	Turbio
	PROLONGADAS	GLARGINA	100	Lantus®	1-2 h	Sin pico	20-24 h	Claro
			100	(No disponible)	Abasaglar KwikPen®	1-2 h	Sin pico	20-24 h
			100	(No disponible)	Semglee®	1-2 h	Sin pico	20-24 h
			300	(No disponible)	Toujeo Solostar®	3-4 h	Sin pico	24-36 h
				Toujeo DoubleStar®				
		DETEMIR		(No disponible)	Levemir Flexpen® Levemir Innolet®	1-2 h	Sin pico	12-18 h
		DEGLUDEC		(No disponible)	Tresiba FlexTouch® 100 Tresiba FlexTouch® 200	1-2 h	Sin pico	24-42 h
M E Z C L A S	Con insulina humana	RÁPIDA + NPH		Mixtard 30® Humulina 30:70®	Mixtard 30 Innolet® Humulina 30:70 KwikPen®	30 min	Doble	12 h
	Con análogos de insulina	ASPART + NPA			NovoMix 30 Flexpen® NovoMix 50 Flexpen® NovoMix 70 Flexpen®	10-15 min	Doble	12 h
		LISPRO + NPL			Humalog Mix 25 KwikPen® Humalog Mix 50 KwikPen®	10-15 min	Doble	12 h

Figura G.4: Principales insulinas comercializadas en España (noviembre 2022), con tiempos de inicio, pico máximo y duración de acción. Fuente: redGDPS [Mora Navarro et al. \(2022\)](#).

Rangos de búsqueda de hiperparámetros, valores obtenidos y justificación

ARIMAX

La búsqueda de hiperparámetros para ARIMAX se realizó mediante `grid_search_stats` de `skforecast` ([Amat Rodrigo and Escobar Ortiz, 2024](#)) sobre un conjunto de 30 combinaciones de órdenes (p, d, q) basadas en los valores utilizados en ([Prendin et al., 2022](#)), cubriendo los siguientes casos:

- Modelos AR puros ($q=0$) con y sin diferenciación ($d=0$ y $d=1$), para órdenes $p=1, 2, 3$.
- Modelos MA puros ($p=0$) con y sin diferenciación, para órdenes $q=1, 2, 3$.
- Modelos ARMA/ARIMA combinados para $p=1, 2, 3$ y $q=1, 2, 3$, con $d=0$ y $d=1$.

Se descartó la búsqueda de componente estacional dado su alto coste computacional.

El orden óptimo resultante fue ($p=2$, $d=0$, $q=3$), cuyo significado es el siguiente:

- **$p=2$ (orden autorregresivo):** el modelo utiliza los dos valores pasados más recientes de la glucemia para predecir el valor futuro. Un orden $p=2$ captura tanto el nivel actual como la velocidad de cambio de la glucemia, sin incorporar historia más lejana que podría introducir ruido.
- **$d=0$ (grado de diferenciación):** la serie glucémica no requiere diferenciación para ser estacionaria en el corto plazo. Esto indica que la media y la varianza de la serie no presentan tendencias sistemáticas en la ventana temporal analizada, lo que es esperable en series glucémicas simuladas con patrones regulares y sin derivas prolongadas.
- **$q=3$ (orden de media móvil):** el modelo incorpora los errores de predicción de los tres pasos anteriores (15 minutos) para corregir la predicción actual. Un orden $q=3$ mayor que $p=2$ sugiere que el modelo se apoya más en la corrección de errores pasados que en los valores observados directamente, lo que es coherente con la presencia de perturbaciones exógenas de corta duración —especialmente los picos postprandiales— cuyo efecto residual persiste durante varios pasos temporales y que el componente MA es capaz de absorber.

En conjunto, el orden (2,0,3) refleja un modelo que captura la tendencia glucémica reciente mediante la componente AR y suaviza las perturbaciones de corta duración mediante la componente MA, sin necesidad de diferenciación.

XGBoost

La búsqueda de hiperparámetros para XGBoost se realizó mediante optimización bayesiana con `OneStepAheadFold` ([Amat Rodrigo and Escobar Ortiz, 2024](#)). La Tabla G.4 recoge los rangos de búsqueda y la justificación de cada hiperparámetro:

Tabla G.4: Espacio de búsqueda de hiperparámetros para XGBoost y justificación de los rangos.

Hiperparámetro	Rango	Tipo	Justificación
<code>lags</code>	{3, 6, 12, 24, 36}	Categorico	Equivalen a 15, 30, 60, 120 y 180 min de historia glucémica.
<code>n_estimators</code>	[50, 500]	Entero	Número de árboles del ensemble; valores bajos pueden producir underfitting y valores altos overfitting
<code>max_depth</code>	[3, 10]	Entero	Profundidad máxima de cada árbol; controla la complejidad del modelo y el riesgo de overfitting
<code>learning_rate</code>	[0,01, 0,3]	Real (log)	Tasa de aprendizaje; escala logarítmica para explorar mejor los valores bajos, que producen modelos más robustos
<code>subsample</code>	[0,6, 1,0]	Real	Fracción de muestras usadas en cada árbol; valores menores a 1 introducen aleatoriedad y reducen el overfitting
<code>colsample_bytree</code>	[0,6, 1,0]	Real	Fracción de características usadas en cada árbol; efecto similar a <code>subsample</code> sobre las variables
<code>min_child_weight</code>	[1, 20]	Entero	Peso mínimo de las hojas del árbol; valores altos producen modelos más conservadores
<code>reg_alpha</code>	[1e-4, 10]	Real (log)	Regularización L1; penaliza la magnitud de los pesos; escala logarítmica para explorar un rango amplio
<code>reg_lambda</code>	[1e-4, 10]	Real (log)	Regularización L2; penaliza el cuadrado de los pesos; actúa conjuntamente con <code>reg_alpha</code>

Los valores óptimos obtenidos (recogidos en la Tabla G.5) muestran un modelo con 301 árboles de profundidad 9, una tasa de aprendizaje moderada-baja (0,040) y valores de submuestreo próximos a 1 (0,981 y

0,962), lo que indica que el modelo aprovecha casi la totalidad de los datos disponibles en cada árbol. Los valores de regularización obtenidos son muy bajos ($\text{reg_alpha} = 0,0043$; $\text{reg_lambda} = 0,0012$), sugiriendo que las series simuladas no requieren una regularización agresiva. La selección de únicamente 3 lags (equivalentes a 15 minutos de historia glucémica) es coherente con la alta regularidad de las series simuladas, en las que la glucemia reciente es suficiente para predecir el valor futuro con precisión.

Tabla G.5: Hiperparámetros óptimos de XGBoost, comunes a los horizontes de 15 y 30 minutos.

Hiperparámetro	Valor
lags	[1, 2, 3]
n_estimators	301
max_depth	9
learning_rate	0,0400
subsample	0,9814
colsample_bytree	0,9618
min_child_weight	1
reg_alpha	0,0043
reg_lambda	0,0012

G.3. Detalle de resultados

Esta sección recoge las figuras y tablas complementarias a los resultados presentados en el Capítulo 5, organizadas por tipo de análisis.

Distribución de TIR por paciente y escenario

Las figuras [G.5](#) a [G.10](#) muestran la distribución del tiempo en rango (TIR) de los pacientes virtuales para cada uno de los seis escenarios experimentales. Cabe destacar la presencia de pacientes con TIR del 0 %, cuyas series glucémicas se encuentran sistemáticamente por encima del rango normoglucémico (>180 mg/dL) con perfiles regulares pero desplazados hacia la hiperglucemia, lo que refleja una característica del simulador y no un perfil clínico real (véase apartado 6.4).




Figura G.5: Distribución de TIR, TAR y TBR por paciente — Escenario E1 ($HC^- E_{j0} E_{r0}$).




Figura G.6: Distribución de TIR, TAR y TBR por paciente — Escenario E2 ($HC^+ E_{j0} E_{r0}$).




Figura G.7: Distribución de TIR, TAR y TBR por paciente — Escenario E3 ($HC^- Ej^+ Er_0$).




Figura G.8: Distribución de TIR, TAR y TBR por paciente — Escenario E4 ($HC^- Ej_0 Er^+$).




Figura G.9: Distribución de TIR, TAR y TBR por paciente — Escenario E5 (HC^+ Ej_0 Er^+).




Figura G.10: Distribución de TIR, TAR y TBR por paciente — Escenario E6 (HC^- Ej^+ Er^+).

Distribución detallada del error por paciente

Los boxplots de las figuras G.11 y G.12 muestran la distribución completa del MAE y el RMSE sobre los 20 pacientes virtuales para cada escenario y horizonte de predicción, incluyendo las observaciones individuales. Estas

figuras complementan las gráficas de barras del Capítulo 5 al mostrar la dispersión interpaciente y la presencia de valores atípicos.




Figura G.11: Distribución del Error Absoluto Medio (MAE) por escenario. Izda.: horizonte 15 minutos. Dcha.: horizonte 30 minutos




Figura G.12: Distribución de la Raíz Error Cuadrático Medio (RMSE) por escenario. Izda.: horizonte 15 minutos. Dcha.: horizonte 30 minutos

Clarke Error Grid

La figura G.13 muestra la distribución de predicciones en las zonas de la Clarke Error Grid para el horizonte de 30 minutos. El resultado es idéntico al presentado en el Capítulo 5 para el horizonte de 15 minutos: el 100 % de las predicciones se clasifican en zona A en todos los escenarios y modelos.




Figura G.13: Distribución de las predicciones según la Clarke Error Grid (CEG) por escenario.

Correlación Spearman entre error predictivo y TIR por escenario

Las figuras G.14, G.15, G.16 y G.17 muestran la correlación de Spearman entre el error predictivo de cada paciente y su TIR, desglosada por escenario y modelo para cada horizonte de predicción. Estos resultados complementan los valores agregados presentados en el apartado 5.4 del Capítulo 5.

Estudio experimental




Figura G.14: Correlación de Spearman entre Error Absoluto Medio (MAE) y Tiempo en rango (TIR). Horizonte 15 minutos. Cada punto representa la métrica de error de un paciente.




Figura G.15: Correlación de Spearman entre Error Absoluto Medio (MAE) y Tiempo en rango (TIR). Horizonte 30 minutos. Cada punto representa la métrica de error de un paciente.

Estudio experimental




Figura G.16: Correlación de Spearman entre la Raíz del Error Cuadrático Medio (RMSE) y Tiempo en rango (TIR). Horizonte 15 minutos. Cada punto representa la métrica de error de un paciente.




Figura G.17: Correlación de Spearman entre la Raíz del Error Cuadrático Medio (RMSE) y Tiempo en rango (TIR). Horizonte 30 minutos. Cada punto representa la métrica de error de un paciente.

Estudio experimental

Las tablas G.18 y G.19 recogen los coeficientes de correlación de Spearman y sus p-valores para cada combinación de escenario, modelo y horizonte.

Simulación	XGBoost 15 min	ARIMAX 15 min	XGBoost 30 min	ARIMAX 30 min
E1 HC ⁻ Ej ₀ Err ₀	r=-0.76 p<0.001 *	r=-0.12 p=0.613	r=-0.76 p<0.001 *	r=0.01 p=0.952
E2 HC ⁺ Ej ₀ Err ₀	r=-0.76 p<0.001 *	r=-0.06 p=0.796	r=-0.75 p<0.001 *	r=-0.04 p=0.858
E3 HC ⁻ Ej ⁺ Err ₀	r=-0.81 p<0.001 *	r=-0.09 p=0.696	r=-0.82 p<0.001 *	r=0.06 p=0.796
E4 HC ⁻ Ej ₀ Err ⁺	r=-0.80 p<0.001 *	r=-0.19 p=0.410	r=-0.78 p<0.001 *	r=-0.08 p=0.743
E5 HC ⁺ Ej ₀ Err ⁺	r=-0.80 p<0.001 *	r=-0.48 p=0.031 *	r=-0.80 p<0.001 *	r=-0.41 p=0.076
E6 HC ⁻ Ej ⁺ Err ⁺	r=-0.78 p<0.001 *	r=-0.07 p=0.757	r=-0.76 p<0.001 *	r=-0.10 p=0.679

Figura G.18: Correlaciones de Spearman entre Error Absoluto Medio (MAE) y Tiempo en rango (TIR) por escenario, modelo y horizonte. Verde: correlación negativa significativa Rojo: correlación positiva significativa p<0.05

Simulación	XGBoost 15 min	ARIMAX 15 min	XGBoost 30 min	ARIMAX 30 min
E1 HC ⁻ Ej ₀ Err ₀	r=-0.68 p=0.001 *	r=-0.02 p=0.937	r=-0.69 p<0.001 *	r=0.19 p=0.429
E2 HC ⁺ Ej ₀ Err ₀	r=-0.73 p<0.001 *	r=-0.02 p=0.925	r=-0.69 p<0.001 *	r=-0.05 p=0.830
E3 HC ⁻ Ej ⁺ Err ₀	r=-0.77 p<0.001 *	r=0.17 p=0.466	r=-0.80 p<0.001 *	r=0.03 p=0.885
E4 HC ⁻ Ej ₀ Err ⁺	r=-0.75 p<0.001 *	r=-0.10 p=0.684	r=-0.76 p<0.001 *	r=-0.04 p=0.853
E5 HC ⁺ Ej ₀ Err ⁺	r=-0.69 p<0.001 *	r=-0.31 p=0.179	r=-0.63 p=0.003 *	r=-0.28 p=0.235
E6 HC ⁻ Ej ⁺ Err ⁺	r=-0.65 p=0.002 *	r=0.13 p=0.589	r=-0.60 p=0.006 *	r=0.10 p=0.677

Figura G.19: Correlaciones de Spearman entre la Raíz del Error Cuadrático Medio (RMSE) y Tiempo en rango (TIR) por escenario, modelo y horizonte. Verde: correlación negativa significativa Rojo: correlación positiva significativa p<0.05

Resultados del test de Wilcoxon

Las tablas G.20 y G.21 recogen los resultados del test de Wilcoxon inter-simulación, que evalúa el efecto de cada factor experimental sobre el rendimiento predictivo dentro de cada modelo. Las tablas G.22 y G.23 recogen los resultados del test inter-modelo, que compara el rendimiento de ARIMAX y XGBoost en cada escenario.

Par	Factor	W XGB 15min	p-valor XGB 15min	W ARX 15min	p-valor ARX 15min	W XGB 30min	p-valor XGB 30min	W ARX 30min	p-valor ARX 30min
E1 vs E2	Variabilidad HC	0	0.0000	83	0.4304	0	0.0000	86	0.4980
E1 vs E3	Ejercicio	63	0.1231	96	0.7562	58	0.0826	103	0.9563
E1 vs E4	Error insulina	0	0.0000	94	0.7012	0	0.0000	104	0.9854
E2 vs E5	Error insulina (HC var)	12	0.0001	83	0.4304	20	0.0007	85	0.4749
E3 vs E6	Error insulina (ej.)	4	0.0000	101	0.8983	7	0.0000	93	0.6742

Figura G.20: Test de Wilcoxon inter-simulación — MAE.

Par	Factor	W XGB 15min	p-valor XGB 15min	W ARX 15min	p-valor ARX 15min	W XGB 30min	p-valor XGB 30min	W ARX 30min	p-valor ARX 30min
E1 vs E2	Variabilidad HC	7	0.0000	83	0.4304	11	0.0001	87	0.5217
E1 vs E3	Ejercicio	65	0.1429	79	0.3488	76	0.2943	95	0.7285
E1 vs E4	Error insulina	9	0.0001	96	0.7562	15	0.0003	88	0.5459
E2 vs E5	Error insulina (HC var)	31	0.0042	81	0.3884	50	0.0400	80	0.3683
E3 vs E6	Error insulina (ej.)	24	0.0014	92	0.6477	21	0.0009	89	0.5706

Figura G.21: Test de Wilcoxon inter-simulación — RMSE.

Simulación	Media XGB 15 min	Media ARX 15 min	W 15 min	p-valor 15 min	Media XGB 30 min	Media ARX 30 min	W 30 min	p-valor 30 min
E1 HC ⁻ E _{ij} Err ₀	0.1205	0.2486	0	0.0000	0.1261	0.2492	0	0.0000
E2 HC ⁺ E _{ij} Err ₀	0.1537	0.2496	8	0.0000	0.1665	0.2504	16	0.0003
E3 HC ⁻ E _j ⁺ Err ₀	0.1270	0.2490	0	0.0000	0.1329	0.2494	0	0.0000
E4 HC ⁻ E _{ij} Err ₊	0.1746	0.2484	14	0.0002	0.1884	0.2489	31	0.0042
E5 HC ⁺ E _{ij} Err ₊	0.1952	0.2511	32	0.0049	0.2152	0.2527	58	0.0826
E6 HC ⁻ E _j ⁺ Err ₊	0.1936	0.2491	40	0.0136	0.2161	0.2497	61	0.1054

Figura G.22: Test de Wilcoxon inter-modelo — MAE.

Simulación	Media XGB 15 min	Media ARX 15 min	W 15 min	p-valor 15 min	Media XGB 30 min	Media ARX 30 min	W 30 min	p-valor 30 min
E1 HC ⁻ E ₀ Err ₀	0.2711	0.2896	54	0.0583	0.2845	0.2893	86	0.4980
E2 HC ⁺ E ₀ Err ₀	0.3311	0.2893	87	0.5217	0.3799	0.2896	48	0.0328
E3 HC ⁻ E ₁ ⁺ Err ₀	0.2984	0.3001	104	0.9854	0.3131	0.2968	87	0.5217
E4 HC ⁻ E ₁ ⁺ Err ₁ ⁺	0.3443	0.2878	47	0.0296	0.3865	0.2879	39	0.0121
E5 HC ⁺ E ₀ Err ₁ ⁺	0.4141	0.3075	27	0.0023	0.4983	0.3158	15	0.0003
E6 HC ⁻ E ₁ ⁺ Err ₁ ⁺	0.4573	0.2911	45	0.0240	0.5472	0.2905	33	0.0056

Figura G.23: Test de Wilcoxon inter-modelo — RMSE.

Importancia de características — paciente de referencia

Las Tabla G.6 y Tabla G.7 muestran la importancia de las 10 principales características de entrada para cada modelo, calculada sobre el paciente de referencia (paciente 1, escenario E3). Dado que el análisis de importancia no se integró en el pipeline de backtesting completo (véase apartado 6.6), estos resultados son únicamente ilustrativos y no representan el comportamiento promedio sobre toda la cohorte.

Tabla G.6: Importancia de las 10 principales variables para XGBoost

feature	importance
glu_mmol	0.983555
lag_1	0.011125
snack_carb_-40m	0.000566
lag_3	0.000359
meal_carb_-80m	0.000291
meal_carb_-100m	0.000280
meal_carb_-60m	0.000271
meal_carb_-120m	0.000218
running_speed_-40m	0.000187
running_speed_-120m	0.000155

Tabla G.7: Importancia de las 10 principales variables para ARIMAX

feature	importance
glu_mmol	0.986074

feature	importance
sigma2	0.004453
ar.L2	0.002733
ma.L2	0.002709
ma.L3	0.001636
running_speed	0.001342
ma.L1	0.000907
ar.L1	0.000841
running_speed_-120m	0.000305
running_speed_-240m	0.000262

Anexo de sostenibilización curricular

H.1. Introducción

La diabetes mellitus tipo 1 afecta a millones de personas en todo el mundo ([Gregory et al., 2022](#)) y su gestión supone una carga continua para el paciente, el sistema sanitario y la sociedad. En este trabajo se aborda el desarrollo de herramientas predictivas que podrían contribuir a mejorar la calidad de vida de las personas con DM1 en régimen MDI, reduciendo el impacto de las excursiones glucémicas y facilitando la toma de decisiones terapéuticas. Esta orientación hacia un problema de salud pública con dimensión social directa constituye el hilo conductor de las reflexiones que se recogen a continuación, organizadas en torno a las competencias transversales para la sostenibilidad definidas por la CRUE ([Conferencia de Rectores de las Universidades Españolas, 2012](#)).

H.2. Contextualización crítica del conocimiento (SOS1)

El trabajo ha requerido integrar conocimientos de ingeniería de la salud, estadística, aprendizaje automático y fisiopatología de la DM1, lo que ha exigido un esfuerzo constante de contextualización crítica: comprender no solo cómo funcionan los modelos predictivos, sino qué significado clínico tienen sus resultados y qué limitaciones impone el contexto real de aplicación. La decisión de trabajar con datos simulados ante la imposibilidad de acceder

a datos reales no fue tomada de forma automática, sino tras evaluar las barreras éticas, burocráticas y legislativas existentes y sus implicaciones sobre la validez externa del estudio. Esta experiencia ha reforzado la comprensión de que la investigación en salud no puede desvincularse del contexto social, regulatorio y clínico en el que se desarrolla.

A escala más amplia, el trabajo se enmarca en la tendencia global hacia la digitalización de la medicina y el uso de la inteligencia artificial en el ámbito clínico, un proceso que plantea desafíos relevantes en términos de equidad en el acceso a la tecnología, privacidad de los datos de salud y responsabilidad en la toma de decisiones automatizadas.

H.3. Utilización sostenible de recursos (SOS2)

El trabajo ha sido desarrollado íntegramente con herramientas de software libre y de código abierto —Python ([Python Software Foundation, 2025](#)), skforecast ([Amat Rodrigo and Escobar Ortiz, 2024](#)), py-mgipsim ([Siket et al., 2025](#))— sin incurrir en costes de licencias. Esta elección no fue únicamente pragmática: el uso de software abierto garantiza la reproducibilidad del estudio, facilita su verificación por parte de la comunidad científica y elimina barreras económicas para futuros investigadores que quieran extender el trabajo.

Desde el punto de vista del consumo de recursos computacionales, el coste energético del backtesting —estimado en un mínimo de 300 horas de uso intensivo de hardware personal— pone de manifiesto que incluso trabajos de escala académica tienen una huella energética no despreciable. Esta toma de conciencia refuerza la importancia de diseñar los experimentos computacionales de forma eficiente desde el inicio, evitando reprocesados innecesarios por una planificación deficiente del pipeline. También es necesario mencionar que el backtesting comprende el entrenamiento y las predicciones del modelo sobre los 30 días, por lo que supone una carga computacional puntual elevada. En un escenario de despliegue clínico, el modelo operaría de forma incremental: el entrenamiento y las predicciones se realizarían de manera secuencial a medida que el paciente fuese generando nuevas lecturas con su dispositivo MCG, distribuyendo la carga computacional a lo largo del tiempo y reduciendo significativamente el coste energético por predicción.

H.4. Participación en procesos comunitarios (SOS3)

El trabajo contribuye a un objetivo de interés colectivo: mejorar las herramientas de soporte a la decisión clínica disponibles para pacientes con DM1 en régimen MDI, modalidad terapéutica mayoritaria.

H.5. Aplicación de principios éticos (SOS4)

La investigación con datos de salud plantea dilemas éticos que han estado presentes a lo largo de todo el desarrollo del trabajo. La decisión de no acceder a datos reales de pacientes sin las garantías éticas y el consentimiento informado adecuados —a pesar de las implicaciones sobre el alcance del estudio— refleja un compromiso con los principios de protección de datos y respeto a la autonomía del paciente, recogidos en el RGPD ([Parlamento Europeo y Consejo de la Unión Europea, 2016](#)) y la LOPDGDD ([Jefatura del Estado, 2018](#)).

El uso de herramientas de inteligencia artificial para la comprensión del código fuente del simulador se ha documentado de forma transparente en el Anexo I. La reproducibilidad del estudio —garantizada mediante el uso de semillas aleatorias fijas, la publicación del código en un repositorio público y la descripción detallada de todos los parámetros experimentales— constituye también una práctica ética fundamental en la investigación computacional.

Apéndice I

Registro de interacciones con sistemas de IA

I.1. Registro de interacciones con sistemas de IA

Interacción 1

- **Herramienta:** Perplexity AI (modo académico)
- **Fecha aproximada:** Marzo 2026
- **Solicitud:** @académico busca casos de utilización del algoritmo XGBoost para la predicción de series temporales con múltiples variables de entrada
- **Resultado:** Descubrimiento de la librería *skforecast* [Amat Rodrigo and Escobar Ortiz \(2024\)](#) como herramienta específica para la predicción de series temporales con modelos de machine learning en Python.
- **Uso en el TFG:** Adopción de *skforecast* como librería principal del pipeline de análisis para la implementación del backtesting y la optimización de hiperparámetros de ambos modelos.

Interacción 2

- **Herramienta:** Perplexity AI (modo académico)

- **Fecha aproximada:** Abril 2026
- **Solicitud:** @académico find scientific papers about the effect of past blood glucose levels, insulin bolus and exercise on future glucose value
- **Resultado:** Identificación de referencias científicas relevantes, entre ellas:
 - *Effects of postprandial exercise on blood glucose levels in adults with type 1 diabetes: a review* [Helleputte et al. \(2023\)](#): resume cómo el ejercicio postprandial modifica la glucemia futura y cómo las reducciones de insulina prandial antes del ejercicio afectan al riesgo de hipoglucemia.
 - *The impact of brief high-intensity exercise on blood glucose levels* (2013): revisa los efectos agudos del ejercicio intenso breve sobre la sensibilidad a la insulina y la glucosa, con efectos que pueden extenderse de 1 a 3 días.
 - *Ejercicio y niveles de glucosa en la diabetes* (ADA, 2024): explica que el ejercicio generalmente reduce la glucemia, aunque ciertos tipos pueden elevarla por activación adrenérgica, con efectos que pueden prolongarse hasta 48 horas.
- **Uso en el TFG:** Base científica para el diseño de las variables de entrada de los modelos, en particular la creación de *lags* y variables acumuladas de insulina, hidratos de carbono y ejercicio en el dataframe de características (véase apartado 4.2 y Anexo G).

Interacción 3

- **Herramienta:** Antigravity [Google Antigravity Team \(2026\)](#)
- **Fecha aproximada:** Febrero – marzo 2026
- **Solicitud:** Análisis del repositorio de código fuente del simulador py-mgipsim para comprender el significado de las variables de salida, el comportamiento interno del modelo fisiológico y los parámetros de los pacientes virtuales, ante la ausencia de documentación oficial detallada. Se realizaron múltiples consultas sobre distintos aspectos del simulador, incluyendo el significado de las variables fisiológicas de salida, los parámetros metabólicos individuales de los pacientes

virtuales, el efecto del ejercicio sobre el modelo y el origen de los episodios críticos observados durante las pruebas previas.

- **Resultado:** Interpretación completa del modelo T1DM.ExtHovorka y sus variables internas. A continuación se incluye un extracto representativo de una de las respuestas generadas, correspondiente al análisis de los parámetros metabólicos de los pacientes virtuales.
- **Uso en el TFG:** Fundamentó las decisiones de diseño experimental descritas en el Anexo G, en particular la fijación de `basal_uncertainty = 0`, la selección de las variables de interés para el pipeline de análisis (véase Anexo F) y la comprensión de la heterogeneidad glucémica entre pacientes discutida en el apartado 6.4 de la memoria.

Extracto de respuesta — Parámetros metabólicos de los pacientes virtuales

PARÁMETROS METABÓLICOS OCULTOS (`model_parameters`)

Sensibilidad y Producción:

- `kb1` Sensibilidad a la insulina respecto al flujo de glucosa.
Un valor muy bajo implica resistencia a la insulina.
- `kb2` Sensibilidad a la insulina respecto al consumo general.
- `kb3` Sensibilidad de la insulina para la supresión hepática.
Un valor bajo significa que el hígado no deja de soltar glucosa incluso con insulina circulante suficiente.
- `EGP0` Producción endógena de glucosa basal (glucosa que suelta el hígado en ayunas de forma natural).

Dinámica y Absorción:

- `tmaxI` Minutos hasta el pico de insulina en sangre.
- `ke` Tasa de eliminación de insulina.
- `tmaxG` Tiempo de vaciado gástrico. Un estómago lento causa hiperglucemias tardías.
- `VG/VI` Volúmenes de distribución de glucosa e insulina.

Impacto del Ejercicio (ExtHovorka):

- `HRrest/HRmax` Frecuencia cardíaca en reposo y máxima.
Determinan la intensidad relativa del ejercicio.
- `a, beta,` Constantes que modifican la sensibilidad a la
- `p3, p4, p5` insulina (`kb1, kb2`) durante el ejercicio muscular.

Tabla resumen - valores clave de los 20 pacientes virtuales:

Paciente	Peso(kg)	Basal/día(U)	Ratio C/I	ISF	kb1	EGPO
Patient_1	79.2	16.9	17.5	27.8	9.11e-05	1.00
Patient_2	74.0	21.9	16.5	28.4	7.41e-05	1.04
Patient_3	70.5	22.2	23.5	59.1	7.60e-05	2.87
Patient_4	73.1	21.8	23.0	58.9	5.38e-05	2.68
Patient_5	64.1	12.0	18.0	74.3	5.31e-05	1.17
Patient_6	65.5	6.5	15.5	66.4	7.17e-05	0.56
Patient_7	61.5	21.3	19.8	64.0	5.31e-05	1.97
Patient_8	67.6	13.4	15.2	42.2	1.16e-04	0.74
Patient_9	66.5	15.1	16.0	55.7	7.81e-05	1.51
Patient_10	71.1	8.4	14.0	41.9	6.04e-05	0.81
Patient_11	84.1	25.3	19.8	32.2	8.27e-05	2.45
Patient_12	82.8	12.6	18.2	43.5	1.03e-04	1.27
Patient_13	70.4	14.0	15.5	66.4	2.58e-05	1.58
Patient_14	77.0	9.0	18.0	37.1	1.14e-04	0.93
Patient_15	84.6	11.7	18.5	53.7	7.80e-05	1.61
Patient_16	66.2	8.7	14.0	55.0	9.04e-05	0.81
Patient_17	81.2	31.4	20.2	51.8	5.10e-05	2.41
Patient_18	88.2	35.2	24.5	40.5	7.03e-05	2.72
Patient_19	73.5	17.5	18.2	37.9	3.75e-05	2.13
Patient_20	75.4	19.6	19.1	44.3	4.56e-05	2.40

Observación: Patient_6 presenta la producción hepática más baja (EGPO = 0.56) y menor requerimiento basal, resultando en un perfil estable. Patient_13 presenta la sensibilidad kb1 más baja de la cohorte (2.58e-05), lo que implica una resistencia a la insulina marcada y mayor dificultad de control glucémico.

Interacción 4

- **Herramienta:** Claude (Anthropic)
- **Fecha aproximada:** Finales abril – mayo 2026
- **Solicitud:** Generación de código Python para la representación gráfica de los resultados, principalmente las gráficas de la Clarke Error Grid (CEG).
- **Resultado:** Código base para la visualización de las zonas de la CEG y la distribución de predicciones.

- **Uso en el TFG:** El código generado requirió modificaciones para ajustar las regiones según la bibliografía, y corregir errores. Se utilizó por la ausencia de librerías disponibles o con los suficientes requisitos (ej: colores de significación)

Interacción 5

- **Herramienta:** Claude (Anthropic)
- **Fecha aproximada:** Mayo – junio 2026
- **Solicitud:** Revisión y ajuste de tono en apartados de la memoria, con el objetivo de mejorar la coherencia y consistencia del texto académico, eliminar incoherencias entre secciones y adecuar el registro a los requisitos formales del documento.
- **Resultado:** Sugerencias de reformulación de párrafos específicos, aplicadas de forma selectiva.

Interacción 6

- **Herramienta:** Gemini (Google, modo razonamiento)
- **Fecha aproximada:** Marzo – junio 2026
- **Solicitud:** Interpretación de errores durante la compilación del documento y resolución de problemas de visualización en el ajuste del código para la correcta renderización de apartados, tablas y figuras.
- **Resultado:** Explicación del origen de los errores de compilación y propuestas de solución para los problemas de formato identificados.

Bibliografía

- Agencia Española de Seguridad Alimentaria y Nutrición (2010). Valores dietéticos de referencia para los hidratos de carbono y la fibra alimentaria. https://www.aesan.gob.es/AECOSAN/web/seguridad_alimentaria/noticias_efsa/2010/valores_nutrientes.htm.
- Amat Rodrigo, J. and Escobar Ortiz, J. (2024). skforecast: time series forecasting with scikit-learn. <https://skforecast.org>. Versión 0.21.0.
- Anaconda, Inc. (2023). Anaconda distribution. <https://www.anaconda.com>.
- Apache Software Foundation (2004). Apache license, version 2.0. <https://www.apache.org/licenses/LICENSE-2.0>.
- Biblioteca Nacional de Medicina de los EE. UU. (2026). Carbohidratos en la dieta. <https://medlineplus.gov/spanish/carbohydrates.html>. MedlinePlus en español. Accedido: 8 de junio de 2026.
- Calvo Ferrer, F., López García, M. J., and Rodríguez Rigual, M. (2004). Diabetes mellitus tipo 1: Tratamiento, seguimiento, complicaciones agudas. In Oyarzabal Irigoyen, M., editor, *Manual de Consenso de la Sociedad Española de Endocrinología Pediátrica*, chapter 23, pages 1–32. Sociedad Española de Endocrinología Pediátrica (SEEP).
- CDCespanol (2024). Tipos de insulina. <https://www.cdc.gov/diabetes/es/about/tipos-de-insulina.html>. Accedido: 1 de junio de 2026.
- Conferencia de Rectores de las Universidades Españolas (2012). Directrices para la introducción de la Sostenibilidad en el Curriculum. Documento aprobado por Asamblea General CRUE. https://www.crue.org/wp-content/uploads/2020/02/Directrices_Sostenibilidad_Crue2012.pdf.

- Free Software Foundation (2007). GNU general public license, version 3. <https://www.gnu.org/licenses/gpl-3.0.html>.
- GitHub, Inc. (2026). Github. <https://github.com>. Plataforma global de alojamiento de código fuente y desarrollo colaborativo. Accedido: 28 de mayo de 2026.
- Google (2026). Google collaboratory. <https://colab.research.google.com/>.
- Google Antigravity Team (2026). Google antigravity: An agent-first development platform. <https://antigravity.google>. Google. Versión 2.0.
- Gregory, G. A., Robinson, T. I. G., Linklater, S. E., Wang, F., Colagiuri, S., de Beaufort, C., Donaghue, K. C., et al. (2022). Global incidence, prevalence, and mortality of type 1 diabetes in 2021 and projections to 2040. *The Lancet Diabetes & Endocrinology*, 10(10):741–760. [https://doi.org/10.1016/S2213-8587\(22\)00218-2](https://doi.org/10.1016/S2213-8587(22)00218-2).
- Grupo de trabajo de la Guía de Práctica Clínica sobre Diabetes Mellitus Tipo 1 (2026). Guía de práctica clínica sobre diabetes mellitus tipo 1. Guías de práctica clínica en el SNS, Ministerio de Sanidad. Servicio de Evaluación del Servicio Canario de Salud.
- Helleputte, S., Yardley, J. E., Scott, S. N., Stautemas, J., Jansseune, L., Marlier, J., De Backer, T., Lapauw, B., and Calders, P. (2023). Effects of postprandial exercise on blood glucose levels in adults with type 1 diabetes: a review. *Diabetologia*, 66(7):1179–1191. <https://doi.org/10.1007/s00125-023-05910-x>.
- Indeed (2026). Salario de Ingeniero biomédico en España. <https://es.indeed.com/career/ingeniero-biom%C3%A9dico/salaries>. Accedido: 5 de junio de 2026.
- Jefatura del Estado (2018). Ley orgánica 3/2018, de 5 de diciembre, de protección de datos personales y garantía de los derechos digitales. Boletín Oficial del Estado. <https://www.boe.es/eli/es/lo/2018/12/05/3>.
- Man, C. D., Micheletto, F., Lv, D., Breton, M., Kovatchev, B., and Cobelli, C. (2014). The UVa/Padova type 1 diabetes simulator: new features. *Journal of Diabetes Science and Technology*, 8(1):26–34. <https://doi.org/10.1177/1932296813514502>.
- Marling, C. and Bunescu, R. (2020). The OhioT1DM dataset for blood glucose level prediction: Update 2020. *CEUR Workshop Proceedings*, 2675:71–74. <https://europepmc.org/articles/PMC7881904>.

- Massachusetts Institute of Technology (1988). The MIT license. <https://opensource.org/licenses/MIT>.
- Ministerio de Sanidad (2022a). Actividad física para la salud y reducción del sedentarismo. recomendaciones para la población. estrategia de promoción de la salud y prevención en el SNS. <https://www.sanidad.gob.es/areas/promocionPrevencion/actividadFisica/home.htm>. Accedido: junio de 2026.
- Ministerio de Sanidad (2022b). Estilos de vida saludable: alimentación saludable. <https://estilosdevidasaludable.sanidad.gob.es>. Accedido: junio de 2026.
- Mora Navarro, G., Iglesias González, R., and Sagrero Pérez, J. (2022). Insulinas comercializadas en España. noviembre 2022. redGDPS — Red de Grupos de Diabetes de la Sociedad Española de Médicos de Atención Primaria. <https://www.redgdps.org/tabla-de-insulinas-comercializadas-muy-practica>.
- Parlamento Europeo y Consejo de la Unión Europea (2016). Reglamento (UE) 2016/679 del parlamento europeo y del consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales. Diario Oficial de la Unión Europea. <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:32016R0679>.
- Prendin, F., Díez, J.-L., Del Favero, S., Sparacino, G., Facchinetti, A., and Bondia, J. (2022). Assessment of Seasonal Stochastic Local Models for Glucose Prediction without Meal Size Information under Free-Living Conditions. *Sensors (Basel, Switzerland)*, 22(22):8682. <https://doi.org/10.3390/s22228682>.
- Python Software Foundation (2025). Python language reference, version 3. <https://www.python.org/>.
- R Core Team (2025). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
- Regents of the University of California (1990). The BSD 3-clause license. <https://opensource.org/licenses/BSD-3-Clause>.
- Rizos, E. C., Markozannes, G., Charitakis, N., Filis, P., Stoimeni, A. E., Nørgaard, K., Ntzani, E. E., and Tsilidis, K. K. (2025). Continuous Glucose Monitoring in Type 1 Diabetes, Type 2 Diabetes, and Diabetes During Pregnancy: A Systematic Review with Meta-Analysis of Randomized Controlled Trials. *Diabetes Technology & Therapeutics*, 27(7):537–552. <https://doi.org/10.1089/dia.2024.0599>.

Bibliografia

- Siket, M., Rashid, M. M., and Cinar, A. (2025). py-mgipsim: An Open-Source Python Library for Simulating Type 1 Diabetes With Diverse Meals and Physical Activities. *Journal of Diabetes Science and Technology*, 19(3):855–856. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11926810/>.
- Taylor, S. J. and Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1):37–45. <https://doi.org/10.1080/00031305.2017.1380080>.