




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Desarrollo de un modelo
predictivo de glucemia a corto
plazo mediante técnicas de
aprendizaje automático en
pacientes con diabetes tipo 1
en terapia MDI**

Documentación Técnica

Presentado por Guillermo de la Fuente Abajo
en Universidad de Burgos

2 de junio de 2026

Tutores: Antonio Jesús Canepa Oneto – Ruth Estefanía
Santos Mazo

Índice general

Índice general	1
Índice de figuras	3
Índice de tablas	5
Apéndice A Plan de Proyecto	7
A.1. Introducción	7
A.2. Metodología de ingeniería del software	8
A.3. Planificación temporal	8
A.4. Planificación económica	9
A.5. Viabilidad legal	12
Apéndice B Manual de especificación de diseño	15
Apéndice C Especificación de Requisitos	17
C.1. Diagrama de casos de uso	17
C.2. Casos de uso	18
C.3. Prototipos de interfaz	20
Apéndice D Documentación de usuario	23
D.1. Requisitos software y hardware para ejecutar el proyecto. . .	23
D.2. Instalación / Puesta en marcha	23
D.3. Manuales y/o Demostraciones prácticas	23
D.4. Requisitos software y hardware	23
D.5. D.2. Instalación y puesta en marcha	25

Apéndice E Manual del desarrollador / programador / investigador.	27
E.1. Estructura de directorios	27
E.2. Compilación, instalación y ejecución del proyecto	27
E.3. Pruebas del sistema	27
E.4. Instrucciones para la modificación o mejora del proyecto. . .	28
E.5. Estructura de directorios	28
E.6. Compilación, instalación y ejecución del proyecto	28
E.7. Pruebas del sistema	28
E.8. Instrucciones para la modificación o mejora del proyecto . .	29
Apéndice F Descripción de adquisición y tratamiento de datos	33
F.1. Descripción formal de los datos	34
F.2. Descripción clínica de los datos	36
Apéndice G Estudio experimental	39
G.1. Cuaderno de trabajo	39
G.2. Configuración y parametrización de las técnicas	42
G.3. Detalle de resultados	48
Apéndice H Anexo de sostenibilización curricular	61
H.1. Introducción	61
Apéndice I Registro de interacciones con sistemas de IA	63
I.1. Registro de interacciones con sistemas de IA	63
Bibliografía	65

Índice de figuras

A.1. Diagrama de Gantt del proyecto.	10
A.2. Fórmula para el cálculo de la amortización durante un periodo determinado.	10
C.1. Diagrama de casos de uso del sistema.	17
C.2. Interfaz gráfica del simulador py-mgipsim	20
C.3. Línea de comandos del simulador py-mgipsim	21
C.4. Visualización de serie glucémica	21
E.1. Diagrama del pipeline de análisis del proyecto.	30
F.1. Flujo de trabajo del simulador py-mgipsim. Fuente: Siket et al. (2025).	36
G.1. Principales insulinas comercializadas en España (noviembre 2022), con tiempos de inicio, pico máximo y duración de acción. Fuente: redGDPS Mora Navarro et al. (2022).	45
G.2. Distribución de TIR, TAR y TBR por paciente — Escenario E1 ($HC^- E_0 Er_0$).	49
G.3. Distribución de TIR, TAR y TBR por paciente — Escenario E2 ($HC^+ E_0 Er_0$).	50
G.4. Distribución de TIR, TAR y TBR por paciente — Escenario E3 ($HC^- E^+ Er_0$).	50
G.5. Distribución de TIR, TAR y TBR por paciente — Escenario E4 ($HC^- E_0 Er^+$).	51
G.6. Distribución de TIR, TAR y TBR por paciente — Escenario E5 ($HC^+ E_0 Er^+$).	51
G.7. Distribución de TIR, TAR y TBR por paciente — Escenario E6 ($HC^- E^+ Er^+$).	52

G.8. Distribución del Error Absoluto Medio (MAE) por escenario. Izda: horizonte 15 minutos. Dcha: horizonte 30 minutos	52
G.9. Distribución del Error Cuadrático Medio (RMSE) por escenario. Izda: horizonte 15 minutos. Dcha: horizonte 30 minutos	53
G.10. Distribución de las predicciones según la Clarke Error Grid (CEG) por escenario.	53
G.11. Correlación de Spearman entre Error Absoluto Medio (MAE) y Tiempo en rango (TIR). Horizonte 15 minutos.	55
G.12. Correlación de Spearman entre Error Absoluto Medio (MAE) y Tiempo en rango (TIR). Horizonte 30 minutos.	56
G.13. Correlación de Spearman entre la Raíz del Error Cuadrático Medio (RMSE) y Tiempo en rango (TIR). Horizonte 15 minutos.	57
G.14. Correlación de Spearman entre la Raíz del Error Cuadrático Medio (RMSE) y Tiempo en rango (TIR). Horizonte 30 minutos.	58

Índice de tablas

A.1. Milestones del proyecto y fechas de entrega.	9
C.1. CU-1 Ejecutar simulación de pacientes virtuales	18
C.2. CU-2 Visualizar series temporales de glucemia	19
C.3. CU-3 Exploración interactiva de datos por selección de paciente y escenario	20
D.1. Requisitos software del proyecto.	24
D.2. Especificaciones hardware del equipo de desarrollo utilizado como referencia.	24
F.1. Resumen estadístico del conjunto de datos mtcars	34
F.2. Variables fisiológicas de salida del simulador py-mgipsim.	34
G.1. Parámetros comunes a todos los escenarios experimentales.	42
G.2. Rangos horarios de inicio de cada ingesta, comunes a todos los escenarios.	43
G.3. Cantidades objetivo de hidratos de carbono por ingesta y varia- bilidad por escenario.	43
G.4. Espacio de búsqueda de hiperparámetros para XGBoost y justifi- cación de los rangos.	47
G.5. Hiperparámetros óptimos de XGBoost, comunes a los horizontes de 15 y 30 minutos.	48

Apéndice A

Plan de Proyecto

A.1. Introducción

Este trabajo aborda el estudio comparativo de modelos predictivos de glucemia en pacientes con DM1 en régimen MDI. El alcance definitivo no estuvo definido desde el inicio: los primeros meses se dedicaron a explorar la viabilidad de acceder a datos reales de pacientes, lo que condicionó el arranque formal del proyecto.

A partir de octubre de 2025 se inició el contacto con la especialidad de endocrinología del Hospital Universitario de Burgos (HUBU) para identificar una cotutora clínica, valorar el tema y explorar el acceso a datos de pacientes reales. La reunión con el servicio hospitalario no pudo celebrarse hasta enero de 2026, momento en el que se constató que el acceso a datos reales presentaba barreras significativas: el proceso requería el consentimiento individualizado de cada paciente, los tiempos de respuesta dependían de las consultas clínicas y pocos pacientes disponían de registros completos de todas las variables de interés. Se exploró también la vía de la asociación local de diabetes (Asociación de Diabéticos de Burgos), con el mismo resultado. Paralelamente, desde enero de 2026 se inició la búsqueda de simuladores y datasets públicos como alternativa.

Una vez definida y aprobada la línea de trabajo, la planificación se formalizó mediante milestones e issues en [GitHub](#)¹ ([GitHub, Inc., 2026](#)), plataforma de gestión utilizada durante todo el desarrollo. No obstante, el trabajo previo de búsqueda de información, contacto con el hospital y

¹url repositorio: <https://github.com/WillyFtAb/TFG-GIS-Predictor-glucosa.git>

exploración de alternativas no quedó reflejado en GitHub ([GitHub, Inc., 2026](#)) al no haberse formalizado aún el proyecto.

A.2. Metodología de ingeniería del software

El trabajo siguió una metodología experimental iterativa, centrada en el análisis de datos y la evaluación de modelos más que en el desarrollo de un sistema software completo. Las fases se organizaron de forma secuencial pero con retroalimentación entre ellas: los resultados del preprocesamiento condicionaron decisiones de diseño experimental, y los resultados de la evaluación determinaron el alcance final de los modelos desarrollados.

La gestión de tareas se realizó mediante issues agrupadas en milestones en GitHub, lo que permitió un seguimiento incremental del progreso. Dado que el trabajo no incluye el desarrollo de un sistema software desplegable, no se aplicó ninguna metodología ágil formal.

Las fases previstas inicialmente que no pudieron completarse fueron: la validación con un segundo simulador o con datos reales, el análisis de significación de variables exógenas y la implementación de Prophet ([Taylor and Letham, 2018](#)) como modelo adicional. Estas quedan identificadas como líneas futuras en el Capítulo 8 de la memoria.

De cara a un desarrollo software futuro basado en este trabajo —por ejemplo, un sistema de soporte a la decisión clínica para pacientes MDI— se recomienda una metodología ágil con sprints cortos (Scrum), dado que el dominio clínico requiere validación iterativa con especialistas y los requisitos pueden evolucionar con los resultados experimentales.

A.3. Planificación temporal

La planificación formal del proyecto se inició en marzo de 2026, una vez definida y aprobada la línea de trabajo. Se organizó en cinco milestones principales más un milestone de seguimiento para reuniones y tareas transversales. La Tabla [A.1](#) resume los hitos y la Figura [A.1](#) muestra su distribución temporal. A continuación se detallan las tareas asociadas a cada milestone.

Fase previa (oct. 2025 – ene. 2026): contacto con el servicio de endocrinología del hospital, búsqueda de cotutora clínica, exploración de acceso a datos reales y búsqueda de simuladores y datasets públicos. Esta fase no está reflejada en GitHub al ser anterior a la formalización del proyecto.

M1 — Obtención y validación de datos (ene. – mar. 2026): configuración del entorno y simuladores, diseño experimental, generación de datasets virtuales y validación clínica de los datos generados con la cotutora especialista.

M2 — Preprocesamiento de los datos (feb. – mar. 2026): implementación de un parser multiformato para la lectura de los archivos del simulador, resampling y ajuste temporal de las series a 5 minutos, y exploración de funciones de estandarización y normalización.

M3 — Desarrollo y entrenamiento del predictor (mar. – abr. 2026): implementación de XGBoost, implementación de ARIMAX, implementación y descarte de Prophet por incompatibilidad con el entorno, y ajuste de hiperparámetros mediante búsqueda bayesiana y grid search.

M4 — Validación clínica y métricas de error (abr. – may. 2026): diseño de la estrategia de evaluación, implementación del backtesting y visualización de resultados mediante métricas de error y Clarke Error Grid.

M5 — Escritura de memoria (may. – jun. 2026): redacción de todos los capítulos de la memoria, elaboración de anexos y revisión final para la entrega.

Seguimiento: reuniones periódicas con tutores a lo largo de todo el desarrollo, envío del compromiso alumno-tutor y redacción de la propuesta de TFG.

Tabla A.1: Milestones del proyecto y fechas de entrega.

Hito	Inicio	Fin previsto
Fase previa	Oct 2025	Ene 2026
M1: Obtención y validación de datos	Ene 2026	Mar 2026
M2: Preprocesamiento de datos	Feb 2026	Mar 2026
M3: Desarrollo y entrenamiento de modelos	Mar 2026	Abr 2026
M4: Validación clínica y métricas de error	Abr 2026	May 2026
M5: Escritura de memoria y entrega final	May 2026	Jun 2026

A.4. Planificación económica

La estimación económica del proyecto contempla los costes directos asociados al trabajo del alumno, la supervisión tutorial y el uso de equipamiento hardware. No se han incurrido costes de licencias de software, dado que




Figura A.1: Diagrama de Gantt del proyecto.

todas las herramientas utilizadas —Python ([Python Software Foundation, 2025](#)), R ([R Core Team, 2025](#)), Quarto ([Allaire, J.J. and Teague, Charles and Xie, Yihui and Dervieux, Christophe, 2022](#)), GitHub([GitHub, Inc., 2026](#)) y Google Colab ([Google, 2026](#)) en su modalidad gratuita— son de acceso libre.

Costes de personal

El coste del trabajo del alumno se estima a partir de las 360 horas previstas, aplicando el Salario Mínimo Interprofesional (SMI) vigente en 2026, fijado en 17.094 € brutos anuales por el Real Decreto 126/2026, lo que equivale a 7,10 €/hora para una jornada de 1.694 horas anuales (?). El coste de supervisión de los tutores se estima a partir de 20 horas totales de tutoría, aplicando una tarifa orientativa de técnico senior:

Concepto	Horas	Coste/hora (€)	Total (€)
Trabajo del alumno	360	7,10	2.556,00
Supervisión tutores	20	50,00	1000,00
Total personal			3.556,00

Costes de hardware

El desarrollo se realizó sobre hardware personal del alumno. La amortización de cada equipo durante el periodo de uso del proyecto se calcula según la expresión recogida en la figura [A.2](#).

$$\text{Amortización del periodo} = \frac{\text{Precio de compra}}{\text{Vida útil en años}} \times \frac{\text{Meses de uso}}{12}$$

Figura A.2: Fórmula para el cálculo de la amortización durante un periodo determinado.

Concepto	Coste (€)	Vida útil (años)	Meses de uso	Amortización (€)
Ordenador personal principal	[COMPLETAR]	5	6	[COMPLETAR]
Ordenador personal secundario	[COMPLETAR]	6	2	[COMPLETAR]
Total hardware				[COMPLETAR]

Consideraciones sobre el uso de hardware personal

El uso de ordenadores personales para el desarrollo del proyecto implica un coste temporal significativo derivado del tiempo de cómputo requerido por el backtesting y la optimización de hiperparámetros. Se estima un mínimo de 300 horas de uso intensivo, incluyendo pruebas y reinicios por fallos. Quien desee replicar el estudio debe contemplar este coste temporal como un factor limitante, especialmente si no se dispone de acceso a infraestructura de cómputo de alto rendimiento.

Costes de infraestructura cloud (referencia)

Aunque no se ha incurrido en coste alguno por uso de Google Colab ([Google, 2026](#)), se incluye como referencia el coste que habría supuesto el uso de la modalidad Colab Pro+ durante el periodo de desarrollo intensivo de modelos (aproximadamente 3 meses), a un precio de 49,99 \$/mes ([Google, 2026](#)):

Concepto	Coste mensual	Meses	Total
Google Colab Pro+	49,99 \$	3	149,97 \$

Resumen económico

Concepto	Total (€)
Personal	3.156,00
Hardware (amortización)	[COMPLETAR]
Software y licencias	0,00
Cloud (referencia, no incurrido)	~138,00
Total del proyecto	[COMPLETAR]

A.5. Viabilidad legal

El presente trabajo no ha requerido la aprobación de la Comisión de Bioética ni de ningún comité ético de investigación, dado que no involucra datos de pacientes reales. Todos los datos utilizados han sido generados mediante el simulador py-mgipsim (Siket et al., 2025), que implementa el modelo UVA/Padova (Man et al., 2014) sobre una cohorte de pacientes virtuales. Al tratarse exclusivamente de datos sintéticos, el trabajo queda fuera del ámbito de aplicación de la normativa de protección de datos de carácter personal.

Reglamento General de Protección de Datos (RGPD)

El Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos (Parlamento Europeo y Consejo de la Unión Europea, 2016), establece el marco normativo europeo en materia de privacidad. Su ámbito de aplicación material comprende el tratamiento total o parcialmente automatizado de datos personales, así como el tratamiento no automatizado de datos personales contenidos o destinados a ser incluidos en un fichero. Los datos de salud se clasifican como categoría especial de datos, cuyo tratamiento está prohibido con carácter general, salvo en supuestos tasados como el consentimiento explícito del interesado, la protección de intereses vitales o el interés público en el ámbito de la salud pública. Dado que el

presente trabajo no trata datos personales de ningún paciente real, el RGPD no resulta de aplicación.

Ley Orgánica 3/2018 de Protección de Datos Personales

La Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales (LOPDGDD) ([Jefatura del Estado, 2018](#)) adapta el RGPD al ordenamiento jurídico español y establece garantías adicionales para el tratamiento de datos sensibles. En materia de investigación sanitaria, la disposición adicional decimoséptima de la LOPDGDD introduce previsiones encaminadas a garantizar el adecuado desarrollo de la investigación en materia de salud, ponderando los beneficios que esta aporta a la sociedad con las debidas garantías del derecho fundamental a la protección de datos. Al no existir tratamiento de datos de pacientes reales en este trabajo, tampoco resulta de aplicación esta norma.

Licencias de software

Las herramientas de software utilizadas son de código abierto o de uso libre, sin restricciones de licencia que limiten su uso académico. El simulador py-mgipsim ([Siket et al., 2025](#)) se distribuye bajo licencia MIT ([Massachusetts Institute of Technology, 1988](#)), que permite su uso, modificación y distribución sin restricciones. Las librerías de Python ([Python Software Foundation, 2025](#)) y R ([R Core Team, 2025](#)) empleadas se distribuyen bajo licencias BSD ([Regents of the University of California, 1990](#)), Apache 2.0 ([Apache Software Foundation, 2004](#)) o GPL ([Free Software Foundation, 2007](#)), todas compatibles con el uso académico y la reproducibilidad del estudio.

Apéndice B

Manual de especificación de diseño

El presente trabajo no incluye desarrollo de hardware ni de un sistema software desplegable, por lo que los apartados de planos técnicos y diseño arquitectónico no resultan de aplicación.

Especificación de Requisitos

C.1. Diagrama de casos de uso

El trabajo no desarrolla un sistema software con interfaz de usuario final, por lo que el diagrama de casos de uso (Figura C.1) se limita a las interacciones del investigador/alumno con las herramientas utilizadas durante el desarrollo. Se identifican tres casos de uso principales:

- **CU-1:** Ejecutar simulación de pacientes virtuales.
- **CU-2:** Visualizar series temporales de glucemia generadas.
- **CU-3:** Exploración interactiva de datos por selección de paciente y escenario.




Figura C.1: Diagrama de casos de uso del sistema.

C.2. Casos de uso

CU-1	Ejecutar simulación de pacientes virtuales
Versión	1.0
Autor	Alumno
Descripción	El investigador ejecuta el simulador py-mgipsim para generar series temporales de glucemia bajo un escenario experimental definido.
Precondición	Python 3.12 instalado y dependencias del simulador instaladas mediante <i>pip install -r requirements.txt</i>
Acciones	El investigador selecciona la modalidad de ejecución (GUI o CLI). - Modalidad GUI: ejecutar <code>streamlit run interface_gui.py</code> en terminal, configurar los parámetros del escenario mediante la interfaz web y lanzar la simulación. - Modalidad CLI interactiva: ejecutar <code>interface_cmd.py</code>, cargar un escenario predefinido con <code>load -sn <nombre_escenario></code> y ejecutar <code>simulate</code>. - Modalidad CLI comando único: ejecutar <code>interface_cli.py [OPTIONS]</code> con los parámetros definidos en línea de comandos.
Postcondición	Los resultados se almacenan en <code>./SimulationResults/<carpetacondatettime>/. </code>
Excepciones	Versión de Python incompatible; dependencias no instaladas.
Importancia	Alta

Tabla C.1: CU-1 Ejecutar simulación de pacientes virtuales

CU-1	Ejecutar simulación de pacientes virtuales
Versión	1.0
Autor	Alumno
Descripción	El investigador ejecuta una función de visualización sobre los datos generados por el simulador para inspeccionar la serie glucémica de los paciente en un escenario determinado.
Precondición	Datos del simulador disponibles; entorno Python con matplotlib activo.
Acciones	1. El investigador abre el notebook de visualización. 2. Especifica el número de escenario y el identificador de paciente. 3. Ejecuta la función de visualización. 4. Se generan las gráfica con la serie temporal de glucemia de los paciente.
Postcondición	La gráfica se muestra en pantalla y puede exportarse como imagen
Excepciones	Fichero de datos no encontrado
Importancia	Media

Tabla C.2: CU-2 Visualizar series temporales de glucemia

CU-1	Exploración interactiva de datos por selección de paciente y escenario
Versión	1.0
Autor	Alumno
Descripción	El alumno selecciona por teclado el escenario y el paciente de interés para obtener una visualización directa de la serie glucémica, sin necesidad de modificar el notebook.
Precondición	Datos del simulador disponibles; entorno Python con matplotlib activo.
Acciones	1. El investigador ejecuta la función interactiva. 2. El sistema solicita por teclado el número de escenario (1–6) y el identificador de paciente (0–19). 3. El sistema valida la entrada. 4. Se genera y muestra la gráfica correspondiente.
Postcondición	La gráfica se muestra en pantalla.
Excepciones	Entrada no válida; datos del escenario no disponibles.
Importancia	Baja

Tabla C.3: CU-3 Exploración interactiva de datos por selección de paciente y escenario

C.3. Prototipos de interfaz

Las siguientes capturas muestran las dos modalidades de interacción con el simulador py-mgipsim ([Siket et al., 2025](#)) disponibles para el investigador.




Figura C.2: Interfaz gráfica del simulador py-mgipsim




Figura C.3: Línea de comandos del simulador py-mgipsim




Figura C.4: Visualización de serie glucémica

Apéndice D

Documentación de usuario

D.1. Requisitos software y hardware para ejecutar el proyecto.

Se detallarán los requisitos mínimos de software y hardware necesarios para ejecutar correctamente el proyecto.

D.2. Instalación / Puesta en marcha

Se describirá el proceso de instalación y ejecución del sistema de forma clara y ordenada, indicando los pasos necesarios para su correcta puesta en funcionamiento.

D.3. Manuales y/o Demostraciones prácticas

Se incluirán instrucciones de uso del sistema y ejemplos prácticos que faciliten su comprensión por parte del usuario final.

D.4. Requisitos software y hardware

Requisitos software

Tabla D.1: Requisitos software del proyecto.

Software	Versión	Descripción
Python	3.12.0	Lenguaje de programación principal
R	4.x	Entorno para la compilación del documento
Quarto	1.x	Sistema de publicación del documento
conda	23.x o superior	Gestor de entornos y dependencias
Git	Reciente	Control de versiones
py-mgipsim	Última versión (descargada en 2026)	Simulador de pacientes virtuales

Las dependencias de Python del proyecto se recogen en el fichero `environment.yml` del repositorio, que permite reproducir el entorno de forma completa. Las versiones exactas de cada librería se especifican en dicho fichero.

Requisitos hardware

El proyecto no presenta requisitos estrictos de almacenamiento: los datos generados por el simulador ocupan menos de 10 GB en disco, una cantidad asumible para el estándar de almacenamiento actual.

El factor limitante es la capacidad de procesamiento y la memoria RAM disponibles. El backtesting con refit sobre 120 series temporales requiere tiempos de cómputo elevados; equipos con procesadores poco potentes o RAM insuficiente pueden hacer inviable la ejecución en tiempos razonables. El trabajo se ha desarrollado sobre un equipo con las siguientes especificaciones, que se proponen como referencia orientativa en la Tabla [D.2](#):

Tabla D.2: Especificaciones hardware del equipo de desarrollo utilizado como referencia.

Componente	Especificación
Procesador	AMD Ryzen 7 5700U (1,80 GHz, 8 núcleos)
RAM	16,0 GB (15,4 GB usable)

Componente	Especificación
Tarjeta gráfica	AMD Radeon Graphics (496 MB)
Sistema operativo	Windows 11

D.5. D.2. Instalación y puesta en marcha

Los pasos siguientes describen el proceso completo para reproducir el entorno y ejecutar el pipeline de análisis. Los pasos 3 y 4 (instalación y uso del simulador) son opcionales si se desea trabajar directamente con los datos ya generados incluidos en el repositorio.

Paso 1 — Clonar el repositorio

```
git clone https://github.com/WillyFtAb/TFG-GIS-Predictor-glucosa.git
cd TFG-GIS-Predictor-glucosa
```

Paso 2 — Crear el entorno conda e instalar dependencias

```
conda env create -f environment.yml
conda activate tfg-glucosa
```

Paso 3 — Instalar el simulador py-mgipsim (opcional)

```
git clone https://github.com/illinoistech-itm/py-mgipsim.git
cd py-mgipsim
pip install -r requirements.txt
```

Paso 4 — Generar nuevos datos con el simulador (opcional)

Una vez instalado el simulador, los datos pueden generarse mediante la interfaz gráfica o la interfaz de línea de comandos, tal como se describe en el Anexo C (CU-1). Los ficheros de resultados deben colocarse en la carpeta `data/` del repositorio para que el pipeline los localice correctamente.

Paso 5 — Visualizar los datos generados

Abrir y ejecutar el notebook de visualización:

```
jupyter notebook notebooks/visualizacion_datos.ipynb
```

Paso 6 — Ejecutar el pipeline de análisis

Abrir y ejecutar el notebook principal con las celdas en orden:

```
jupyter notebook notebooks/pipeline_prediccion.ipynb
```

Uso del notebook de visualización

El notebook de visualización permite inspeccionar las series temporales de glucemia generadas por el simulador. El usuario debe especificar en la celda de parámetros el número de escenario (1–6) y el identificador de paciente (0–19) para obtener la gráfica correspondiente. Las gráficas pueden exportarse como imagen desde la propia interfaz de Jupyter.

Uso del notebook de pipeline

El notebook de pipeline está organizado en secciones secuenciales que corresponden a las fases del análisis: preprocesamiento, ingeniería de características, optimización de hiperparámetros, backtesting y evaluación. Las celdas deben ejecutarse en orden. Los resultados se almacenan automáticamente en la carpeta **resultados/** del repositorio.

Los parámetros configurables por el usuario se encuentran en la celda de configuración al inicio del notebook, e incluyen la selección de escenarios a evaluar, los horizontes de predicción y las rutas de entrada y salida de datos.

Apéndice E

Manual del desarrollador / programador / investigador.

E.1. Estructura de directorios

Descripción de la estructura de carpetas y archivos entregados junto con el proyecto.

E.2. Compilación, instalación y ejecución del proyecto

En caso necesario, se detallarán los pasos técnicos para compilar, instalar y ejecutar el proyecto.

E.3. Pruebas del sistema

Esta sección puede ser opcional.

Se describirán las pruebas realizadas para validar el correcto funcionamiento del sistema, tales como pruebas unitarias, funcionales o validaciones con usuarios.

E.4. Instrucciones para la modificación o mejora del proyecto.

Se proporcionarán indicaciones y recomendaciones para facilitar futuras ampliaciones o mejoras del trabajo realizado.

E.5. Estructura de directorios

[COMPLETAR cuando la estructura del repositorio esté definida]

E.6. Compilación, instalación y ejecución del proyecto

El proceso de instalación y ejecución del entorno se describe en detalle en el Anexo D (apartado D.2). Desde el punto de vista del desarrollador, se señalan los siguientes aspectos técnicos adicionales:

El entorno de desarrollo se gestiona mediante conda. El fichero `environment.yml` del repositorio recoge todas las dependencias con sus versiones exactas, garantizando la reproducibilidad del entorno. Para activar el entorno:

```
conda env create -f environment.yml
conda activate tfg-glucosa
```

Las funciones de preprocesamiento, ingeniería de características y evaluación están implementadas en el módulo `[COMPLETAR].py`, importado por los notebooks principales. Cualquier modificación sobre estas funciones se propagará automáticamente a todos los notebooks que las utilicen, sin necesidad de duplicar código.

E.7. Pruebas del sistema

El proyecto no incorpora un sistema formal de pruebas unitarias. La validación del correcto funcionamiento de las funciones de preprocesamiento, ingeniería de características y backtesting se realizó de forma manual durante el desarrollo, mediante la visualización de las series temporales de glucemia,

la inspección de los dataframes intermedios y la comprobación de coherencia con los ficheros de origen (CSV y JSON) generados por el simulador.

El notebook de visualización (véase Anexo D, apartado D.3) constituye la herramienta principal para verificar visualmente que los datos preprocesados son correctos antes de ejecutar el pipeline de análisis. Las celdas de prueba con datos sintéticos utilizadas durante el desarrollo han sido eliminadas del pipeline final, que contiene únicamente el flujo de trabajo definitivo.

E.8. Instrucciones para la modificación o mejora del proyecto

El diagrama de la Figura E.1 ilustra el flujo completo del pipeline de análisis, desde la generación de datos hasta la evaluación de resultados.

Las principales extensiones y modificaciones que pueden realizarse sobre el proyecto son las siguientes:

Incorporación de nuevos modelos predictivos: para añadir un nuevo modelo al pipeline, es necesario implementar la función de entrenamiento y predicción siguiendo la interfaz de `skforecast` ([Amat Rodrigo and Escobar Ortiz, 2024](#)), definir la estrategia de búsqueda de hiperparámetros y añadir el modelo al bucle de backtesting. El resto del pipeline (preprocesamiento, evaluación y visualización de resultados) es reutilizable sin modificaciones.

Nuevos escenarios experimentales: la generación de nuevos escenarios se realiza directamente desde el simulador `py-mgipsim` ([Siket et al., 2025](#)), modificando los parámetros de variabilidad en la ingesta, ejercicio y error en la dosis. Los nuevos ficheros de salida deben colocarse en la carpeta de datos del repositorio siguiendo la convención de nomenclatura establecida. Las funciones del pipeline deberán ser ajustadas para que los bucles incluyan la búsqueda de los nuevos ficheros.

Validación con datos reales: la sustitución de los datos simulados por datos reales requiere adaptar el parser de lectura al formato del dataset utilizado (por ejemplo, OhioT1DM ([Marling and Bunesu, 2020](#))) y verificar que las variables exógenas disponibles son compatibles con las esperadas por las funciones de ingeniería de características.

Análisis de explicabilidad: la integración de SHAP o de la extracción sistemática de importancia de características puede incorporarse al bucle de backtesting añadiendo una llamada a las funciones correspondientes tras




Figura E.1: Diagrama del pipeline de análisis del proyecto.

cada paso de refit, almacenando los valores de importancia junto con las métricas de evaluación.

Apéndice *F*

Descripción de adquisición y tratamiento de datos

A continuación se muestra un **ejemplo de análisis exploratorio con R** que produce tanto código visible como tabla y figura en el PDF:

```
library(knitr)
library(dplyr)

mtcars |>
  select(mpg, cyl, hp, wt) |>
  summarise(across(everything(),
    list(media = mean, sd = sd, min = min, max = max),
    .names = "{.col}_{.fn}"
  )) |>
  tidyr::pivot_longer(everything(),
    names_to = c("variable", "estadístico"),
    names_sep = "_"
  ) |>
  tidyr::pivot_wider(names_from = estadístico, values_from = value) |>
  mutate(across(where(is.numeric), \(x) round(x, 2))) |>
  kable(booktabs = TRUE, format = "latex",
    col.names = c("Variable", "Media", "SD", "Mín", "Máx"))
```

Tabla F.1: Resumen estadístico del conjunto de datos mtcars

Variable	Media	SD	Mín	Máx
mpg	20.09	6.03	10.40	33.90
cyl	6.19	1.79	4.00	8.00
hp	146.69	68.56	52.00	335.00
wt	3.22	0.98	1.51	5.42

F.1. Descripción formal de los datos

Los datos utilizados en el trabajo son series temporales de variables fisiológicas y de control generadas mediante el simulador py-mgipsim ([Siket et al., 2025](#)), que implementa el modelo metabólico UVA/Padova ([Man et al., 2014](#)) sobre una cohorte de 20 pacientes virtuales con DM1 en régimen MDI.

Para cada paciente y escenario experimental (E1–E6), el simulador genera un fichero CSV con una resolución de muestreo de 1 minuto, que contiene 16 variables fisiológicas y de control (Tabla F.2) y un archivo JSON que registra todos los eventos de entrada al simulador con su marca temporal ([Siket et al., 2025](#)). El flujo de trabajo interno del simulador se ilustra en la Figura F.1. El conjunto de datos bruto comprende 120 series temporales independientes (20 pacientes $\times$ 6 escenarios), cada una con una duración de varios días simulados.

Tabla F.2: Variables fisiológicas de salida del simulador py-mgipsim.

Variable	Unidades	Descripción
S1	mU/min	Compartimento de absorción de insulina subcutánea (1)
S2	S2	Compartimento de absorción de insulina subcutánea (2)
I	I	Concentración de insulina en plasma
x1	x1	Efecto de la insulina sobre la distribución de glucosa
x2	x2	Efecto de la insulina sobre la producción hepática de glucosa

Descripción de adquisición y tratamiento de datos

Variable	Unidades	Descripción
x3	x3	Efecto de la insulina sobre la captación periférica de glucosa
Q1	Q1	Masa de glucosa en el compartimento central
Q2	Q2	Masa de glucosa en el compartimento periférico
IG	mmol/L	Glucosa intersticial (variable de interés principal)
D1Slow	mmol/min	Absorción intestinal lenta de glucosa (compartimento 1)
D2Slow	mmol/min	Absorción intestinal lenta de glucosa (compartimento 2)
D1Fast	mmol/min	Absorción intestinal rápida de glucosa (compartimento 1)
D2Fast	mmol/min	Absorción intestinal rápida de glucosa (compartimento 2)
EEfast	EEfast	Efecto del ejercicio de corta duración sobre la glucosa
EEhighintensity	EEhighintensity	Efecto del ejercicio de alta intensidad
EElongeffect	EElongeffect	Efecto prolongado del ejercicio sobre la sensibilidad a la insulina

La documentación oficial del simulador no describe de forma explícita el significado de cada variable de salida. Para su comprensión se recurrió al análisis del código fuente mediante la herramienta de inteligencia artificial de Antigravity ([Google Antigravity Team, 2026](#)), que permitió interpretar las variables en el contexto del modelo fisiológico subyacente. El detalle del uso de esta herramienta se recoge en el Anexo I.

De entre las 16 variables disponibles en el CSV, se seleccionó para el análisis la glucosa intersticial (IG, convertida de mmol/L a mg/dL). Las




Figura F.1: Flujo de trabajo del simulador py-mgipsim. Fuente: [Siket et al. \(2025\)](#).

variables de control —insulina en bolo, insulina basal, ingesta de comidas y tentempiés, y ejercicio físico— se obtienen del fichero JSON del escenario. Ambas fuentes se integraron en un único dataframe por paciente y escenario antes de aplicar el preprocesamiento. Las series resultantes se remuestrearon a 5 minutos, resolución habitual de los dispositivos MCG comerciales (?), reduciendo el volumen de datos en un factor de 5 sin pérdida de información relevante para el horizonte de predicción analizado.

Para garantizar la coherencia de los datos generados en los escenarios con error en la dosis de insulina (E4, E5 y E6), fue necesario modificar un parámetro interno del simulador que regula el error estocástico en la insulina. Esta modificación no está incluida en el repositorio del proyecto al tratarse de un fichero perteneciente al código fuente del simulador. Quien desee reproducir exactamente estos escenarios deberá aplicar el mismo ajuste sobre su instalación local de py-mgipsim ([Siket et al., 2025](#)). El detalle de las pruebas realizadas hasta obtener datos coherentes se recoge en el Anexo G.

F.2. Descripción clínica de los datos

Las variables seleccionadas para el análisis tienen el siguiente significado clínico en el contexto de la DM1 en régimen MDI:

Glucosa intersticial (IG): es la variable objetivo del estudio. Representa la concentración de glucosa en el líquido intersticial, medida por los dispositivos MCG. Presenta un retardo fisiológico de aproximadamente 5–15 minutos respecto a la glucemia capilar (?). Los valores de referencia clínica son: rango normoglucémico 70–180 mg/dL (TIR), hipoglucemia <70 mg/dL (TBR) e hiperglucemia >180 mg/dL (TAR).

Insulina en bolo: dosis de insulina de acción rápida administrada antes de cada ingesta, calculada en función de los hidratos de carbono consumidos y la glucemia preprandial mediante la ratio insulina/ración (I:R) (??). Constituye la principal perturbación exógena controlable por el paciente y tiene un perfil de acción con inicio a los 15–30 minutos y pico a los 60–90 minutos de su administración.

Insulina basal: dosis de insulina de acción prolongada administrada generalmente una vez al día, cuyo objetivo es mantener la glucemia estable en ausencia de ingesta (??). Su perfil de acción se extiende durante 20–24 horas, lo que justifica su acumulación sobre las últimas 24 horas en la ingeniería de características del modelo.

Hidratos de carbono (comidas y tentempiés): cantidad de hidratos de carbono ingeridos en cada evento de ingesta, expresada en gramos. Constituyen el principal determinante de la excursión glucémica postprandial. Los tentempiés generados por el simulador no conllevan administración de insulina en bolo, a diferencia de las comidas principales ([Siket et al., 2025](#)).

Ejercicio físico: variable de intensidad que indica la presencia y características de la actividad física realizada. El ejercicio modifica la sensibilidad a la insulina de forma aguda y prolongada, pudiendo inducir tanto hipoglucemia durante o tras su práctica como hiperglucemia en ejercicio de alta intensidad (?).

Apéndice *G*

Estudio experimental

G.1. Cuaderno de trabajo

Diseño experimental inicial y pruebas previas

El diseño experimental inicial contemplaba la creación de distintos grupos de pacientes virtuales con perfiles de control glucémico diferenciados —buen control y mal control— mediante la modulación del error estocástico en las unidades de insulina administradas, con el objetivo de estudiar el efecto del perfil del paciente sobre el rendimiento predictivo de los modelos.

Para implementar este diseño se modificaron las variables `basal_uncertainty` y `bolus_uncertainty` del archivo `pymgipsim/Controllers/StochasticOpenLoop/control` del simulador:

```
self.basal_uncertainty = 0
self.bolus_uncertainty = 2.0/20.0
```

Durante las pruebas previas se realizaron múltiples ejecuciones con distintos valores de estas variables. Los resultados iniciales no reflejaban el comportamiento glucémico esperado en un paciente con DM1: las series presentaban periodos prolongados de hipoglucemia severa, con valores continuos e iguales que evidenciaban un estado fisiológico irreal.

La identificación de las causas de este comportamiento no fue inmediata. La escasa documentación oficial del simulador —limitada a una descripción funcional de las interfaces de usuario y sin referencia al significado de las variables internas ni a los parámetros fisiológicos de los pacientes virtuales—

dificultó significativamente la comprensión del sistema. Para interpretar el código fuente y entender el origen de los resultados anómalos fue necesario recurrir al análisis mediante herramientas de inteligencia artificial, como se detalla en el Anexo I.

Una vez analizado el comportamiento del simulador, se identificaron dos limitaciones estructurales que hacían inviable el diseño experimental inicial:

- La cohorte del simulador está fijada en 20 pacientes virtuales cuyos parámetros fisiológicos no pueden modificarse directamente sin crear nuevos perfiles desde cero. La creación de nuevos pacientes requeriría definir manualmente todos los parámetros del modelo metabólico subyacente, una tarea que constituye en sí misma un trabajo de investigación independiente y que excede el alcance del presente TFG.
- El simulador no contempla la ingesta de hidratos de carbono de rescate ante hipoglucemia ni la administración de bolos correctores ante hiperglucemia. La incorporación de estos mecanismos habría implicado modificaciones sustanciales en el código fuente del simulador validado. Esto provoca que, al introducir error estocástico en la insulina, algunos pacientes no sean capaces de estabilizarse dentro del patrón de variables establecido para ellos, generando episodios críticos sostenidos.

Ambas vías fueron descartadas en favor de un diseño experimental que aprovechara las capacidades del simulador dentro de sus limitaciones documentadas, basado en la variabilidad de las condiciones de manejo — variabilidad en la ingesta de HC, presencia de ejercicio y error en el cálculo de la ratio insulina/ración— manteniendo los parámetros fisiológicos de los 20 pacientes virtuales sin modificar, tal como se describe en el Capítulo 4.

[INSERTAR figura con ejemplo de serie glucémica del diseño experimental inicial mostrando episodios críticos]

Desarrollo e implementación de los modelos

El desarrollo de los modelos se abordó de forma secuencial. En primer lugar se implementó XGBoost, dado su carácter no paramétrico y la disponibilidad de herramientas de optimización bayesiana en `skforecast` ([Amat Rodrigo and Escobar Ortiz, 2024](#)). A continuación se implementó ARIMAX, cuya búsqueda de hiperparámetros mediante `grid_search_stats` resultó computacionalmente más costosa que la optimización bayesiana de XGBoost. Se valoró la incorporación de Prophet ([Taylor and Letham, 2018](#)) como

tercer modelo —representando una familia distinta de predictores— pero fue descartado por incompatibilidades entre las versiones de las dependencias del entorno de desarrollo.

La optimización de hiperparámetros de ambos modelos se realizó de forma independiente sobre el paciente 1 del escenario E3. La elección de este paciente de referencia respondió a dos criterios: presentar un perfil glucémico con un tiempo en rango adecuado y una variabilidad glucémica ni excesivamente reducida ni elevada; e incluir la variable de ejercicio físico, garantizando que el modelo pudiera capturar la importancia de dicha variable durante el entrenamiento. Se descartó utilizar el mismo paciente en el escenario E6 —que incluye tanto ejercicio como error en la dosis— para evitar que el modelo se entrenase sobre condiciones perturbadas, prefiriendo entrenar sobre el caso ideal y evaluar posteriormente el efecto de las perturbaciones de forma controlada.

[INSERTAR figura con serie glucémica del paciente de referencia (paciente 1, escenario E3)]

Optimización del tiempo de cómputo

Los tiempos iniciales del backtesting superaban la hora por ejecución, lo que hacía inviable completar las 240 evaluaciones por modelo en un tiempo razonable. Para reducir el tiempo de cómputo se adoptaron las siguientes medidas:

- Configuración del parámetro `n_jobs = -1` en `skforecast` ([Amat Rodrigo and Escobar Ortiz, 2024](#)), permitiendo la paralelización del backtesting sobre todos los núcleos del procesador disponibles.
- Configuración del sistema operativo en modo de alto rendimiento, evitando la limitación de frecuencia del procesador.
- Uso de un dispositivo de ventilación externa para reducir la temperatura del procesador y evitar el throttling térmico.
- Conexión continua a la corriente eléctrica y desactivación del modo de suspensión, que en las primeras ejecuciones pausaba el proceso de forma inesperada.

Con estas medidas se consiguió una reducción aproximada del 30–40 % del tiempo de cómputo. El uso del equipo para otras tareas de forma paralela durante las ejecuciones resultó prácticamente inviable.

Resultados no exitosos

La integración de SHAP para el análisis de explicabilidad y la extracción sistemática de importancia de características durante el backtesting no pudieron completarse por incompatibilidades de dependencias y restricciones de tiempo y capacidad de cómputo respectivamente. Ambas se identifican como líneas futuras en el Capítulo 8.

G.2. Configuración y parametrización de las técnicas

Parámetros comunes a todos los escenarios

Todos los escenarios comparten los siguientes parámetros de simulación:

Tabla G.1: Parámetros comunes a todos los escenarios experimentales.

Parámetro	Valor	Justificación
Días de simulación	30	Máximo permitido por el simulador
Semilla aleatoria	402	Valor por defecto; garantiza reproducibilidad
Modelo metabólico	T1DM.ExtHovorka	Modelo de referencia del simulador
Tiempo de muestreo	1 min	Resolución máxima del simulador
Función renal	1	Estado por defecto; sin deterioro renal
Rango de peso corporal	60–80 kg	Valor por defecto; no modificado para evitar efectos no controlados en los resultados
Exportación a Excel	True	Necesario para extraer los datos de glucemia

Horarios de ingesta

Los rangos horarios de inicio de cada ingesta, expresados en minutos desde el inicio de la simulación, son comunes a todos los escenarios:

Tabla G.2: Rangos horarios de inicio de cada ingesta, comunes a todos los escenarios.

Ingesta	Inicio mínimo (min)	Inicio máximo (min)	Equivalencia horaria
Desayuno	495	525	08:15 – 08:45
Media mañana	645	675	10:45 – 11:15
Comida	855	885	14:15 – 14:45
Merienda	1035	1065	17:15 – 17:45
Cena	1245	1275	20:45 – 21:15

La duración de cada ingesta no fue modificada respecto a los valores por defecto del simulador.

Cantidad de hidratos de carbono

Las cantidades de hidratos de carbono se establecieron a partir de una dieta de referencia de 2.000 kcal diarias para población adulta, valor coherente con las referencias para mujeres adultas españolas (?). La Autoridad Europea de Seguridad Alimentaria (EFSA) establece que los hidratos de carbono deben aportar entre el 45 y el 60 % de la energía total consumida ([Agencia Española de Seguridad Alimentaria y Nutrición, 2010](#)). Se adoptó el límite inferior del rango (45 %), que corresponde a 900 kcal y equivale a 225 g de HC diarios (a razón de 4 kcal/g). La distribución porcentual por ingesta se basó en las recomendaciones del Ministerio de Sanidad ([Ministerio de Sanidad, 2022b](#)):

Tabla G.3: Cantidades objetivo de hidratos de carbono por ingesta y variabilidad por escenario.

Ingesta	Distribución (%)	HC objetivo (g)	Variabilidad E1,E3,E4,E6	Variabilidad E2,E5
Desayuno	20	45,0	±5 %	±25 %
Media mañana	10	22,5	±5 %	±25 %
Comida	35	78,8	±5 %	±25 %
Merienda	10	22,5	±5 %	±25 %
Cena	25	56,2	±5 %	±25 %

	Distribución	HC objetivo	Variabilidad	Variabilidad
Ingesta	(%)	(g)	E1,E3,E4,E6	E2,E5
Total	100	225,0		

Dado que los pacientes virtuales tienen pesos, sexos y niveles de actividad física distintos, y que la talla y la edad no están disponibles en el simulador, no fue posible calcular un requerimiento energético individualizado para cada paciente. La dieta de 2.000 kcal se adoptó como valor de referencia común para toda la cohorte, priorizando la comparabilidad entre escenarios sobre la precisión individual.

Ejercicio físico

Para los escenarios con ejercicio (E3 y E6), la actividad física se configuró como carrera continua diaria de 30 minutos, con inicio entre las 16:00 y las 16:30, y una intensidad de 1,7 a 2,5 m/s (6,1 a 9,0 km/h).

Según las recomendaciones del Ministerio de Sanidad, la actividad física vigorosa —categoría en la que se encuadra correr a esta velocidad en población adulta— produce beneficios adicionales para la salud cuando se superan los 150 minutos semanales, incluyendo fortalecimiento muscular y mayor mejora cardiovascular ([Ministerio de Sanidad, 2022a](#)). Con 30 minutos diarios se alcanzan 210 minutos semanales de actividad vigorosa, dentro del rango de máximo beneficio recomendado. Se eligió esta configuración para representar el caso de mayor impacto fisiológico del ejercicio sobre la glucemia, garantizando que su efecto fuese detectable en el rendimiento de los modelos predictivos.

Para los escenarios sin ejercicio (E1, E2, E4 y E5), la duración e intensidad de la actividad física se establecieron a 0.

Ingeniería de características

La construcción de las variables de entrada de los modelos se basó en los tiempos de acción de los distintos tipos de insulina disponibles ([Mora Navarro et al., 2022](#), [CDCespanol \(2024\)](#)). La figura G.1 recoge las principales insulinas comercializadas en España con sus tiempos de inicio, pico máximo y duración de acción.

Insulinas comercializadas en España. Noviembre 2022								
Autores: Gustavo Mora Navarro. Rosario Iglesias González. Julio Sagrero Pérez.								
TIPO DE INSULINA			VIALES		PLUMAS	Inicio	Pico máx	Duración
								Aspecto
P R A N D I A L	ULTRARRÁPIDAS	FAST ASPART	Fiasp®		Fiasp FlexTouch®	5-10 min		
		ASPART	NovoRapid®		NovoRapid Flexpen®			
		GLULISINA	Apidra®		Apidra Solostar®			
		LISPRO	100	Humalog®	Humalog KwikPen®	10-15 min	1-2 h	2-4 h
			200	(No disponible)	Humalog Junior KwikPen®			
	RÁPIDAS	Actrapid® Humulina Regular®		Actrapid Innolet®		30 min	2 – 4 h	5-8 h
B A S A L	INTERMEDIAS	NPH		Insulatard® Humulina NPH®	Insulatard FlexPen® Humulina NPH KwikPen®	2 h	4 – 8 h	12 h
	PROLONGADAS	GLARGINA	100	Lantus®	Lantus Solostar®	1-2 h	Sin pico	20-24 h
			100 biosimilar	(No disponible)	Abasaglar KwikPen®	1-2 h	Sin pico	20-24 h
			(No disponible)	Semglee®		1-2 h	Sin pico	20-24 h
			300	(No disponible)	Toujeo Solostar® Toujeo DoubleStar®	3-4 h	Sin pico	24-36 h
		DETEMIR		(No disponible)	Levemir Flexpen® Levemir Innolet®	1-2 h	Sin pico	12-18 h
		DEGLUDEC		(No disponible)	Tresiba FlexTouch® 100 Tresiba FlexTouch® 200	1-2 h	Sin pico	24-42 h
M E Z C L A S	Con insulina humana	RÁPIDA + NPH		Mixtard 30® Humulina 30:70®	Mixtard 30 Innolet® Humulina 30:70 KwikPen®	30 min	Doble	12 h
	Con análogos de insulina	ASPART + NPA			NovoMix 30 Flexpen® NovoMix 50 Flexpen® NovoMix 70 Flexpen®	10-15 min	Doble	12 h
		LISPRO + NPL			Humalog Mix 25 KwikPen® Humalog Mix 50 KwikPen®	10-15 min	Doble	12 h

Figura G.1: Principales insulinas comercializadas en España (noviembre 2022), con tiempos de inicio, pico máximo y duración de acción. Fuente: redGDPS [Mora Navarro et al. \(2022\)](#).

Para la insulina en bolo (de acción rápida o ultrarrápida), el pico de efecto se produce entre 1 y 2 horas tras la administración y la duración total es de 2 a 4 horas ([Mora Navarro et al., 2022](#), [CDCespanol \(2024\)](#)). Para los hidratos de carbono, la absorción intestinal y el pico glucémico postprandial se producen en una ventana similar. Sobre esta base, se estableció la generación de variables acumuladas en intervalos de 20 minutos durante las últimas 4 horas (240 minutos) para la insulina en bolo, los hidratos de carbono y el ejercicio físico, capturando así el perfil temporal completo de acción de cada variable sobre la glucemia.

La insulina basal es el único caso especial, se administra a las 00:00 de cada día, y tiene una duración entorano a un día completo. Por este motivo, su acumulación se estableció sobre las últimas 24 horas.

Rangos de búsqueda de hiperparámetros, valores obtenidos y justificación

ARIMAX

La búsqueda de hiperparámetros para ARIMAX se realizó mediante `grid_search_stats` de `skforecast` ([Amat Rodrigo and Escobar Ortiz, 2024](#)) sobre un conjunto de 30 combinaciones de órdenes (p, d, q) basadas en los valores utilizados en ([Prendin et al., 2022](#)), cubriendo los siguientes casos:

- Modelos AR puros ($q=0$) con y sin diferenciación ($d=0$ y $d=1$), para órdenes $p=1, 2, 3$.
- Modelos MA puros ($p=0$) con y sin diferenciación, para órdenes $q=1, 2, 3$.
- Modelos ARMA/ARIMA combinados para $p=1, 2, 3$ y $q=1, 2, 3$, con $d=0$ y $d=1$.

Se descartó la búsqueda de componente estacional dado su alto coste computacional.

El orden óptimo resultante fue $(p=2, d=0, q=3)$, cuyo significado es el siguiente:

- **$p=2$ (orden autorregresivo):** el modelo utiliza los dos valores pasados más recientes de la glucemia para predecir el valor futuro. Un orden $p=2$ captura tanto el nivel actual como la velocidad de cambio de la glucemia, sin incorporar historia más lejana que podría introducir ruido.
- **$d=0$ (grado de diferenciación):** la serie glucémica no requiere diferenciación para ser estacionaria en el corto plazo. Esto indica que la media y la varianza de la serie no presentan tendencias sistemáticas en la ventana temporal analizada, lo que es esperable en series glucémicas simuladas con patrones regulares y sin derivas prolongadas.
- **$q=3$ (orden de media móvil):** el modelo incorpora los errores de predicción de los tres pasos anteriores (15 minutos) para corregir la predicción actual. Un orden $q=3$ mayor que $p=2$ sugiere que el modelo se apoya más en la corrección de errores pasados que en los valores observados directamente, lo que es coherente con la presencia de perturbaciones exógenas de corta duración —especialmente los picos postprandiales— cuyo efecto residual persiste durante varios pasos temporales y que el componente MA es capaz de absorber.

En conjunto, el orden $(2,0,3)$ refleja un modelo que captura la tendencia glucémica reciente mediante la componente AR y suaviza las perturba-

ciones de corta duración mediante la componente MA, sin necesidad de diferenciación.

XGBoost

La búsqueda de hiperparámetros para XGBoost se realizó mediante optimización bayesiana con `OneStepAheadFold` (Amat Rodrigo and Escobar Ortiz, 2024). La Tabla G.4 recoge los rangos de búsqueda y la justificación de cada hiperparámetro:

Tabla G.4: Espacio de búsqueda de hiperparámetros para XGBoost y justificación de los rangos.

Hiperparámetro	Rango	Tipo	Justificación
<code>lags</code>	{3, 6, 12, 24, 36}	Categorico	Equivalen a 15, 30, 60, 120 y 180 min de historia glucémica. Se exploran desde el mínimo equivalente al horizonte de predicción hasta 3 horas de historia
<code>n_estimators</code>	[50, 500]	Entero	Número de árboles del ensemble; valores bajos pueden producir underfitting y valores altos overfitting
<code>max_depth</code>	[3, 10]	Entero	Profundidad máxima de cada árbol; controla la complejidad del modelo y el riesgo de overfitting
<code>learning_rate</code>	[0,01, 0,3]	Real (log)	Tasa de aprendizaje; escala logarítmica para explorar mejor los valores bajos, que producen modelos más robustos
<code>subsample</code>	[0,6, 1,0]	Real	Fracción de muestras usadas en cada árbol; valores menores a 1 introducen aleatoriedad y reducen el overfitting
<code>colsample_bytree</code>	[0,6, 1,0]	Real	Fracción de características usadas en cada árbol; efecto similar a <code>subsample</code> sobre las variables

Estudio experimental

Hiperparámetro	Rango	Tipo	Justificación
<code>min_child_weight</code>	[1, 20]	Entero	Peso mínimo de las hojas del árbol; valores altos producen modelos más conservadores
<code>reg_alpha</code>	[1e-4, 10]	Real (log)	Regularización L1; penaliza la magnitud de los pesos; escala logarítmica para explorar un rango amplio
<code>reg_lambda</code>	[1e-4, 10]	Real (log)	Regularización L2; penaliza el cuadrado de los pesos; actúa conjuntamente con <code>reg_alpha</code>

Los valores óptimos obtenidos (recogidos en la Tabla G.5) muestran un modelo con 301 árboles de profundidad 9, una tasa de aprendizaje moderada-baja (0,040) y valores de submuestreo próximos a 1 (0,981 y 0,962), lo que indica que el modelo aprovecha casi la totalidad de los datos disponibles en cada árbol. Los valores de regularización obtenidos son muy bajos (`reg_alpha` = 0,0043; `reg_lambda` = 0,0012), sugiriendo que las series simuladas no requieren una regularización agresiva. La selección de únicamente 3 lags (equivalentes a 15 minutos de historia glucémica) es coherente con la alta regularidad de las series simuladas, en las que la glucemia reciente es suficiente para predecir el valor futuro con precisión.

Tabla G.5: Hiperparámetros óptimos de XGBoost, comunes a los horizontes de 15 y 30 minutos.

Hiperparámetro	Valor
<code>lags</code>	[1, 2, 3]
<code>n_estimators</code>	301
<code>max_depth</code>	9
<code>learning_rate</code>	0,0400
<code>subsample</code>	0,9814
<code>colsample_bytree</code>	0,9618
<code>min_child_weight</code>	1
<code>reg_alpha</code>	0,0043
<code>reg_lambda</code>	0,0012

G.3. Detalle de resultados

Esta sección recoge las figuras y tablas complementarias a los resultados presentados en el Capítulo 5, organizadas por tipo de análisis.

Distribución de TIR por paciente y escenario

Las figuras G.2 a G.7 muestran la distribución del tiempo en rango (TIR) de los pacientes virtuales para cada uno de los seis escenarios experimentales. Cabe destacar la presencia de pacientes con TIR del 0 %, cuyas series glucémicas se encuentran sistemáticamente por encima del rango normoglucémico (>180 mg/dL) con perfiles regulares pero desplazados hacia la hiperglucemia, lo que refleja una característica del simulador y no un perfil clínico real (véase apartado 6.4).




Figura G.2: Distribución de TIR, TAR y TBR por paciente — Escenario E1 ($HC^- E_0 Er_0$).




Figura G.3: Distribución de TIR, TAR y TBR por paciente — Escenario E2 ($HC^+ E_0 Er_0$).




Figura G.4: Distribución de TIR, TAR y TBR por paciente — Escenario E3 ($HC^- E^+ Er_0$).




Figura G.5: Distribución de TIR, TAR y TBR por paciente — Escenario E4 ($HC^- E_0 Er^+$).




Figura G.6: Distribución de TIR, TAR y TBR por paciente — Escenario E5 ($HC^+ E_0 Er^+$).




Figura G.7: Distribución de TIR, TAR y TBR por paciente — Escenario E6 ($HC^- E^+ Er^+$).

Distribución detallada del error por paciente

Los boxplots de las figuras G.8 y G.9 muestran la distribución completa del MAE y el RMSE sobre los 20 pacientes virtuales para cada escenario y horizonte de predicción, incluyendo las observaciones individuales. Estas figuras complementan las gráficas de barras del Capítulo 5 al mostrar la dispersión interpaciente y la presencia de valores atípicos.




Figura G.8: Distribución del Error Absoluto Medio (MAE) por escenario. Izda: horizonte 15 minutos. Dcha: horizonte 30 minutos




Figura G.9: Distribución del Error Cuadrático Medio (RMSE) por escenario. Izda: horizonte 15 minutos. Dcha: horizonte 30 minutos

Clarke Error Grid

La figura G.10 muestra la distribución de predicciones en las zonas de la Clarke Error Grid para el horizonte de 30 minutos. El resultado es idéntico al presentado en el Capítulo 5 para el horizonte de 15 minutos: el 100 % de las predicciones se clasifican en zona A en todos los escenarios y modelos.




Figura G.10: Distribución de las predicciones según la Clarke Error Grid (CEG) por escenario.

Correlación Spearman entre error predictivo y TIR por escenario

Las figuras G.11, G.12, G.13 y G.14 muestran la correlación de Spearman entre el error predictivo de cada paciente y su TIR, desglosada por escenario

y modelo para cada horizonte de predicción. Estos resultados complementan los valores agregados presentados en el apartado 5.4 del Capítulo 5.




Figura G.11: Correlación de Spearman entre Error Absoluto Medio (MAE) y Tiempo en rango (TIR). Horizonte 15 minutos.

Estudio experimental




Figura G.12: Correlación de Spearman entre Error Absoluto Medio (MAE) y Tiempo en rango (TIR). Horizonte 30 minutos.




Figura G.13: Correlación de Spearman entre la Raíz del Error Cuadrático Medio (RMSE) y Tiempo en rango (TIR). Horizonte 15 minutos.

Estudio experimental




Figura G.14: Correlación de Spearman entre la Raíz del Error Cuadrático Medio (RMSE) y Tiempo en rango (TIR). Horizonte 30 minutos.

Las tablas `?@tbl-spearman-mae` y `?@tbl-spearman-rmse` recogen los coeficientes de correlación de Spearman y sus p-valores para cada combinación de escenario, modelo y horizonte.

`?@tbl-spearman-mae`

`?@tbl-spearman-rmse`

Resultados del test de Wilcoxon

Las tablas `?@tbl-wilcoxon-intersim-mae` y `?@tbl-wilcoxon-intersim-rmse` recogen los resultados del test de Wilcoxon inter-simulación, que evalúa el efecto de cada factor experimental sobre el rendimiento predictivo dentro de cada modelo. Las tablas `?@tbl-wilcoxon-intermodelo-mae` y `?@tbl-wilcoxon-intermodelo-rmse` recogen los resultados del test inter-modelo, que compara el rendimiento de ARIMAX y XGBoost en cada escenario.

`?@tbl-wilcoxon-intersim-mae`

`?@tbl-wilcoxon-intersim-rmse`

`?@tbl-wilcoxon-intermodelo-mae`

`?@tbl-wilcoxon-intermodelo-rmse`

Importancia de características — paciente de referencia

Las tablas `?@tbl-feat-arimax` y `?@tbl-feat-xgb` muestran la importancia de las características de entrada para cada modelo, calculada sobre el paciente de referencia (paciente 1, escenario E3). Dado que el análisis de importancia no se integró en el pipeline de backtesting completo (véase apartado 6.6), estos resultados son únicamente ilustrativos y no representan el comportamiento promedio sobre toda la cohorte.

[INSERTAR ?? — importancia de características ARIMAX, paciente de referencia]

[INSERTAR ?? — importancia de características XGBoost, paciente de referencia]

Apéndice H

Anexo de sostenibilización curricular

H.1. Introducción

Este anexo incluirá una reflexión personal del alumnado sobre los aspectos de la sostenibilidad que se abordan en el trabajo. Se pueden incluir tantas subsecciones como sean necesarias con la intención de explicar las competencias de sostenibilidad adquiridas durante el alumnado y aplicadas al Trabajo de Fin de Grado.

Más información en el documento de la CRUE https://www.crue.org/wp-content/uploads/2020/02/Directrices_Sostenibilidad_Crue2012.pdf.

Este anexo tendrá una extensión comprendida entre 600 y 800 palabras.

Apéndice I

Registro de interacciones con sistemas de IA

I.1. Registro de interacciones con sistemas de IA

Este anexo tiene como objetivo garantizar la transparencia en el uso de herramientas de inteligencia artificial generativa durante la realización del Trabajo de Fin de Grado. En él se deberá incluir un registro ordenado de los *prompts*, solicitudes, o peticiones formuladas por el estudiante en las interacciones con sistemas de IA que hayan sido más significativas en relación al desarrollo del TFG. Asimismo se incluirán bien las respuestas generadas directamente por los sistemas de IA, o bien se reflejará la importancia que ha tenido esa interacción en el desarrollo del trabajo (código, texto, enfoque...) de esas interacciones significativas.

El propósito de este anexo no es penalizar el uso de inteligencia artificial, sino documentarlo de forma clara, permitiendo al tribunal evaluar el alcance, la finalidad y el impacto real de dichas herramientas en el proceso de aprendizaje y en los resultados obtenidos. El uso de IA debe entenderse como una herramienta de apoyo, nunca como un sustituto del razonamiento, la toma de decisiones técnicas o la autoría del trabajo.

Para cada interacción relevante con sistemas de IA, se deberá indicar, al menos, la siguiente información:

- Herramienta o modelo de IA utilizado.
- Fecha aproximada de uso.

- Prompt/petición/solicitud/forma de uso realizada por el estudiante.
- Respuesta completa generada por la IA (opcional)
- Uso posterior de dicha respuesta en el TFG (orientación conceptual, mejora de redacción, generación de ideas, apoyo técnico, generación de código, etc.).

Este anexo podrá estructurarse en forma de tablas o listados numerados, y solo deberá incluir aquellas interacciones que hayan tenido una influencia significativa en el desarrollo del trabajo.

- perplexity
- 10/04
- @académico busca casos de utilización del algoritmo xgboost para la predicción de series temporales con multiples variables de entrada
- Descubrimiento de la librería *Skforecast*.

- perplexity
- 10/04
- @académico find scientific papers about the effect of past blood glucose levels, insulin bolus and exercise on future glucose value

Effects of postprandial exercise on blood glucose levels in adults with type 1 diabetes: a review of the literature (2023). Resume cómo el ejercicio después de comer cambia la glucosa futura y cómo las reducciones de insulina prandial antes del ejercicio modifican el riesgo de hipoglucemia.

The impact of brief high-intensity exercise on blood glucose levels (2013). Revisa estudios sobre ejercicio intenso breve y muestra efectos agudos y también a 1–3 días sobre sensibilidad a la insulina y glucosa.

Ejercicio y niveles de glucosa en la diabetes (ADA, 2024). Explica que el ejercicio suele bajar la glucosa, pero algunos tipos pueden subirla por adrenalina, y que el efecto puede durar horas o incluso hasta 48 horas.

- Utilización para el diseño y creación de *lags* en el dataframe de entrada para los algoritmos y base científica.

Bibliografía

- Agencia Española de Seguridad Alimentaria y Nutrición (2010). Valores dietéticos de referencia para los hidratos de carbono y la fibra alimentaria. Portal web AESAN.
- Allaire, J.J. and Teague, Charles and Xie, Yihui and Dervieux, Christophe (2022). Quarto.
- Amat Rodrigo, J. and Escobar Ortiz, J. (2024). skforecast: time series forecasting with scikit-learn.
- Apache Software Foundation (2004). Apache license, version 2.0.
- CDCespanol (2024). Tipos de insulina.
- Free Software Foundation (2007). GNU general public license, version 3.
- GitHub, Inc. (2026). Github. Plataforma global de alojamiento de código fuente y desarrollo colaborativo.
- Google (2026). Google colabory. <https://colab.research.google.com/>.
- Google Antigravity Team (2026). Google antigravity: An agent-first development platform.
- Jefatura del Estado (2018). Ley orgánica 3/2018, de 5 de diciembre, de protección de datos personales y garantía de los derechos digitales. Boletín Oficial del Estado.
- Man, C. D., Micheletto, F., Lv, D., Breton, M., Kovatchev, B., and Cobelli, C. (2014). The UVa/Padova type 1 diabetes simulator: new features. *Journal of Diabetes Science and Technology*, 8(1):26–34.

- Marling, C. and Bunescu, R. (2020). The ohiot1dm dataset for blood glucose level prediction: Update 2020. *CEUR workshop proceedings.*, 2675:71—74.
- Massachusetts Institute of Technology (1988). The MIT license.
- Ministerio de Sanidad (2022a). Actividad física para la salud y reducción del sedentarismo. recomendaciones para la población. estrategia de promoción de la salud y prevención en el SNS. Ministerio de Sanidad.
- Ministerio de Sanidad (2022b). Estilos de vida saludable: alimentación saludable. Portal web.
- Mora Navarro, G., Iglesias González, R., and Sagrero Pérez, J. (2022). Insulinas comercializadas en España. noviembre 2022. redGDPS — Red de Grupos de Diabetes de la Sociedad Española de Médicos de Atención Primaria.
- Parlamento Europeo y Consejo de la Unión Europea (2016). Reglamento (UE) 2016/679 del parlamento europeo y del consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales. Diario Oficial de la Unión Europea.
- Prendin, F., Díez, J.-L., Del Favero, S., Sparacino, G., Facchinetti, A., and Bondia, J. (2022). Assessment of Seasonal Stochastic Local Models for Glucose Prediction without Meal Size Information under Free-Living Conditions. *Sensors (Basel, Switzerland)*, 22(22):8682.
- Python Software Foundation (2025). Python language reference, version 3.
- R Core Team (2025). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
- Regents of the University of California (1990). The BSD 3-clause license.
- Siket, M., Rashid, M. M., and Cinar, A. (2025). py-mgipsim: An Open-Source Python Library for Simulating Type 1 Diabetes With Diverse Meals and Physical Activities. *Journal of Diabetes Science and Technology*, 19(3):855–856.
- Taylor, S. J. and Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1):37–45.