




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior
Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Desarrollo de un modelo
predictivo de glucemia a corto
plazo mediante técnicas de
aprendizaje automático en
pacientes con diabetes tipo 1
en terapia MDI**

Presentado por Guillermo de la Fuente Abajo
en Universidad de Burgos

25 de mayo de 2026

Tutores: Antonio Jesús Canepa Oneto – Ruth Estefanía
Santos Mazo



UNIVERSIDAD
DE BURGOS

Escuela Politécnica Superior

Grado en Ingeniería de la Salud

D. Antonio Jesús Canepa Oneto, profesor del departamento de Informática.

D. Ruth Estefanía Santos Mazo, profesor/a del departamento de , área de .

Expone/n:

Que el/la alumno/a D. Guillermo de la Fuente Abajo, con DNI 71704960E, ha realizado el Trabajo final de Grado en Ingeniería de la Salud titulado *título del trabajo*.

Y que dicho trabajo ha sido realizado por el/la alumno/a bajo la dirección del/los que suscribe/n.

En Burgos, a 25 de mayo de 2026

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

D. Antonio Jesús Canepa Oneto

D. Ruth Estefanía Santos Mazo

Resumen

En este primer apartado se hace una **breve** presentación del tema que se aborda en el proyecto.

Descriptores

Palabras separadas por comas que identifiquen el contenido del proyecto.

Abstract

A **brief** presentation of the topic addressed in the project.

Keywords

keywords separated by commas.

Índice general

Índice general	iii
Índice de figuras	iv
Índice de tablas	v
Introducción	1
Objetivos	3
Conceptos teóricos	5
Metodología	13
Resultados	17
Discusión	23
Conclusiones	25
7.1. Aspectos relevantes	25
Líneas de trabajo futuras	27
Bibliografía	29

Índice de figuras

5.1. MAE medio por escenario y horizonte de predicción para ARI-MAX y XGBoost.	17
5.2. RMSE medio por escenario y horizonte de predicción para ARI-MAX y XGBoost.	18
5.3. Distribución de predicciones en zonas de la Clarke Error Grid para XGBoost y ARIMAX en el horizonte de 15 minutos, por escenario.	19
5.4. Degradación del MAE al aumentar el horizonte de predicción. Izquierda: valores absolutos por escenario. Derecha: ratio MAE_{30}/MAE_{15} por escenario y modelo.	20
5.5. Degradación del RMSE al aumentar el horizonte de predicción. Izquierda: valores absolutos por escenario. Derecha: ratio $RMSE_{30}/RMSE_{15}$ por escenario y modelo.	20
5.6. Correlación de Spearman entre MAE medio por paciente (promediado sobre los seis escenarios) y TIR, para ambos modelos y horizontes de predicción.	21
5.7. Correlación de Spearman entre RMSE medio por paciente (promediado sobre los seis escenarios) y TIR, para ambos modelos y horizontes de predicción.	21

Índice de tablas

4.1. Definición de los escenarios experimentales.	13
---	----

Introducción

La diabetes mellitus tipo 1 (DM1) es una enfermedad autoinmune crónica caracterizada por la destrucción de las células beta pancreáticas y la consecuente dependencia absoluta de insulina exógena. La prevalencia mundial se estima en 9,5 millones de personas en 2025 ([Ogle et al., 2025](#)), con tendencia ascendente hacia 2040 ([Gregory et al., 2022](#)). En España, la incidencia en menores de 15 años se sitúa en 20,54 casos por cada 100.000 personas-año ([Conde Barreiro et al., 2025](#)).

El tratamiento de la DM1 se apoya principalmente en dos modalidades: la terapia con múltiples dosis diarias de insulina (MDI) y la infusión subcutánea continua mediante bomba de insulina (ISCI). La incorporación de sistemas de monitorización continua de glucosa (MCG) ha supuesto un avance significativo en ambas modalidades: la evidencia disponible muestra mejoras en la hemoglobina glicada (HbA1c), incremento del tiempo en rango (TIR) y reducción de episodios hipoglucémicos ([Rizos et al., 2025](#)). Los sistemas de asa cerrada o páncreas artificial, que integran MCG, bomba de insulina y algoritmo de control, representan el estadio más avanzado de esta evolución tecnológica ([Nwokolo and Hovorka, 2023](#)), aunque su implantación generalizada sigue limitada por barreras económicas, tecnológicas y de aceptación del paciente. En consecuencia, una proporción significativa de la población con DM1 continúa gestionando su tratamiento con MDI y MCG sin soporte algorítmico integrado.

En este contexto surge la motivación del presente trabajo. La disponibilidad de series temporales de glucemia procedentes de dispositivos MCG abre la posibilidad de aplicar modelos predictivos que anticipen la evolución de la glucosa y, con ello, faciliten la toma de decisiones terapéuticas en pacientes con MDI.

Estructura del documento

La memoria se organiza en ocho capítulos cuya progresión refleja el ciclo metodológico del trabajo:

- **Capítulo 1 - Introducción:** presenta el trabajo realizado y contextualiza el problema abordado.
- **Capítulo 2 - Objetivos:** define de forma precisa los objetivos generales y específicos que guían el desarrollo del trabajo.
- **Capítulo 3 - Conceptos teóricos:** proporciona el marco de referencia para la comprensión del trabajo.
- **Capítulo 4 - Metodología:** describe el conjunto de datos utilizado, el preprocesamiento aplicado, los modelos predictivos seleccionados y las métricas de evaluación empleadas para su comparación.
- **Capítulo 5 - Resultados:** presenta los resultados cuantitativos obtenidos.
- **Capítulo 6 - Discusión:** interpreta los resultados en relación con la literatura existente, analiza las limitaciones del estudio y discute las implicaciones clínicas de los hallazgos.
- **Capítulo 7 - Conclusiones:** sintetiza las aportaciones del trabajo.
- **Capítulo 8 - Líneas futuras:** identifica las direcciones de investigación y desarrollo que se derivan de los resultados obtenidos y de las limitaciones identificadas.

Objetivos

El objetivo general del trabajo es realizar un estudio comparativo del rendimiento de modelos de predicción de glucosa en sangre aplicados a series temporales de monitorización continua con variables exógenas en pacientes con DM1 en tratamiento mediante MDI, bajo distintas condiciones experimentales simuladas, para horizontes de predicción de 15 y 30 minutos.

Para alcanzarlo, se definen los siguientes objetivos específicos:

1. Generar los conjuntos de datos necesarios para el estudio a partir de un simulador validado.
2. Comparar el rendimiento global de los modelos seleccionados mediante métricas de error y criterios de seguridad clínica en los horizontes de predicción establecidos.
3. Analizar el efecto de las condiciones de manejo de la diabetes - variabilidad en la ingesta de hidratos de carbono, práctica de ejercicio físico y error en el cálculo de la dosis de insulina- sobre la precisión de los modelos.
4. Analizar la degradación del rendimiento de los modelos al aumentar el horizonte de predicción de 15 a 30 minutos.

Asimismo, el desarrollo del trabajo ha permitido adquirir y consolidar las siguientes competencias:

- **Conocimiento clínico aplicado:** comprensión de la fisiopatología de la DM1, las modalidades de tratamiento con insulina y el funcionamiento de los sistemas de monitorización continua de glucosa, así como de los criterios de seguridad clínica empleados en la evaluación de modelos predictivos (Clarke Error Grid).

- **Diseño experimental:** planificación de condiciones experimentales simuladas, definición de variables de interés y generación de conjuntos de datos a partir de un simulador biomédico validado.
- **Tratamiento y análisis de datos:** manipulación de series temporales biomédicas mediante herramientas de programación (Python), incluyendo preprocesamiento, transformación y análisis exploratorio.
- **Modelado predictivo:** implementación y ajuste de modelos estadísticos y de aprendizaje automático aplicados a series temporales con variables exógenas, y evaluación comparativa de su rendimiento mediante métricas cuantitativas.

Conceptos teóricos

3.1. Diabetes mellitus tipo 1

La diabetes mellitus tipo 1 (DM1) es una enfermedad autoinmune crónica en la que el sistema inmunitario destruye de forma progresiva las células beta de los islotes de Langerhans del páncreas, responsables de la secreción de insulina. La consecuencia directa es una deficiencia absoluta de esta hormona, lo que impide la captación celular de glucosa y provoca hiperglucemia crónica. A diferencia de la diabetes tipo 2, la DM1 no está asociada a resistencia a la insulina ni a factores de estilo de vida, y su aparición se produce habitualmente en la infancia o la adolescencia, aunque puede manifestarse a cualquier edad ([Gregory et al., 2022](#)).

La hiperglucemia mantenida se asocia a complicaciones microvasculares (retinopatía, nefropatía, neuropatía) y macrovasculares (enfermedad cardiovascular) que determinan de forma significativa la morbimortalidad a largo plazo. El control glucémico estricto, cuantificado principalmente mediante la hemoglobina glicada (HbA1c) y el tiempo en rango (TIR), constituye el principal objetivo terapéutico ([Calvo Ferrer et al., 2004](#)). El TIR se define como el porcentaje de tiempo en que la glucemia se mantiene entre 70 y 180 mg/dL, y se ha consolidado como indicador clínico de referencia gracias a su correlación con el riesgo de complicaciones (?). La magnitud epidemiológica de la enfermedad, con una prevalencia global estimada en 9,5 millones de personas en 2025 ([Ogle et al., 2025](#)), subraya la necesidad de desarrollar herramientas tecnológicas que mejoren su gestión.

3.2. Tratamiento con múltiples dosis diarias de insulina

El tratamiento con múltiples dosis diarias de insulina (MDI) es la modalidad terapéutica más extendida en pacientes con DM1. Consiste en la administración de insulina basal de acción prolongada —generalmente una dosis diaria— combinada con insulina de acción rápida en cada ingesta, cuya dosis se calcula en función de la cantidad de hidratos de carbono consumidos y de la glucemia preprandial del paciente ([Calvo Ferrer et al., 2004](#)).

El cálculo de la dosis de insulina prandial se basa en dos parámetros individualizados: la ratio insulina/ración (I:R), que determina las unidades de insulina necesarias para metabolizar una cantidad fija de hidratos de carbono (habitualmente 10 g), y el factor de sensibilidad a la insulina (FSI), que estima el descenso glucémico esperado por cada unidad de insulina administrada. Ambos parámetros presentan variabilidad interindividual e intraindividual significativa, lo que convierte su estimación precisa en uno de los principales retos del manejo clínico de la DM1 ([Calvo Ferrer et al., 2004](#)).

La eficacia del régimen MDI depende en gran medida de la capacidad del paciente para estimar con precisión los hidratos de carbono ingeridos, un proceso sujeto a error sistemático y aleatorio con impacto directo sobre el control glucémico postprandial ([Calvo Ferrer et al., 2004](#)). La práctica de ejercicio físico añade una capa adicional de complejidad, dado que modifica la sensibilidad a la insulina de forma aguda y prolongada, induciendo tanto episodios hipoglucémicos durante o tras el ejercicio como respuestas hiperglucémicas en ejercicio de alta intensidad ([Helleputte et al., 2023](#)).

3.3. Monitorización continua de glucosa

Los sistemas de monitorización continua de glucosa (MCG) miden la concentración de glucosa en el líquido intersticial mediante un sensor electroquímico implantado en el tejido subcutáneo, proporcionando lecturas automáticas con una frecuencia típica de 5 minutos (?). A diferencia de la glucometría capilar tradicional, que ofrece mediciones puntuales, la MCG genera series temporales continuas que permiten caracterizar la dinámica glucémica a lo largo del día, identificar patrones postprandiales, episodios nocturnos y la respuesta glucémica al ejercicio físico.

La evidencia disponible muestra que el uso de MCG en pacientes con DM1 se asocia a reducciones significativas de la HbA1c, incremento del TIR y disminución de la frecuencia e intensidad de los episodios hipoglucémicos (?).

Entre los dispositivos más extendidos en la práctica clínica actual destacan el FreeStyle Libre 2 Plus y el FreeStyle Libre 3 (Abbott), que proporcionan lecturas transmitidas cada 5 minutos, con una vida útil del sensor de 15 días y sin necesidad de calibración. El Dexcom ONE+ ofrece características similares con transmisión en tiempo real continua. En el sistema de Salud de Castilla y León (SaCyL), el FreeStyle Libre 2 es el dispositivo financiado para pacientes con DM1 en régimen MDI, mientras que el FreeStyle Libre 3 se asigna a los usuarios de bomba de insulina.

Desde el punto de vista de las capacidades predictivas integradas, la mayoría de los dispositivos MCG comerciales incorporan únicamente indicadores de tendencia glucémica —flechas de dirección y velocidad de cambio basadas en el comportamiento reciente de la señal— y alarmas configurables por umbral. La única solución que actualmente incorpora predicción cuantitativa de glucosa es el sistema Accu-Chek SmartGuide (Roche), cuya aplicación complementaria Accu-Chek SmartGuide Predict estima la evolución de la glucosa en los siguientes 30 minutos y 2 horas, así como el riesgo de hipoglucemia nocturna, a partir de los valores de MCG y las entradas manuales de insulina y carbohidratos registradas por el usuario (Roche Diabetes Care, 2025). Este sistema no está incluido en la cartera de financiación pública del sistema de Salud de Castilla y León a la fecha de elaboración de este trabajo.

Métricas de evaluación clínica

La evaluación del control glucémico en pacientes con MCG se apoya en indicadores estandarizados. El tiempo en rango (TIR) cuantifica el porcentaje de lecturas dentro del intervalo 70–180 mg/dL, mientras que el tiempo por debajo del rango (TBR, <70 mg/dL) y el tiempo por encima del rango (TAR, >180 mg/dL) caracterizan la exposición a hipoglucemia e hiperglucemia respectivamente. El coeficiente de variación (CV) de la glucosa refleja la variabilidad glucémica, con un umbral clínico de referencia del 36 % (?).

Clarke Error Grid y Parkes Error Grid

La Clarke Error Grid (CEG) es un método de evaluación de la seguridad clínica de las estimaciones glucémicas que clasifica los pares (valor real, valor predicho) en cinco zonas según su impacto potencial sobre la toma de decisiones terapéuticas (Clarke et al., 1987). La zona A agrupa las estimaciones clínicamente precisas (error $\leq 20\%$ o dentro del rango normoglucémico); la zona B incluye estimaciones con desviación aceptable que no inducen tratamiento erróneo; las zonas C, D y E recogen, respectivamente, estimaciones

que llevarían a correcciones innecesarias, a omitir tratamiento necesario, o a tratamiento opuesto al requerido. En el contexto de modelos predictivos de glucemia, la distribución de predicciones en zonas A y B es el criterio de seguridad clínica más relevante, ya que determina si el modelo es utilizable en la práctica asistencial (Sengupta et al., 2022).

La Parkes Error Grid, también conocida como Consensus Error Grid, constituye una revisión posterior de la CEG que amplía su aplicabilidad a dispositivos de monitorización modernos y refina la delimitación de las zonas de riesgo clínico (Pfützner et al., 2013). Si bien no ha sido aplicada en el presente trabajo, su existencia es relevante como marco de referencia para estudios futuros que busquen una evaluación de seguridad clínica más actualizada.

3.4. Simulación de pacientes virtuales con DM1

La obtención de datos reales de pacientes con DM1 para el desarrollo y evaluación de algoritmos presenta barreras éticas, burocráticas y logísticas que dificultan su disponibilidad en el contexto académico. Los simuladores de pacientes virtuales constituyen una alternativa consolidada en la investigación en tecnologías para la diabetes, permitiendo generar datos controlados y reproducibles bajo condiciones experimentales definidas (Siket et al., 2025).

El simulador de referencia en este campo es el UVA/Padova metabolic simulator, desarrollado conjuntamente por la Universidad de Virginia y la Universidad de Padova (Man et al., 2014). Este simulador está aceptado por la Food and Drug Administration (FDA) de Estados Unidos como sustituto de los estudios preclínicos en animales para el desarrollo y evaluación de algoritmos de control glucémico, lo que acredita su validez como entorno de pruebas (Man et al., 2014). El modelo reproduce la dinámica glucosa-insulina mediante un sistema de ecuaciones diferenciales que describe los compartimentos de absorción gastrointestinal, distribución de glucosa, acción de la insulina y producción hepática de glucosa, parametrizado a partir de datos fisiológicos reales.

En el presente trabajo se ha utilizado py-mgipsim, una librería Python de código abierto que implementa y extiende el modelo UVA/Padova (Siket et al., 2025). La librería proporciona una cohorte de 20 pacientes virtuales con conjuntos de parámetros individualizados y datos demográficos diferenciados, e incorpora implementaciones de los regímenes terapéuticos MDI, bomba de insulina con sensor aumentado (SAP) y sistemas de asa cerrada híbrida.

Entre sus características relevantes para el presente trabajo se encuentran la posibilidad de introducir incertidumbre en el recuento de hidratos de carbono, variabilidad estocástica en los tiempos de ingesta y ejercicio físico, y la exportación de variables de estado en formato estructurado ([Siket et al., 2025](#)).

3.5. Modelos predictivos para series temporales

La predicción de series temporales consiste en estimar valores futuros de una variable a partir de su historia pasada y, en su caso, de variables externas relacionadas. En el contexto de la glucemia, la serie temporal está formada por las lecturas periódicas del sensor MCG, y las variables externas incluyen la insulina administrada, la ingesta de hidratos de carbono y el ejercicio realizado. El horizonte de predicción define el intervalo temporal entre el último dato disponible y el instante predicho; en este trabajo se trabaja con horizontes de 15 y 30 minutos, equivalentes a 3 y 6 pasos temporales respectivamente, dada la frecuencia de muestreo de 5 minutos.

ARIMAX

Los modelos ARIMA (AutoRegressive Integrated Moving Average) son una familia de modelos estadísticos lineales para series temporales estacionarias que combinan tres componentes: un término autorregresivo (AR) que modela la dependencia lineal con valores pasados de la propia serie, un término de media móvil (MA) que modela la dependencia con errores de predicción pasados, y un operador de diferenciación (I) que transforma la serie en estacionaria mediante diferencias sucesivas. El modelo se parametriza mediante el triplete (p, d, q) , donde p es el orden autorregresivo, d el grado de diferenciación y q el orden de la media móvil ([Box et al., 2015](#)).

La extensión ARIMAX (ARIMA with eXogenous inputs) incorpora variables exógenas como regresores adicionales al modelo, lo que permite capturar el efecto de entradas externas sobre la evolución de la serie. Esta extensión es especialmente relevante en el modelado de la glucemia, dado que las excursiones postprandiales y el efecto de la insulina constituyen perturbaciones exógenas con un perfil temporal conocido.

XGBoost

XGBoost (eXtreme Gradient Boosting) es un algoritmo de aprendizaje automático basado en la construcción secuencial de árboles de decisión, donde cada árbol nuevo se entrena para corregir los errores residuales del

conjunto de árboles anteriores mediante el descenso de gradiente sobre una función de pérdida ([Chen and Guestrin, 2016](#)). A diferencia de los modelos estadísticos clásicos, XGBoost no impone supuestos sobre la linealidad de las relaciones entre variables, lo que lo hace apto para capturar interacciones no lineales entre la glucemia pasada, la insulina y los hidratos de carbono. Su aplicación a series temporales requiere una transformación previa de la serie en formato supervisado, dado que el algoritmo no opera de forma nativa sobre datos secuenciales.

Selección de hiperparámetros

Ambos modelos requieren la optimización de sus hiperparámetros para maximizar el rendimiento predictivo. En el presente trabajo, la búsqueda de hiperparámetros se ha realizado sobre un paciente virtual de referencia, común a ambos modelos, con el objetivo de garantizar la comparabilidad de los resultados. Los hiperparámetros obtenidos se han aplicado posteriormente al resto de la cohorte sin reajuste individual, lo que permite evaluar la capacidad de generalización de cada modelo ante la variabilidad interpaciente.

3.6. Estado del arte

La predicción de glucemia mediante modelos de aprendizaje automático y estadísticos aplicados a series temporales de MCG es un campo de investigación activo desde la década de 2010, impulsado por la generalización de los dispositivos MCG y la disponibilidad de datos continuos de alta frecuencia. Una revisión sistemática y metaanálisis en red que incluyó 46 estudios cifra el RMSE medio para horizontes de 15, 30 y 60 minutos en 18,88, 21,40 y 30,01 mg/dL respectivamente, con los modelos de redes neuronales mostrando el mejor rendimiento relativo en todos los horizontes ([Liu et al., 2023](#)). Esta tendencia al aumento del error con el horizonte de predicción es consistente en la literatura y constituye uno de los ejes de análisis del presente trabajo.

Entre los enfoques estadísticos, los modelos de la familia ARIMA y sus extensiones con variables exógenas han sido utilizados ampliamente para la predicción a corto plazo, valorados por su interpretabilidad y bajo coste computacional. Entre los enfoques basados en aprendizaje automático, las arquitecturas LSTM han mostrado resultados competitivos gracias a su capacidad para capturar dependencias temporales de largo alcance ([Carvalho and Liang, 2024](#); [Butt et al., 2023](#)). El trabajo de Butt et al. (2023), que aplica transformación de características de insulina y carbohidratos sobre el dataset OhioT1DM con un modelo Bi-LSTM, obtiene un RMSE de 14,76

mg/dL a 30 minutos, constituyendo una referencia de comparación directa para el presente trabajo. Enfoques basados en programación genética han explorado la predicción individualizada a 30 y 60 minutos sobre datos reales de pacientes, logrando que el 98 % y el 90 % de las predicciones respectivamente caigan en zonas clínicamente aceptables según la CEG (Cano et al., 2025).

Los modelos híbridos y de ensemble han ganado presencia en la literatura reciente como estrategia para mejorar la robustez entre distintos horizontes de predicción. La revisión de (Cinar et al., 2025) identifica que los modelos apilados obtienen los mejores resultados en regresión, destacando combinaciones de métodos de aprendizaje automático y aprendizaje profundo como modelos base, incluyendo específicamente ensembles de LSTM y XGBoost entre los enfoques con rendimiento más estable. Sin embargo, la mayoría de modelos no mantienen su rendimiento de forma robusta a través de múltiples horizontes con una única arquitectura, lo que refuerza el interés por analizar el comportamiento de modelos individuales ante distintos horizontes antes de explorar combinaciones.

La mayoría de los trabajos existentes se han desarrollado sobre datos reales procedentes de datasets públicos —como el OhioT1DM— o sobre cohortes de pacientes con sistemas de asa cerrada o ISCI, mientras que los estudios centrados específicamente en poblaciones MDI son menos frecuentes. En el ámbito nacional, se han explorado sistemas de predicción de glucosa portátiles (?) y algoritmos de control avanzado basados en modelos predictivos (?).

El presente trabajo se distingue de los precedentes en tres aspectos: la delimitación explícita al régimen MDI, la comparación directa entre un modelo estadístico lineal (ARIMAX) y un modelo de aprendizaje automático no lineal (XGBoost) bajo condiciones experimentales controladas mediante simulador validado, y el análisis del efecto de variables clínicamente relevantes —variabilidad en la ingesta, ejercicio físico y error en la dosis de insulina— sobre el rendimiento predictivo de cada modelo.

Metodología

4.1. Descripción de los datos

Los datos utilizados en el trabajo fueron generados mediante el simulador py-mgipsim (Siket et al., 2025) sobre una cohorte de 20 pacientes virtuales con DM1 en régimen MDI. Para cada paciente se simularon seis escenarios experimentales que combinan tres factores clínicamente relevantes: la variabilidad en la ingesta de hidratos de carbono, la presencia de ejercicio físico regular y el error en el cálculo de la ratio insulina/ración (I:R), tal como se recoge en la Tabla 4.1.

Tabla 4.1: Definición de los escenarios experimentales.

Escenario	Código	HC	Ejercicio	Error I:R
E1	HC ⁻ E ₀ Er ₀	Baja	No	0 %
E2	HC ⁺ E ₀ Er ₀	Alta	No	0 %
E3	HC ⁻ E ⁺ Er ₀	Baja	Sí	0 %
E4	HC ⁻ E ₀ Er ⁺	Baja	No	10 %
E5	HC ⁺ E ₀ Er ⁺	Alta	No	10 %
E6	HC ⁻ E ⁺ Er ⁺	Baja	Sí	10 %

E1 actúa como escenario de referencia o línea base, con condiciones ideales de manejo. Los escenarios E2, E3 y E4 introducen cada factor de variabilidad de forma aislada respecto a E1, mientras que E5 y E6 combinan el error en la dosis con variabilidad en HC y con ejercicio respectivamente. Los horarios de ingesta son comunes a todos los escenarios. Esta estructura permite analizar el efecto individual y combinado de cada factor sobre el rendimiento predictivo.

El simulador genera un conjunto amplio de variables fisiológicas y de control distribuidas en dos archivos de salida por paciente y escenario. De entre ellas se seleccionaron las relevantes para el estudio: glucemia (convertida de mmol/L a mg/dL), ejercicio físico, insulina en bolo, insulina basal, y la ingesta de comidas y tentempiés. Cabe señalar que los tentempiés generados por el simulador no conllevan administración de insulina en bolo. El resto de variables proporcionadas por el simulador —como señales fisiológicas internas del modelo metabólico— fueron descartadas por no ser relevantes para el problema de predicción planteado. El conjunto de datos resultante comprende 120 series temporales independientes (20 pacientes $\times$ 6 escenarios). La descripción detallada de las variables y la estructura de los ficheros se recoge en el Anexo F.

4.2. Técnicas y herramientas

Preprocesamiento

Las series temporales generadas por py-mgipsim presentan una frecuencia de muestreo de 1 minuto. Para alinearlas con la resolución temporal de los dispositivos MCG comerciales y reducir la carga computacional, se aplicó un remuestreo a 5 minutos mediante una función propia que desplaza las variables de evento —ingesta de hidratos de carbono, insulina en bolo e insulina basal— al instante de muestreo más cercano dentro de cada intervalo de 5 minutos. A continuación se asignó un índice temporal de tipo datetime al dataframe de cada paciente, requisito necesario para el correcto funcionamiento de las funciones de predicción con series temporales de skforecast ([Amat Rodrigo and Escobar Ortiz, 2024](#)).

Ingeniería de características

A partir de las series preprocesadas se construyeron dos tipos de características de entrada, comunes a ambos modelos:

- **Retardos de glucemia:** valores pasados de la glucosa en los instantes previos al horizonte de predicción, seleccionados durante la optimización de hiperparámetros.
- **Variables exógenas acumuladas:** para la insulina en bolo, los hidratos de carbono y el ejercicio se calcularon valores acumulados por tramos de 20 minutos durante las últimas 4 horas, capturando el perfil temporal de acción de cada variable sobre la glucemia. De forma excepcional, la insulina basal se acumuló sobre las últimas 24 horas, dado su perfil de acción prolongada.

Se implementaron funciones de escalado y estandarización que finalmente no se aplicaron en la evaluación, dado que los resultados sin transformación fueron satisfactorios y su inclusión habría incrementado de forma significativa el coste computacional.

División train/test y backtesting

Cada serie temporal se dividió en un 80 % para entrenamiento y un 20 % para test, respetando el orden cronológico. La evaluación se realizó mediante backtesting con tamaño de ventana de entrenamiento fijo y reajuste del modelo en cada paso (refit), simulando el comportamiento de un predictor en producción que se actualiza periódicamente con nuevos datos. El proceso se aplicó de forma independiente para cada combinación de paciente, escenario y horizonte de predicción (15 y 30 minutos), generando un total de 240 evaluaciones por modelo (20 pacientes $\times$ 6 escenarios $\times$ 2 horizontes).

Optimización de hiperparámetros

La búsqueda de hiperparámetros se realizó sobre un paciente de referencia único (paciente 1, escenario E3), común a ambos modelos, tomando el MAE como métrica objetivo y garantizando la comparabilidad. Los hiperparámetros obtenidos se aplicaron al resto de la cohorte sin reajuste individual. Para ARIMAX se empleó `grid_search_stats` de `skforecast`, descartando la componente de estacionalidad. Para XGBoost ([Chen and Guestrin, 2016](#)) se empleó optimización bayesiana con validación `OneStepAheadFold`. Los hiperparámetros detallados de ambos modelos se recogen en el Anexo G.

Métricas de evaluación

El rendimiento predictivo se cuantificó mediante el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE). La seguridad clínica se evaluó mediante la Clarke Error Grid ([Clarke et al., 1987](#)), extrayendo el porcentaje de predicciones en zona A, en zonas A+B (clínicamente aceptables) y en zonas D+E (clínicamente peligrosas).

Dado que los tests de normalidad de Shapiro-Wilk aplicados sobre las distribuciones de MAE y RMSE rechazaron la hipótesis de normalidad en la mayoría de los escenarios, la comparación estadística entre pares de escenarios se realizó mediante el test de Wilcoxon de rangos con signo ([SciPy Contributors, 2020](#)). Los pares analizados fueron E1–E2, E1–E3, E1–E4, E2–E5 y E4–E6, seleccionados para aislar el efecto individual de cada factor experimental sobre el rendimiento predictivo de cada modelo.

Herramientas

El desarrollo se llevó a cabo en Python. Las principales librerías utilizadas fueron skforecast ([Amat Rodrigo and Escobar Ortiz, 2024](#)) para la implementación y evaluación de los modelos predictivos, xgboost ([Chen and Guestrin, 2016](#)) para el regresor base del modelo de gradient boosting, statsmodels para ARIMAX, pandas y numpy para la manipulación de datos, scipy ([SciPy Contributors, 2020](#)) para los tests estadísticos y matplotlib para la visualización de resultados.

Se valoró la incorporación de la librería SHAP para el análisis de importancia y explicabilidad de las variables de entrada. Sin embargo, su integración no pudo llevarse a cabo debido a incompatibilidades entre las versiones de las dependencias del entorno de desarrollo. Adicionalmente, una modificación de la versión de Python habría comprometido la reproducibilidad de los resultados al afectar al comportamiento de los generadores de números aleatorios de las librerías utilizadas. Por este motivo, el análisis de explicabilidad mediante SHAP se identifica como una línea de trabajo futura (véase Capítulo 8).

4.3. Metodología de ingeniería del software

El trabajo siguió una metodología experimental iterativa, centrada en el análisis de datos y la evaluación de modelos más que en el desarrollo de un sistema software completo. El proceso se organizó en fases sucesivas: generación de datos mediante simulación, desarrollo del pipeline de preprocesamiento, implementación y ajuste de los modelos, y evaluación comparativa de resultados. Dado que el trabajo no comprende el ciclo de vida completo de un desarrollo software, se remite al Anexo A para la planificación temporal detallada y la descripción de las fases realizadas y pendientes.

Resultados

Este capítulo presenta los resultados obtenidos para los modelos ARIMAX y XGBoost en los seis escenarios experimentales definidos, para los horizontes de predicción de 15 y 30 minutos. Los resultados se organizan en torno a los ejes de análisis establecidos en los objetivos: rendimiento global mediante métricas de error, seguridad clínica mediante la Clarke Error Grid, degradación del rendimiento con el horizonte de predicción, y relación entre el perfil glucémico del paciente y el error predictivo. Los resultados detallados por paciente y escenario se recogen en el Anexo G.

5.1. Rendimiento global




Figura 5.1: MAE medio por escenario y horizonte de predicción para ARIMAX y XGBoost.

En términos de MAE, XGBoost superó a ARIMAX en todos los escenarios y horizontes (Figura 5.1). En el escenario de referencia E1, los valores medios fueron 0,121 mg/dL frente a 0,249 mg/dL a 15 minutos, y 0,126 mg/dL frente a 0,249 mg/dL a 30 minutos. El test de Wilcoxon inter-modelo confirmó que

Resultados

las diferencias fueron estadísticamente significativas en todos los escenarios a 15 minutos ($p < 0,001$ en E1, E2, E3 y E4; $p < 0,01$ en E5; $p < 0,05$ en E6), mientras que a 30 minutos la diferencia dejó de ser significativa en E5 y E6. Sin embargo, el rendimiento de XGBoost presentó mayor variabilidad interpaciente, especialmente en los escenarios con error estocástico: en E5 y E6 el MAE medio alcanzó 0,195 y 0,194 mg/dL a 15 minutos y 0,215 y 0,216 mg/dL a 30 minutos. ARIMAX, por el contrario, mantuvo un MAE prácticamente constante en todos los escenarios (0,249–0,251 mg/dL) con desviación típica notablemente inferior.




Figura 5.2: RMSE medio por escenario y horizonte de predicción para ARIMAX y XGBoost.

En términos de RMSE, el patrón fue distinto (Figura 5.2). XGBoost obtuvo un RMSE comparable a ARIMAX en los escenarios sin error en la dosis (E1, E2, E3), sin diferencias estadísticamente significativas entre modelos. En los escenarios con error en la dosis (E4, E5, E6), ARIMAX resultó significativamente mejor que XGBoost en RMSE ($p < 0,05$ en E4 a 15 min; $p < 0,01$ en E5 y E6 a 15 min; $p < 0,05$ en E4 y E6 a 30 min; $p < 0,001$ en E5 a 30 min), con valores medios de XGBoost de 0,344, 0,414 y 0,457 mg/dL a 15 minutos frente a 0,288, 0,307 y 0,291 mg/dL de ARIMAX en esos mismos escenarios. Este resultado refleja que XGBoost genera errores puntuales de mayor magnitud bajo condiciones de perturbación, penalizados en mayor medida por el RMSE.

El test de Wilcoxon inter-simulación reveló patrones diferenciados entre modelos. Para ARIMAX, ningún par de escenarios mostró diferencias estadísticamente significativas en MAE ni en RMSE ($p > 0,05$ en todos los casos), lo que indica que el modelo no ha sido sensible a ninguno de los factores experimentales introducidos. Para XGBoost, la variabilidad en la ingesta de HC (E1–E2) y el error en la dosis de insulina (E1–E4) produjeron incrementos significativos del error en ambos horizontes y métricas ($p <$

0,001). El error en la dosis sobre escenarios de HC variable (E2–E5) también resultó significativo en MAE ($p < 0,001$) y en RMSE ($p < 0,01$ a 15 min; $p < 0,05$ a 30 min). El error en la dosis sobre el escenario con ejercicio (E3–E6) fue significativo en MAE ($p < 0,001$) y en RMSE a 15 minutos ($p < 0,01$). El ejercicio por sí solo (E1–E3) no produjo diferencias significativas en ningún modelo, horizonte ni métrica.

5.2. Seguridad clínica

Ambos modelos obtuvieron el 100 % de las predicciones clasificadas en zona A de la CEG en todos los escenarios y horizontes de predicción, sin ninguna predicción en zonas B, C, D o E (Figura 5.3). Esto implica que la totalidad de las predicciones presentaron un error inferior al 20 % del valor real de glucemia, umbral de precisión clínica más estricto de la CEG. El resultado fue idéntico para el horizonte de 30 minutos (véase Anexo G). La interpretación de este hallazgo se discute en el siguiente capítulo.




Figura 5.3: Distribución de predicciones en zonas de la Clarke Error Grid para XGBoost y ARIMAX en el horizonte de 15 minutos, por escenario.

5.3. Degradación del rendimiento con el horizonte

ARIMAX mostró una degradación prácticamente nula al pasar de 15 a 30 minutos, con ratios MAE_{30}/MAE_{15} iguales a 1,00 en todos los escenarios y ratios $RMSE_{30}/RMSE_{15}$ entre 0,99 y 1,03 (Figura 5.4, Figura 5.5). XGBoost presentó una degradación moderada pero consistente, con ratios MAE_{30}/MAE_{15} entre 1,05 y 1,12 y ratios $RMSE_{30}/RMSE_{15}$ entre 1,05 y 1,20 según el escenario. La degradación fue más pronunciada en los escenarios con mayor perturbación (E5 y E6), lo que sugiere que la complejidad del escenario amplifica el efecto del horizonte sobre el rendimiento de XGBoost.

Resultados




Figura 5.4: Degradación del MAE al aumentar el horizonte de predicción. Izquierda: valores absolutos por escenario. Derecha: ratio MAE_{30}/MAE_{15} por escenario y modelo.




Figura 5.5: Degradación del RMSE al aumentar el horizonte de predicción. Izquierda: valores absolutos por escenario. Derecha: ratio $RMSE_{30}/RMSE_{15}$ por escenario y modelo.

5.4. Relación entre perfil glucémico y rendimiento predictivo

Para XGBoost se observó una correlación negativa fuerte y altamente significativa entre el TIR del paciente y su error predictivo en todos los escenarios, tanto para MAE (r entre -0,76 y -0,81 a 15 min; r entre -0,75 y -0,82 a 30 min; $p < 0,001$ en todos los casos) como para RMSE (r entre -0,65 y -0,77 a 15 min; r entre -0,60 y -0,80 a 30 min; $p < 0,01$ o inferior). Agregando los resultados sobre los seis escenarios, los coeficientes de correlación fueron $r = -0,85$ (MAE, 15 min), $r = -0,89$ (MAE, 30 min), $r = -0,83$ (RMSE, 15 min) y $r = -0,84$ (RMSE, 30 min), todos con $p < 0,001$ (Figura 5.6, Figura 5.7).

Para ARIMAX, la correlación entre TIR y error no fue estadísticamente significativa en ningún escenario ni horizonte, a excepción del escenario E5 en MAE a 15 minutos ($r = -0,48$, $p = 0,031$). Los resultados detallados por escenario se recogen en el Anexo G.




Figura 5.6: Correlación de Spearman entre MAE medio por paciente (promediado sobre los seis escenarios) y TIR, para ambos modelos y horizontes de predicción.




Figura 5.7: Correlación de Spearman entre RMSE medio por paciente (promediado sobre los seis escenarios) y TIR, para ambos modelos y horizontes de predicción.

Discusión

Se realizará un análisis crítico de los resultados, interpretando su significado y, cuando sea pertinente, comparándolos con los resultados de trabajos previos, obtenidos con la revisión del estado del arte; de forma que se destaquen las mejoras y aportes sobre el mismo.

Conclusiones

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas.

7.1. Aspectos relevantes

Este apartado pretende recoger los aspectos más interesantes del **desarrollo del proyecto**, comentados por los autores del mismo y que den respuesta a los objetivos planteados.

Debe incluir los detalles más relevantes en cada fase del desarrollo, justificando los caminos tomados, especialmente aquellos que no sean triviales.

Puede ser el lugar más adecuado para documentar los aspectos más interesantes del proyecto y también los resultados negativos obtenidos por soluciones previas a la solución entregada.

Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.

Líneas de trabajo futuras

Este capítulo debería ser informe crítico indicando cómo se puede mejorar el proyecto, o cómo se puede continuar trabajando en la línea del proyecto realizado.

Bibliografía

- Amat Rodrigo, J. and Escobar Ortiz, J. (2024). skforecast: time series forecasting with scikit-learn.
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., and Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control*. Wiley, 5 edition.
- Butt, H., Khosa, I., and Iftikhar, M. A. (2023). Feature transformation for efficient blood glucose prediction in type 1 diabetes mellitus patients. *Diagnostics*, 13(3):340.
- Calvo Ferrer, F., López García, M. J., and Rodríguez Rigual, M. (2004). Diabetes mellitus tipo 1: Tratamiento, seguimiento, complicaciones agudas. In Oyarzabal Irigoyen, M., editor, *Manual de Consenso de la Sociedad Española de Endocrinología Pediátrica*, chapter 23, pages 1–32. Sociedad Española de Endocrinología Pediátrica (SEEP). Coordinador del capítulo: Miren Oyarzabal Irigoyen.
- Cano, J., Hidalgo, J. I., and Garnica, O. (2025). Hardware real-time individualised blood glucose predictor generator based on grammars and Cartesian genetic programming. *Genetic Programming and Evolvable Machines*, 26:3.
- Carvalho, C. F. and Liang, Z. (2024). Glucose prediction with Long Short-Term Memory (LSTM) models in three distinct populations. *Engineering Proceedings*, 82(1):87.
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.

- Cinar, B., van den Boom, L., and Maleshkova, M. (2025). A review on machine learning approaches for the prediction of glucose levels and hypoglycemia. *arXiv preprint*. arXiv:2601.11615. [COMPLETAR] autor(es) completos.
- Clarke, W. L., Cox, D., Gonder-Frederick, L. A., Carter, W., and Pohl, S. L. (1987). Evaluating Clinical Accuracy of Systems for Self-Monitoring of Blood Glucose. *Diabetes Care*, 10(5):622–628. _eprint: <https://diabetesjournals.org/care/article-pdf/10/5/622/515265/10-5-622.pdf>.
- Conde Barreiro, S., González Pelegrín, B., Quevedo Beneyto, B., Feja Solana, C., Malo Aznar, C., Rojo-Martínez, G., Menéndez Torre, E., and Gómez Peralta, F. (2025). Estimation of the incidence and prevalence of type 1 diabetes mellitus in children under 15 years of age in Spain. *Endocrinología, Diabetes Y Nutrición*, 72(7):501591.
- Gregory, G. A. et al. (2022). Global incidence, prevalence, and mortality of type 1 diabetes in 2021 and projections to 2040. *The Lancet Diabetes & Endocrinology*.
- Helleputte, S., Yardley, J. E., Scott, S. N., Stautemas, J., Jansseune, L., Marlier, J., De Backer, T., Lapauw, B., and Calders, P. (2023). Effects of postprandial exercise on blood glucose levels in adults with type 1 diabetes: a review. *Diabetologia*, 66(7):1179–1191.
- Liu, K., Li, L., Ma, Y., Jiang, J., Liu, Z., Ye, Z., Liu, S., Pu, C., Chen, C., and Wan, Y. (2023). Machine learning models for blood glucose level prediction in patients with diabetes mellitus: systematic review and network meta-analysis. *JMIR Medical Informatics*, 11:e47833.
- Man, C. D., Micheletto, F., Lv, D., Breton, M., Kovatchev, B., and Cobelli, C. (2014). The UVa/Padova type 1 diabetes simulator: new features. *Journal of Diabetes Science and Technology*, 8(1):26–34.
- Nwokolo, M. and Hovorka, R. (2023). The Artificial Pancreas and Type 1 Diabetes. *The Journal of Clinical Endocrinology and Metabolism*, 108(7):1614–1623.
- Ogle, G. D., Wang, F., Haynes, A., et al. (2025). Global type 1 diabetes prevalence, incidence, and mortality estimates 2025: Results from the International Diabetes Federation Atlas, 11th Edition, and the T1D Index Version 3.0. *Diabetes Research and Clinical Practice*. Global estimate: 9.5 million people living with type 1 diabetes in 2025.

- Pfützner, A., Klonoff, D. C., Pardo, S., and Parkes, J. L. (2013). Technical Aspects of the Parkes Error Grid. *Journal of Diabetes Science and Technology*, 7(5):1275–1281.
- Rizos, E. C., Markozannes, G., Charitakis, N., Filis, P., Stoimeni, A. E., Nørgaard, K., Ntzani, E. E., and Tsilidis, K. K. (2025). Continuous Glucose Monitoring in Type 1 Diabetes, Type 2 Diabetes, and Diabetes During Pregnancy: A Systematic Review with Meta-Analysis of Randomized Controlled Trials. *Diabetes Technology & Therapeutics*, 27(7):537–552.
- Roche Diabetes Care (2025). Solución de MCG Accu-Chek SmartGuide. Sitio web corporativo. Consultado en 2025.
- SciPy Contributors (2020). SciPy: fundamental algorithms for scientific computing in Python.
- Sengupta, S., Handoo, A., Haq, I., Dahiya, K., Mehta, S., and Kaushik, M. (2022). Clarke Error Grid Analysis for Performance Evaluation of Glucometers in a Tertiary Care Referral Hospital. *Indian Journal of Clinical Biochemistry*, 37(2):199–205.
- Siket, M., Rashid, M. M., and Cinar, A. (2025). py-mgipsim: An Open-Source Python Library for Simulating Type 1 Diabetes With Diverse Meals and Physical Activities. *Journal of Diabetes Science and Technology*, 19(3):855–856.