




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Desarrollo de un modelo
predictivo de glucemia a corto
plazo mediante técnicas de
aprendizaje automático en
pacientes con diabetes tipo 1
en terapia MDI**

Presentado por Guillermo de la Fuente Abajo
en Universidad de Burgos

28 de mayo de 2026

Tutores: Antonio Jesús Canepa Oneto – Ruth Estefanía
Santos Mazo



UNIVERSIDAD
DE BURGOS

Escuela Politécnica Superior

Grado en Ingeniería de la Salud

D. Antonio Jesús Canepa Oneto, profesor del departamento de Ingeniería Informática. D. Ruth Estefanía Santos Mazo, Jefe de Sección. Endocrinología y Nutrición.

Expone/n:

Que el alumno D. Guillermo de la Fuente Abajo, con DNI 71704960E, ha realizado el Trabajo final de Grado en Ingeniería de la Salud titulado *título del trabajo*.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección de los que suscriben.

En Burgos, a 28 de mayo de 2026

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

D. Antonio Jesús Canepa Oneto

D. Ruth Estefanía Santos Mazo

Resumen

En este primer apartado se hace una **breve** presentación del tema que se aborda en el proyecto.

Descriptores

Palabras separadas por comas que identifiquen el contenido del proyecto.

Abstract

A **brief** presentation of the topic addressed in the project.

Keywords

keywords separated by commas.

Índice general

Índice general	iii
Índice de figuras	iv
Índice de tablas	v
Introducción	1
Objetivos	3
Conceptos teóricos	5
Metodología	13
Resultados	17
Discusión	23
Conclusiones	29
Líneas de trabajo futuras	31
Bibliografía	33

Índice de figuras

5.1. MAE medio por escenario y horizonte de predicción para ARI-MAX y XGBoost.	17
5.2. RMSE medio por escenario y horizonte de predicción para ARI-MAX y XGBoost.	18
5.3. Distribución de predicciones en zonas de la Clarke Error Grid para XGBoost y ARIMAX en el horizonte de 15 minutos, por escenario.	19
5.4. Degradación del MAE al aumentar el horizonte de predicción. Izquierda: valores absolutos por escenario. Derecha: ratio MAE_{30}/MAE_{15} por escenario y modelo.	20
5.5. Degradación del RMSE al aumentar el horizonte de predicción. Izquierda: valores absolutos por escenario. Derecha: ratio $RMSE_{30}/RMSE_{15}$ por escenario y modelo.	20
5.6. Correlación de Spearman entre MAE medio por paciente (promediado sobre los seis escenarios) y TIR, para ambos modelos y horizontes de predicción.	21
5.7. Correlación de Spearman entre RMSE medio por paciente (promediado sobre los seis escenarios) y TIR, para ambos modelos y horizontes de predicción.	21

Índice de tablas

4.1. Definición de los escenarios experimentales.	13
---	----

Introducción

La diabetes mellitus tipo 1 (DM1) es una enfermedad autoinmune crónica caracterizada por la destrucción de las células beta pancreáticas y la consecuente dependencia absoluta de insulina exógena. La prevalencia mundial se estima en 9,5 millones de personas en 2025 ([Ogle et al., 2025](#)), con tendencia ascendente hacia 2040 ([Gregory et al., 2022](#)). En España, la incidencia en menores de 15 años se sitúa en 20,54 casos por cada 100.000 personas-año ([Conde Barreiro et al., 2025](#)).

El tratamiento de la DM1 se apoya principalmente en dos modalidades: la terapia con múltiples dosis diarias de insulina (MDI) y la infusión subcutánea continua mediante bomba de insulina (ISCI). La incorporación de sistemas de monitorización continua de glucosa (MCG) ha supuesto un avance significativo en ambas modalidades: la evidencia disponible muestra mejoras en la hemoglobina glicada (HbA1c), incremento del tiempo en rango (TIR) y reducción de episodios hipoglucémicos ([Rizos et al., 2025](#)). Los sistemas de asa cerrada o páncreas artificial, que integran MCG, bomba de insulina y algoritmo de control, representan el estadio más avanzado de esta evolución tecnológica ([Nwokolo and Hovorka, 2023](#)), aunque su implantación generalizada sigue limitada por barreras económicas, tecnológicas y de aceptación del paciente. En consecuencia, una proporción significativa de la población con DM1 continúa gestionando su tratamiento con MDI y MCG sin soporte algorítmico integrado.

En este contexto surge la motivación del trabajo. La disponibilidad de series temporales de glucemia procedentes de dispositivos MCG abre la posibilidad de aplicar modelos predictivos que anticipen la evolución de la glucosa y, con ello, faciliten la toma de decisiones terapéuticas en pacientes con MDI.

Estructura del documento

La memoria se organiza en ocho capítulos cuya progresión refleja el ciclo metodológico del trabajo:

- **Capítulo 1 - Introducción:** presenta el trabajo realizado y contextualiza el problema abordado.
- **Capítulo 2 - Objetivos:** define de forma precisa los objetivos generales y específicos que guían el desarrollo del trabajo.
- **Capítulo 3 - Conceptos teóricos:** proporciona el marco de referencia para la comprensión del trabajo.
- **Capítulo 4 - Metodología:** describe el conjunto de datos utilizado, el preprocesamiento aplicado, los modelos predictivos seleccionados y las métricas de evaluación empleadas para su comparación.
- **Capítulo 5 - Resultados:** presenta los resultados cuantitativos obtenidos.
- **Capítulo 6 - Discusión:** interpreta los resultados en relación con la literatura existente, analiza las limitaciones del estudio y discute las implicaciones clínicas de los hallazgos.
- **Capítulo 7 - Conclusiones:** sintetiza las aportaciones del trabajo.
- **Capítulo 8 - Líneas futuras:** identifica las direcciones de investigación y desarrollo que se derivan de los resultados obtenidos y de las limitaciones identificadas.

Objetivos

El objetivo general del trabajo es realizar un estudio comparativo del rendimiento de modelos de predicción de glucosa en sangre aplicados a series temporales de monitorización continua con variables exógenas en pacientes con DM1 en tratamiento mediante MDI, bajo distintas condiciones experimentales simuladas, para horizontes de predicción de 15 y 30 minutos.

Para alcanzarlo, se definen los siguientes objetivos específicos:

1. Generar los conjuntos de datos necesarios para el estudio a partir de un simulador validado.
2. Comparar el rendimiento global de los modelos seleccionados mediante métricas de error y criterios de seguridad clínica en los horizontes de predicción establecidos.
3. Analizar el efecto de las condiciones de manejo de la diabetes - variabilidad en la ingesta de hidratos de carbono, práctica de ejercicio físico y error en el cálculo de la dosis de insulina- sobre la precisión de los modelos.
4. Analizar la degradación del rendimiento de los modelos al aumentar el horizonte de predicción de 15 a 30 minutos.

Asimismo, el desarrollo del trabajo ha permitido adquirir y consolidar las siguientes competencias:

- **Conocimiento clínico aplicado:** comprensión de la fisiopatología de la DM1, las modalidades de tratamiento con insulina y el funcionamiento de los sistemas de monitorización continua de glucosa, así como de los criterios de seguridad clínica empleados en la evaluación de modelos predictivos (Clarke Error Grid).

- **Diseño experimental:** planificación de condiciones experimentales simuladas, definición de variables de interés y generación de conjuntos de datos a partir de un simulador biomédico validado.
- **Tratamiento y análisis de datos:** manipulación de series temporales biomédicas mediante herramientas de programación (Python), incluyendo preprocesamiento, transformación y análisis exploratorio.
- **Modelado predictivo:** implementación y ajuste de modelos estadísticos y de aprendizaje automático aplicados a series temporales con variables exógenas, y evaluación comparativa de su rendimiento mediante métricas cuantitativas.

Conceptos teóricos

3.1. Diabetes mellitus tipo 1

La diabetes mellitus tipo 1 (DM1) es una enfermedad autoinmune crónica en la que el sistema inmunitario destruye de forma progresiva las células beta de los islotes de Langerhans del páncreas, responsables de la secreción de insulina. La consecuencia directa es una deficiencia absoluta de esta hormona, lo que impide la captación celular de glucosa y provoca hiperglucemia crónica. A diferencia de la diabetes tipo 2, la DM1 no está asociada a resistencia a la insulina ni a factores de estilo de vida, y su aparición se produce habitualmente en la infancia o la adolescencia, aunque puede manifestarse a cualquier edad ([Gregory et al., 2022](#)).

La hiperglucemia mantenida se asocia a complicaciones microvasculares (retinopatía, nefropatía, neuropatía) y macrovasculares (enfermedad cardiovascular) que determinan de forma significativa la morbilidad a largo plazo. El control glucémico estricto, cuantificado principalmente mediante la hemoglobina glicada (HbA1c) y el tiempo en rango (TIR), constituye el principal objetivo terapéutico ([Calvo Ferrer et al., 2004](#); [Grupo de trabajo de la Guía de Práctica Clínica sobre Diabetes Mellitus Tipo 1, 2026](#)). El TIR se define como el porcentaje de tiempo en que la glucemia se mantiene entre 70 y 180 mg/dL, y se ha consolidado como indicador clínico gracias a su correlación con el riesgo de complicaciones ([Rizos et al., 2025](#)). La magnitud epidemiológica de la enfermedad, con una prevalencia global estimada en 9,5 millones de personas en 2025 ([Ogle et al., 2025](#)), subraya la necesidad de desarrollar herramientas tecnológicas que mejoren su gestión.

3.2. Tratamiento con múltiples dosis diarias de insulina

El tratamiento con múltiples dosis diarias de insulina (MDI) es la modalidad terapéutica más extendida en pacientes con DM1. Consiste en la administración de insulina basal de acción prolongada -generalmente una dosis diaria- combinada con insulina de acción rápida en cada ingesta, cuya dosis se calcula en función de la cantidad de hidratos de carbono consumidos y de la glucemia preprandial del paciente ([Calvo Ferrer et al., 2004](#)).

El cálculo de la dosis de insulina prandial se basa en dos parámetros individualizados: la ratio insulina/ración (I:R), que determina las unidades de insulina necesarias para metabolizar una cantidad fija de hidratos de carbono (habitualmente 10 g), y el factor de sensibilidad a la insulina (FSI), que estima el descenso glucémico esperado por cada unidad de insulina administrada. Ambos parámetros presentan variabilidad interindividual e intraindividual significativa, lo que convierte su estimación precisa en uno de los principales retos del manejo clínico de la DM1 ([Calvo Ferrer et al., 2004](#); [Grupo de trabajo de la Guía de Práctica Clínica sobre Diabetes Mellitus Tipo 1, 2026](#)).

La eficacia del régimen MDI depende en gran medida de la capacidad del paciente para estimar con precisión los hidratos de carbono ingeridos, un proceso sujeto a error sistemático y aleatorio con impacto directo sobre el control glucémico postprandial ([Calvo Ferrer et al., 2004](#); [Grupo de trabajo de la Guía de Práctica Clínica sobre Diabetes Mellitus Tipo 1, 2026](#)). La práctica de ejercicio físico añade una capa adicional de complejidad, dado que modifica la sensibilidad a la insulina de forma aguda y prolongada, induciendo tanto episodios hipoglucémicos durante o tras el ejercicio, como respuestas hiperglucémicas en ejercicio de alta intensidad ([Helleputte et al., 2023](#)).

3.3. Monitorización continua de glucosa

Los sistemas de monitorización continua de glucosa (MCG) miden la concentración de glucosa en el líquido intersticial mediante un sensor electroquímico implantado en el tejido subcutáneo, proporcionando lecturas automáticas con una frecuencia típica de 5 minutos ([Rizos et al., 2025](#)). A diferencia de la glucometría capilar tradicional, que ofrece mediciones puntuales, la MCG genera series temporales continuas que permiten caracterizar la dinámica glucémica a lo largo del día, identificar patrones postprandiales, episodios nocturnos y la respuesta glucémica al ejercicio físico.

La evidencia disponible muestra que el uso de MCG en pacientes con DM1 se asocia a reducciones significativas de la HbA1c, incremento del TIR y disminución de la frecuencia e intensidad de los episodios hipoglucémicos ([Rizos et al., 2025](#)).

Entre los dispositivos más extendidos en la práctica clínica actual destacan el FreeStyle Libre 2 Plus y el FreeStyle Libre 3 (Abbott), que proporcionan lecturas transmitidas cada 5 minutos, con una vida útil del sensor de 15 días y sin necesidad de calibración. El Dexcom ONE+ ofrece características similares con transmisión en tiempo real continua. En el sistema de Salud de Castilla y León (SaCyL), el FreeStyle Libre 2 es el dispositivo financiado para pacientes con DM1 en régimen MDI, mientras que el FreeStyle Libre 3 se asigna a los usuarios de bomba de insulina.

Desde el punto de vista de las capacidades predictivas integradas, la mayoría de los dispositivos MCG comerciales incorporan únicamente indicadores de tendencia glucémica -flechas de dirección y velocidad de cambio basadas en el comportamiento reciente de la señal- y alarmas configurables por umbral. La única solución que actualmente incorpora predicción cuantitativa de glucosa es el sistema Accu-Chek SmartGuide (Roche), cuya aplicación complementaria Accu-Chek SmartGuide Predict estima la evolución de la glucosa en los siguientes 30 minutos y 2 horas, así como el riesgo de hipoglucemia nocturna, a partir de los valores de MCG y las entradas manuales de insulina y carbohidratos registradas por el usuario ([Roche Diabetes Care, 2025](#)). Este sistema no está incluido en la cartera de financiación pública del sistema de Salud de Castilla y León a la fecha de elaboración de este trabajo.

Métricas de evaluación clínica

La evaluación del control glucémico en pacientes con MCG se apoya en indicadores estandarizados. El tiempo en rango (TIR) cuantifica el porcentaje de lecturas dentro del intervalo 70–180 mg/dL, mientras que el tiempo por debajo del rango (TBR, <70 mg/dL) y el tiempo por encima del rango (TAR, >180 mg/dL) caracterizan la exposición a hipoglucemia e hiperglucemia respectivamente.

Clarke Error Grid y Parkes Error Grid

La Clarke Error Grid (CEG) es un método de evaluación de la seguridad clínica de las estimaciones glucémicas que clasifica los pares (valor real, valor predicho) en cinco zonas según su impacto potencial sobre la toma de deci-

siones terapéuticas (Clarke et al., 1987). La zona A agrupa las estimaciones clínicamente precisas (error $\leq 20\%$ o dentro del rango normoglucémico); la zona B incluye estimaciones con desviación aceptable que no inducen tratamiento erróneo; las zonas C, D y E recogen, respectivamente, estimaciones que llevarían a correcciones innecesarias, a omitir tratamiento necesario, o a tratamiento opuesto al requerido. En el contexto de modelos predictivos de glucemia, la distribución de predicciones en zonas A y B es el criterio de seguridad clínica más relevante, ya que determina si el modelo es utilizable en la práctica asistencial (Sengupta et al., 2022).

La Parkes Error Grid, también conocida como Consensus Error Grid, constituye una revisión posterior de la CEG que amplía su aplicabilidad a dispositivos de monitorización modernos y refina la delimitación de las zonas de riesgo clínico (Pfützner et al., 2013). Si bien no ha sido aplicada en este estudio, su existencia es relevante como marco de referencia para estudios futuros que busquen una evaluación de seguridad clínica más actualizada.

3.4. Simulación de pacientes virtuales con DM1

La obtención de datos reales de pacientes con DM1 para el desarrollo y evaluación de algoritmos presenta barreras éticas, burocráticas y logísticas que dificultan su disponibilidad en el contexto académico. Los simuladores de pacientes virtuales constituyen una alternativa consolidada en la investigación en tecnologías para la diabetes, permitiendo generar datos controlados y reproducibles bajo condiciones experimentales definidas (Siket et al., 2025).

El simulador de referencia en este campo es el UVA/Padova metabolic simulator, desarrollado conjuntamente por la Universidad de Virginia y la Universidad de Padova (Man et al., 2014). Este simulador está aceptado por la Food and Drug Administration (FDA) de Estados Unidos como sustituto de los estudios preclínicos en animales para el desarrollo y evaluación de algoritmos de control glucémico, lo que acredita su validez como entorno de pruebas (Man et al., 2014). El modelo reproduce la dinámica glucosa-insulina mediante un sistema de ecuaciones diferenciales que describe los comportamientos de absorción gastrointestinal, distribución de glucosa, acción de la insulina y producción hepática de glucosa, parametrizado a partir de datos fisiológicos reales.

Para el presente trabajo se ha utilizado py-mgipsim, una librería Python de código abierto que implementa y extiende el modelo UVA/Padova (Siket et al., 2025). La librería proporciona una cohorte de 20 pacientes virtuales con

conjuntos de parámetros individualizados y datos demográficos diferenciados, e incorpora implementaciones de los regímenes terapéuticos MDI, bomba de insulina con sensor aumentado (SAP) y sistemas de asa cerrada híbrida. Entre sus características relevantes se encuentran la posibilidad de introducir incertidumbre en las unidades de insulina administrada, variabilidad en los tiempos de ingesta y ejercicio físico, y la exportación de variables de estado en formato estructurado ([Siket et al., 2025](#)).

3.5. Modelos predictivos para series temporales

La predicción de series temporales consiste en estimar valores futuros de una variable a partir de su historia pasada y, en su caso, de variables externas relacionadas. En el contexto de la glucemia, la serie temporal está formada por las lecturas periódicas del sensor MCG, y las variables externas incluyen la insulina administrada, la ingesta de hidratos de carbono y el ejercicio realizado. El horizonte de predicción define el intervalo temporal entre el último dato disponible y el instante predicho; en este trabajo se trabaja con horizontes de 15 y 30 minutos, equivalentes a 3 y 6 pasos temporales respectivamente, dada la frecuencia de muestreo de 5 minutos.

ARIMAX

Los modelos ARIMA (AutoRegressive Integrated Moving Average) son una familia de modelos estadísticos lineales para series temporales que combinan tres componentes: un término autorregresivo (AR) que modela la dependencia lineal con valores pasados de la propia serie, un término de media móvil (MA) que modela la dependencia con errores de predicción pasados, y un operador de diferenciación (I) que transforma la serie en estacionaria mediante diferencias sucesivas. El modelo se parametriza mediante el triplete (p, d, q) , donde p es el orden autorregresivo, d el grado de diferenciación y q el orden de la media móvil ([Box et al., 2015](#)).

La extensión ARIMAX (ARIMA with eXogenous inputs) incorpora variables exógenas como regresores adicionales al modelo, lo que permite capturar el efecto de entradas externas sobre la evolución de la serie.

XGBoost

XGBoost (eXtreme Gradient Boosting) es un algoritmo de aprendizaje automático basado en la construcción secuencial de árboles de decisión, donde cada árbol nuevo se entrena para corregir los errores residuales del conjunto de árboles anteriores mediante el descenso de gradiente sobre una

función de pérdida ([Chen and Guestrin, 2016](#)). A diferencia de los modelos estadísticos clásicos, XGBoost no impone supuestos sobre la linealidad de las relaciones entre variables, lo que lo hace apto para capturar interacciones no lineales entre la glucemia pasada, la insulina y los hidratos de carbono. Su aplicación a series temporales requiere una transformación previa de la serie en formato supervisado, dado que el algoritmo no opera de forma nativa sobre datos secuenciales.

Selección de hiperparámetros

Ambos modelos requieren la optimización de sus hiperparámetros para maximizar el rendimiento predictivo. Para este trabajo, la búsqueda de hiperparámetros se ha realizado sobre un paciente virtual de referencia, común a ambos modelos, con el objetivo de garantizar la comparabilidad de los resultados. Los hiperparámetros obtenidos se han aplicado posteriormente al resto de la cohorte sin reajuste individual, lo que permite evaluar la capacidad de generalización de cada modelo ante la variabilidad interpaciente.

3.6. Estado del arte

La predicción de glucemia mediante modelos de aprendizaje automático y estadísticos aplicados a series temporales de MCG es un campo de investigación activo desde la década de 2010, impulsado por la generalización de los dispositivos MCG y la disponibilidad de datos continuos de alta frecuencia. Una revisión sistemática y metaanálisis en red que incluyó 46 estudios cifra el RMSE medio para horizontes de 15, 30 y 60 minutos en 18,88, 21,40 y 30,01 mg/dL respectivamente, con los modelos de redes neuronales mostrando el mejor rendimiento relativo en todos los horizontes ([Liu et al., 2023](#)).

Entre los enfoques estadísticos, los modelos de la familia ARIMA y sus extensiones con variables exógenas han sido utilizados ampliamente para la predicción a corto plazo, valorados por su interpretabilidad y bajo coste computacional. Entre los enfoques basados en aprendizaje automático, las arquitecturas LSTM han mostrado resultados competitivos gracias a su capacidad para capturar dependencias temporales de largo alcance ([Carvalho and Liang, 2024](#); [Butt et al., 2023](#)). El trabajo de Butt et al. (2023), que aplica transformación de características de insulina y carbohidratos sobre el dataset OhioT1DM ([Marling and Bunesu, 2020](#)) con un modelo Bi-LSTM, obtiene un RMSE de 14,76 mg/dL a 30 minutos. Enfoques basados en programación genética han explorado la predicción individualizada a 30 y 60 minutos sobre datos reales de pacientes, logrando que el 98 % y el 90 %

de las predicciones respectivamente caigan en zonas clínicamente aceptables según la CEG (Cano et al., 2025).

Los modelos híbridos y de ensemble han ganado presencia en la literatura reciente como estrategia para mejorar la robustez entre distintos horizontes de predicción. La revisión de (Cinar et al., 2025) identifica que los modelos apilados obtienen los mejores resultados en regresión, destacando combinaciones de métodos de aprendizaje automático y aprendizaje profundo como modelos base, incluyendo específicamente ensembles de LSTM y XGBoost entre los enfoques con rendimiento más estable. Sin embargo, la mayoría de modelos no mantienen su rendimiento de forma robusta a través de múltiples horizontes con una única arquitectura, lo que refuerza el interés por analizar el comportamiento de modelos individuales ante distintos horizontes antes de explorar combinaciones.

La mayoría de los trabajos existentes se han desarrollado sobre datos reales procedentes de datasets públicos —como el OhioT1DM (Marling and Bunesu, 2020)— o sobre cohortes de pacientes con sistemas de asa cerrada o ISCI, mientras que los estudios centrados específicamente en poblaciones MDI son menos frecuentes.

El presente trabajo se distingue de los precedentes en tres aspectos: la delimitación explícita al régimen MDI, la comparación directa entre un modelo estadístico lineal (ARIMAX) y un modelo de aprendizaje automático no lineal (XGBoost) bajo condiciones experimentales controladas mediante simulador validado, y el análisis del efecto de variables clínicamente relevantes —variabilidad en la ingesta, ejercicio físico y error en la dosis de insulina— sobre el rendimiento predictivo de cada modelo.

Metodología

4.1. Descripción de los datos

Los datos utilizados en el trabajo han sido generados mediante el simulador *py-mgipsim* (Siket et al., 2025) sobre una cohorte de 20 pacientes virtuales con DM1 en régimen MDI. Para cada paciente se han simulado seis escenarios experimentales que combinan tres factores clínicamente relevantes: la variabilidad en la ingesta de hidratos de carbono, la presencia de ejercicio físico regular y el error en el cálculo de la ratio insulina/ración (I:R), tal como se recoge en la Tabla 4.1.

Tabla 4.1: Definición de los escenarios experimentales.

Escenario	Código	HC	Ejercicio	Error I:R
E1	HC ⁻ E ₀ Er ₀	Baja	No	0 %
E2	HC ⁺ E ₀ Er ₀	Alta	No	0 %
E3	HC ⁻ E ⁺ Er ₀	Baja	Sí	0 %
E4	HC ⁻ E ₀ Er ⁺	Baja	No	10 %
E5	HC ⁺ E ₀ Er ⁺	Alta	No	10 %
E6	HC ⁻ E ⁺ Er ⁺	Baja	Sí	10 %

E1 actúa como escenario de referencia o línea base, con condiciones ideales de manejo. Los escenarios E2, E3 y E4 introducen cada factor de variabilidad de forma aislada respecto a E1, mientras que E5 y E6 combinan el error en la dosis con variabilidad en HC y con ejercicio respectivamente. Los horarios de ingesta son comunes a todos los escenarios. Esta estructura permite analizar el efecto individual y combinado de cada factor sobre el rendimiento predictivo.

El simulador genera un conjunto amplio de variables fisiológicas y de control distribuidas en dos archivos de salida por paciente y escenario. De entre ellas se han seleccionado las relevantes para el estudio: glucemia (convertida de mmol/L a mg/dL), ejercicio físico, insulina en bolo, insulina basal, y la ingesta de comidas y tentempiés. Cabe señalar que los tentempiés generados por el simulador no conllevan administración de insulina en bolo. El resto de variables proporcionadas por el simulador —como señales fisiológicas internas del modelo metabólico— han sido descartadas por no ser relevantes para el problema de predicción planteado. El conjunto de datos resultante comprende 120 series temporales independientes (20 pacientes $\times$ 6 escenarios). La descripción detallada de las variables y la estructura de los ficheros se recoge en el Anexo F.

4.2. Técnicas y herramientas

Preprocesamiento

Las series temporales generadas por *py-mgipsim* (Siket et al., 2025) presentan una frecuencia de muestreo de 1 minuto. Para alinearlas con la resolución temporal de los dispositivos MCG comerciales y reducir la carga computacional, se aplicó un remuestreo a 5 minutos mediante una función propia que desplaza las variables de evento —ingesta de hidratos de carbono, insulina en bolo e insulina basal— al instante de muestreo más cercano dentro de cada intervalo de 5 minutos. A continuación, se asignó un índice temporal de tipo `datetime` al dataframe de cada paciente, requisito necesario para el correcto funcionamiento de las funciones de predicción con series temporales de `skforecast` (Amat Rodrigo and Escobar Ortiz, 2024).

Ingeniería de características

A partir de las series preprocesadas se construyeron dos tipos de características de entrada, comunes a ambos modelos:

- **Retardos de glucemia:** valores pasados de la glucosa en los instantes previos al horizonte de predicción, seleccionados durante la optimización de hiperparámetros.
- **Variables exógenas acumuladas:** para la insulina en bolo, los hidratos de carbono y el ejercicio se calcularon valores acumulados por tramos de 20 minutos durante las últimas 4 horas, capturando el perfil temporal de acción de cada variable sobre la glucemia. De forma excepcional, la insulina basal se acumuló sobre las últimas 24 horas, dado su perfil de acción prolongada.

Se implementaron funciones de escalado y estandarización que finalmente no se aplicaron en la evaluación, dado que los resultados sin transformación fueron satisfactorios y su inclusión habría incrementado de forma significativa el coste computacional.

División train/test y backtesting

Cada serie temporal se dividió en un 80 % para entrenamiento y un 20 % para test, respetando el orden cronológico. La evaluación se realizó mediante backtesting con tamaño de ventana de entrenamiento fijo y reajuste del modelo en cada paso (refit), simulando el comportamiento de un predictor en producción que se actualiza periódicamente con nuevos datos. El proceso se aplicó de forma independiente para cada combinación de paciente, escenario y horizonte de predicción (15 y 30 minutos), generando un total de 240 evaluaciones por modelo (20 pacientes $\times$ 6 escenarios $\times$ 2 horizontes).

Optimización de hiperparámetros

La búsqueda de hiperparámetros se realizó sobre un paciente de referencia único (paciente 1, escenario E3), común a ambos modelos, tomando el MAE como métrica objetivo y garantizando la comparabilidad. Los hiperparámetros obtenidos se aplicaron al resto de la cohorte sin reajuste individual. Para ARIMAX se empleó `grid_search_stats` de `skforecast`, descartando la componente de estacionalidad. Para XGBoost ([Chen and Guestrin, 2016](#)) se empleó optimización bayesiana con validación `OneStepAheadFold`. Los hiperparámetros detallados de ambos modelos se recogen en el Anexo G.

Métricas de evaluación

El rendimiento predictivo se cuantificó mediante el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE). La seguridad clínica se evaluó mediante la Clarke Error Grid ([Clarke et al., 1987](#)), extrayendo el porcentaje de predicciones en zona A, en zonas A+B (clínicamente aceptables) y en zonas D+E (clínicamente peligrosas).

Dado que los tests de normalidad de Shapiro-Wilk aplicados sobre las distribuciones de MAE y RMSE rechazaron la hipótesis de normalidad en la mayoría de los escenarios, la comparación estadística entre pares de escenarios se realizó mediante el test de Wilcoxon de rangos con signo ([SciPy Contributors, 2020](#)). Los pares analizados fueron E1–E2, E1–E3, E1–E4, E2–E5 y E4–E6, seleccionados para aislar el efecto individual de cada factor experimental sobre el rendimiento predictivo de cada modelo.

Herramientas

El desarrollo se llevó a cabo en Python. Las principales librerías utilizadas fueron skforecast ([Amat Rodrigo and Escobar Ortiz, 2024](#)) para la implementación y evaluación de los modelos predictivos, xgboost ([Chen and Guestrin, 2016](#)) para el regresor base del modelo de gradient boosting, statsmodels para ARIMAX, pandas y numpy para la manipulación de datos, scipy ([SciPy Contributors, 2020](#)) para los tests estadísticos y matplotlib para la visualización de resultados.

Se valoró la incorporación de la librería SHAP para el análisis de importancia y explicabilidad de las variables de entrada. Sin embargo, su integración no pudo llevarse a cabo debido a incompatibilidades entre las versiones de las dependencias del entorno de desarrollo. Adicionalmente, una modificación de la versión de Python habría comprometido la reproducibilidad de los resultados al afectar al comportamiento de los generadores de números aleatorios de las librerías utilizadas. Por este motivo, el análisis de explicabilidad mediante SHAP se identifica como una línea de trabajo futura (véase Capítulo 8).

4.3. Metodología de ingeniería del software

El trabajo siguió una metodología experimental iterativa, centrada en el análisis de datos y la evaluación de modelos más que en el desarrollo de un sistema software completo. El proceso se organizó en fases sucesivas: generación de datos mediante simulación, desarrollo del pipeline de preprocesamiento, implementación y ajuste de los modelos, y evaluación comparativa de resultados. Dado que el trabajo no comprende el ciclo de vida completo de un desarrollo software, se remite al Anexo A para la planificación temporal detallada y la descripción de las fases realizadas y pendientes.

Resultados

Este capítulo presenta los resultados obtenidos para los modelos ARIMAX y XGBoost en los seis escenarios experimentales definidos, para los horizontes de predicción de 15 y 30 minutos. Los resultados se organizan en torno a los ejes de análisis establecidos en los objetivos: rendimiento global mediante métricas de error, seguridad clínica mediante la Clarke Error Grid, degradación del rendimiento con el horizonte de predicción, y relación entre el perfil glucémico del paciente y el error predictivo. Los resultados detallados por paciente y escenario se recogen en el Anexo G.

5.1. Rendimiento global




Figura 5.1: MAE medio por escenario y horizonte de predicción para ARIMAX y XGBoost.

En términos de MAE, XGBoost superó a ARIMAX en todos los escenarios y horizontes (Figura 5.1). En el escenario de referencia E1, los valores medios fueron 0,121 mg/dL frente a 0,249 mg/dL a 15 minutos, y 0,126 mg/dL frente a 0,249 mg/dL a 30 minutos. El test de Wilcoxon inter-modelo confirmó que

Resultados

las diferencias fueron estadísticamente significativas en todos los escenarios a 15 minutos ($p < 0,001$ en E1, E2, E3 y E4; $p < 0,01$ en E5; $p < 0,05$ en E6), mientras que a 30 minutos la diferencia dejó de ser significativa en E5 y E6. Sin embargo, el rendimiento de XGBoost presentó mayor variabilidad interpaciente, especialmente en los escenarios con error estocástico: en E5 y E6 el MAE medio alcanzó 0,195 y 0,194 mg/dL a 15 minutos y 0,215 y 0,216 mg/dL a 30 minutos. ARIMAX, por el contrario, mantuvo un MAE prácticamente constante en todos los escenarios (0,249–0,251 mg/dL) con desviación típica notablemente inferior.




Figura 5.2: RMSE medio por escenario y horizonte de predicción para ARIMAX y XGBoost.

En términos de RMSE, el patrón fue distinto (Figura 5.2). XGBoost obtuvo un RMSE comparable a ARIMAX en los escenarios sin error en la dosis (E1, E2, E3), sin diferencias estadísticamente significativas entre modelos. En los escenarios con error en la dosis (E4, E5, E6), ARIMAX resultó significativamente mejor que XGBoost en RMSE ($p < 0,05$ en E4 a 15 min; $p < 0,01$ en E5 y E6 a 15 min; $p < 0,05$ en E4 y E6 a 30 min; $p < 0,001$ en E5 a 30 min), con valores medios de XGBoost de 0,344, 0,414 y 0,457 mg/dL a 15 minutos frente a 0,288, 0,307 y 0,291 mg/dL de ARIMAX en esos mismos escenarios. Este resultado refleja que XGBoost genera errores puntuales de mayor magnitud bajo condiciones de perturbación, penalizados en mayor medida por el RMSE.

El test de Wilcoxon inter-simulación reveló patrones diferenciados entre modelos. Para ARIMAX, ningún par de escenarios mostró diferencias estadísticamente significativas en MAE ni en RMSE ($p > 0,05$ en todos los casos), lo que indica que el modelo no ha sido sensible a ninguno de los factores experimentales introducidos. Para XGBoost, la variabilidad en la ingesta de HC (E1–E2) y el error en la dosis de insulina (E1–E4) produjeron incrementos significativos del error en ambos horizontes y métricas ($p <$

0,001). El error en la dosis sobre escenarios de HC variable (E2–E5) también resultó significativo en MAE ($p < 0,001$) y en RMSE ($p < 0,01$ a 15 min; $p < 0,05$ a 30 min). El error en la dosis sobre el escenario con ejercicio (E3–E6) fue significativo en MAE ($p < 0,001$) y en RMSE a 15 minutos ($p < 0,01$). El ejercicio por sí solo (E1–E3) no produjo diferencias significativas en ningún modelo, horizonte ni métrica.

5.2. Seguridad clínica

Ambos modelos obtuvieron el 100 % de las predicciones clasificadas en zona A de la CEG en todos los escenarios y horizontes de predicción, sin ninguna predicción en zonas B, C, D o E (Figura 5.3). Esto implica que la totalidad de las predicciones presentaron un error inferior al 20 % del valor real de glucemia, umbral de precisión clínica más estricto de la CEG. El resultado fue idéntico para el horizonte de 30 minutos (véase Anexo G). La interpretación de este hallazgo se discute en el siguiente capítulo.




Figura 5.3: Distribución de predicciones en zonas de la Clarke Error Grid para XGBoost y ARIMAX en el horizonte de 15 minutos, por escenario.

5.3. Degradación del rendimiento con el horizonte

ARIMAX mostró una degradación prácticamente nula al pasar de 15 a 30 minutos, con ratios MAE_{30}/MAE_{15} iguales a 1,00 en todos los escenarios y ratios $RMSE_{30}/RMSE_{15}$ entre 0,99 y 1,03 (Figura 5.4, Figura 5.5). XGBoost presentó una degradación moderada pero consistente, con ratios MAE_{30}/MAE_{15} entre 1,05 y 1,12 y ratios $RMSE_{30}/RMSE_{15}$ entre 1,05 y 1,20 según el escenario. La degradación fue más pronunciada en los escenarios con mayor perturbación (E5 y E6), lo que sugiere que la complejidad del escenario amplifica el efecto del horizonte sobre el rendimiento de XGBoost.

Resultados




Figura 5.4: Degradación del MAE al aumentar el horizonte de predicción. Izquierda: valores absolutos por escenario. Derecha: ratio MAE_{30}/MAE_{15} por escenario y modelo.




Figura 5.5: Degradación del RMSE al aumentar el horizonte de predicción. Izquierda: valores absolutos por escenario. Derecha: ratio $RMSE_{30}/RMSE_{15}$ por escenario y modelo.

5.4. Relación entre perfil glucémico y rendimiento predictivo

Para XGBoost se observó una correlación negativa fuerte y altamente significativa entre el TIR del paciente y su error predictivo en todos los escenarios, tanto para MAE (r entre -0,76 y -0,81 a 15 min; r entre -0,75 y -0,82 a 30 min; $p < 0,001$ en todos los casos) como para RMSE (r entre -0,65 y -0,77 a 15 min; r entre -0,60 y -0,80 a 30 min; $p < 0,01$ o inferior). Agregando los resultados sobre los seis escenarios, los coeficientes de correlación fueron $r = -0,85$ (MAE, 15 min), $r = -0,89$ (MAE, 30 min), $r = -0,83$ (RMSE, 15 min) y $r = -0,84$ (RMSE, 30 min), todos con $p < 0,001$ (Figura 5.6, Figura 5.7).

Para ARIMAX, la correlación entre TIR y error no fue estadísticamente significativa en ningún escenario ni horizonte, a excepción del escenario E5 en MAE a 15 minutos ($r = -0,48$, $p = 0,031$). Los resultados detallados por escenario se recogen en el Anexo G.




Figura 5.6: Correlación de Spearman entre MAE medio por paciente (promediado sobre los seis escenarios) y TIR, para ambos modelos y horizontes de predicción.




Figura 5.7: Correlación de Spearman entre RMSE medio por paciente (promediado sobre los seis escenarios) y TIR, para ambos modelos y horizontes de predicción.

Discusión

6.1. Interpretación del rendimiento global

Los resultados muestran un patrón diferenciado entre modelos según la métrica de evaluación considerada. La ventaja de XGBoost en MAE es coherente con su capacidad para capturar interacciones no lineales entre la glucemia pasada y las variables exógenas, algo que un modelo lineal como ARIMAX no puede representar. Sin embargo, esta capacidad tiene como contrapartida una mayor sensibilidad a las perturbaciones del escenario, que se manifiesta en una variabilidad interpaciente notablemente superior y, en particular, en un RMSE más elevado bajo condiciones de error en la dosis de insulina.

ARIMAX exhibe un comportamiento notablemente estable en todos los escenarios y horizontes. Esta estabilidad refleja que el modelo captura fundamentalmente la componente autorregresiva de la serie glucémica, cuya estructura es altamente regular en los datos simulados, sin que las variables exógenas aporten valor predictivo adicional significativo. En escenarios con perturbaciones exógenas, su linealidad actúa como mecanismo de regularización implícito, evitando los errores puntuales de gran magnitud que acumula XGBoost.

La divergencia entre MAE y RMSE como criterios de comparación tiene implicaciones clínicas directas: el RMSE amplifica los errores grandes, que son precisamente los más peligrosos en el contexto de la predicción de glucemia. Desde esta perspectiva, ARIMAX ofrece un perfil de seguridad más conservador en escenarios de perturbación, mientras que XGBoost resulta más preciso en condiciones favorables.

6.2. Efecto de los factores experimentales

La sensibilidad de XGBoost al error en la dosis de insulina y a la variabilidad en la ingesta de HC, frente a la insensibilidad de ARIMAX a todos los factores experimentales, refleja una diferencia estructural entre ambos modelos. XGBoost aprende patrones complejos a partir de los datos de entrenamiento y, al optimizarse sobre un escenario sin error en la dosis (E3), carece de ejemplos representativos de esta perturbación, lo que limita su capacidad de generalización cuando dicho error está presente.

La ausencia de efecto significativo del ejercicio en ambos modelos puede explicarse por la naturaleza del escenario simulado: el ejercicio se introduce con un perfil temporal predefinido y regular, sin la variabilidad e imprevisibilidad propias del ejercicio real. En este contexto, ambos modelos incorporan su efecto dentro de la dinámica general de la serie sin que suponga una perturbación diferencial respecto al escenario base. Esta interpretación es coherente con lo señalado por [Cinar et al. \(2025\)](#), que identifica la actividad física como una característica especialmente impactante cuando su intensidad y momento son variables, condiciones que no se reproducen en los escenarios simulados de este trabajo.

La insensibilidad de ARIMAX a todos los factores experimentales es coherente con su formulación: en datos con una estructura temporal tan regular como la de los escenarios simulados, la glucemia pasada es suficiente para predecir la glucemia futura con un error estable, independientemente de las perturbaciones exógenas introducidas.

6.3. Resultados de la CEG y validez clínica

El 100 % de predicciones en zona A de la CEG en todos los escenarios, modelos y horizontes es un resultado que debe interpretarse con cautela. Los valores de error obtenidos son dos órdenes de magnitud inferiores a los reportados en la literatura con datos reales ([Butt et al., 2023](#); [Liu et al., 2023](#)), lo que hace que la comparación directa no sea válida. Esta discrepancia se atribuye a la naturaleza periódica de los datos generados por py-mgipsim ([Siket et al., 2025](#)): las series simuladas presentan patrones de ingesta y actividad altamente regulares que facilitan el aprendizaje de la tendencia glucémica y eliminan el ruido e imprevisibilidad propios de los datos reales. La ausencia total de predicciones en zonas B, C, D o E confirma que el problema de predicción planteado sobre datos simulados es intrínsecamente más sencillo que sobre datos reales, y que los resultados de la CEG no son extrapolables a un contexto clínico sin validación previa.

6.4. Relación entre perfil glucémico y rendimiento predictivo

El TIR se empleó como indicador del control glucémico de cada paciente por ser una métrica de uso clínico habitual que permite categorizar de forma rápida el perfil glucémico individual como primera aproximación ([Rizos et al., 2025](#); [Grupo de trabajo de la Guía de Práctica Clínica sobre Diabetes Mellitus Tipo 1, 2026](#)). La correlación negativa fuerte y significativa entre el TIR y el error predictivo de XGBoost, consistente en todos los escenarios y horizontes, indica que el modelo comete errores mayores en pacientes con peor control glucémico. Esta dependencia del perfil del paciente sugiere que la estrategia de hiperparámetros globales, optimizados sobre un único paciente de referencia, no generaliza de forma uniforme a toda la cohorte: los pacientes con perfiles glucémicos más complejos o atípicos representan casos en los que dicha estrategia resulta insuficiente.

Cabe señalar que algunos pacientes virtuales de la cohorte presentan un TIR del 0%, no como consecuencia de hipoglucemia mantenida sino porque sus valores de glucemia se encuentran sistemáticamente por encima del rango normoglucémico, con perfiles regulares pero desplazados hacia la hiperglucemia. Este fenómeno refleja una característica del simulador más que un perfil clínico real, y debe tenerse en cuenta al interpretar los extremos de la correlación TIR-error (véase Anexo G para la distribución de TIR por paciente y escenario).

La ausencia de correlación significativa entre TIR y error en ARIMAX refleja una ventaja en términos de equidad predictiva: ningún subgrupo de pacientes es sistemáticamente peor predicho que otro.

6.5. Comparación con trabajos previos

La comparación con la literatura debe realizarse con las reservas metodológicas señaladas en el apartado 6.3. El estudio más directamente comparable en términos de diseño es el de [Butt et al. \(2023\)](#), que aplica un modelo Bi-LSTM con transformación de características de insulina y carbohidratos sobre el dataset OhioT1DM. La revisión sistemática de [Liu et al. \(2023\)](#) ofrece un marco de referencia más amplio sobre el rendimiento esperado en datos reales. En ambos casos, los errores reportados son sustancialmente superiores a los obtenidos en este trabajo, lo que confirma que la regularidad de los datos simulados produce un escenario de predicción artificialmente favorable.

Desde el punto de vista del diseño experimental, la contribución de este trabajo respecto al estado del arte reside en dos aspectos. En primer lugar, la delimitación explícita al régimen MDI, modalidad terapéutica mayoritaria pero infrarepresentada en la literatura, donde predominan los estudios sobre sistemas de asa cerrada o ISCI. En segundo lugar, el análisis sistemático del efecto de variables clínicamente relevantes —variabilidad en la ingesta, ejercicio y error en la dosis— sobre el rendimiento predictivo bajo condiciones controladas, algo difícil de aislar con datos reales.

6.6. Limitaciones

La principal limitación del trabajo es el uso exclusivo de datos simulados. Aunque `py-mgipsim` está basado en el modelo UVA/Padova ([Man et al., 2014](#)), aceptado por la FDA como sustituto de estudios preclínicos, la regularidad de las series generadas no reproduce la complejidad y variabilidad propias de los datos reales.

La disponibilidad de datasets públicos adecuados para este problema específico es estructuralmente escasa: los conjuntos de datos con registros simultáneos de glucemia, insulina, ingesta de hidratos de carbono y ejercicio en pacientes con DM1 en régimen MDI son escasos ([Prioleau et al., 2025](#)). El estándar de referencia en la literatura es el dataset OhioT1DM ([Marling and Bunesco, 2020](#)), cuyo acceso requería una solicitud formal, lo que habría supeditado el desarrollo del trabajo a una respuesta afirmativa en un plazo incierto. Se identificó además un dataset con datos de pacientes de Shanghai ([Zhao et al., 2023](#)), descartado por seguir un modelo de control glucémico significativamente distinto al protocolo clínico occidental, criterio corroborado por la cotutora especialista en diabetes. Ante estas circunstancias, el uso del simulador validado constituyó la alternativa más viable para garantizar la reproducibilidad y el control experimental del estudio.

Una segunda limitación es la estrategia de hiperparámetros globales: la optimización sobre un único paciente de referencia y su aplicación sin reajuste al resto de la cohorte limita el rendimiento de XGBoost en pacientes con perfiles glucémicos alejados del paciente de referencia, como evidencia la correlación entre TIR y error predictivo.

Una tercera limitación fue la capacidad de cómputo disponible. El back-testing sobre 120 series temporales con refit en cada paso supuso un coste computacional elevado, lo que restringió el número de escenarios y configuraciones que pudieron evaluarse. Se exploró el uso de computación en la nube mediante Google Colab ([Google, 2026](#)), pero la ausencia de un plan de pago

limitó tanto la velocidad de procesamiento como la disponibilidad continua de los recursos de cálculo. Esta restricción condicionó decisiones como la optimización de hiperparámetros sobre un único paciente de referencia en lugar de realizar una búsqueda individualizada, y descartó la exploración de un mayor número de escenarios o la inclusión de modelos adicionales como Prophet ([Taylor and Letham, 2018](#)).

Finalmente, dos análisis de explicabilidad previstos inicialmente no pudieron completarse. El análisis mediante SHAP no pudo implementarse por incompatibilidades entre las versiones de las dependencias del entorno de desarrollo. Por su parte, la extracción sistemática de la importancia de características de ambos modelos sobre toda la cohorte no se integró en el pipeline de backtesting, lo que habría requerido reprocesar los 120 escenarios con un coste computacional inasumible en el tiempo disponible. Ambos análisis habrían permitido cuantificar la contribución de cada variable exógena al rendimiento predictivo de cada modelo, complementando los resultados del análisis de variabilidad experimental. A modo ilustrativo, se incluye en el Anexo G la importancia de características obtenida para el paciente de referencia en ambos modelos.

Conclusiones

Este trabajo ha abordado el estudio comparativo de modelos predictivos de glucemia en pacientes con DM1 en régimen MDI, empleando datos generados mediante un simulador validado ante la imposibilidad de acceder a datos reales en el tiempo disponible. Esta circunstancia, lejos de ser un obstáculo menor, condicionó de forma determinante el diseño del estudio y pone de manifiesto la importancia de planificar con antelación los aspectos críticos del proyecto: la disponibilidad de datos, los requisitos de acceso y los tiempos burocráticos asociados deben evaluarse en las fases iniciales, ya que su resolución puede comprometer el alcance del trabajo si se abordan tardíamente.

En la misma línea, la experiencia con el pipeline de backtesting ha evidenciado que una planificación cuidadosa del proceso de evaluación —incluyendo qué métricas e indicadores se extraerán en cada paso— evita tener que reprocesar series completas con un coste computacional elevado. Decisiones aparentemente menores en el diseño del código, como no integrar la extracción de importancia de características en el bucle de backtesting, se tradujeron en análisis que no pudieron completarse en el tiempo disponible. Este tipo de experiencia práctica es difícilmente documentable en la literatura pero resulta de gran valor para futuros desarrollos similares.

Respecto a los resultados, ambos modelos demostraron un rendimiento clínicamente aceptable sobre los datos simulados, con el 100 % de predicciones en zona A de la CEG. XGBoost superó a ARIMAX en MAE en condiciones favorables, pero mostró mayor degradación ante perturbaciones exógenas, especialmente el error en la dosis de insulina, donde ARIMAX resultó significativamente más robusto en RMSE. El ejercicio físico, tal como fue modelado en el simulador, no produjo un efecto significativo sobre el rendimiento de ningún modelo. La correlación entre el TIR del paciente

y el error de XGBoost sugiere que este modelo requiere una estrategia de personalización para generalizar de forma equitativa sobre cohortes heterogéneas, mientras que ARIMAX ofrece un comportamiento más uniforme entre pacientes.

La regularidad de los datos simulados limita la extrapolación de estos resultados a un contexto clínico real, donde la variabilidad e imprevisibilidad de las series glucémicas plantean un problema de predicción sustancialmente más complejo.

Líneas de trabajo futuras

La principal extensión natural del trabajo es la validación de los modelos sobre datos reales de pacientes con DM1 en régimen MDI. Los resultados obtenidos sobre datos simulados constituyen una prueba de concepto metodológica, pero su extrapolación clínica requiere necesariamente su contraste con series glucémicas reales, donde la variabilidad, el ruido y la imprevisibilidad propias del entorno clínico plantean un problema de predicción sustancialmente más exigente. El dataset OhioT1DM ([Marling and Bunesco, 2020](#)) representa el estándar de referencia para esta validación, y su acceso debería contemplarse como primer paso en trabajos futuros.

La personalización de hiperparámetros por paciente es otra extensión relevante, especialmente para XGBoost, cuyo rendimiento mostró una dependencia significativa del perfil glucémico individual. Una estrategia de optimización individualizada, o alternativamente el uso del TIR como criterio de selección del modelo más adecuado para cada paciente, podría mejorar la equidad predictiva de la solución sobre cohortes heterogéneas.

La comparativa de eficiencia computacional entre modelos merece atención en futuros trabajos. De forma empírica se observó que ARIMAX requería tiempos de optimización y entrenamiento superiores a XGBoost, si bien las condiciones de ejecución no fueron homogéneas a lo largo del desarrollo—con variabilidad en los recursos disponibles del equipo entre ejecuciones—lo que impidió obtener mediciones fiables y comparables. Una evaluación formal de los tiempos de cómputo bajo condiciones controladas aportaría información relevante para la selección del modelo en entornos con recursos limitados.

La ampliación del diseño experimental es otra dirección de interés. El número de escenarios evaluados estuvo condicionado por la capacidad de

cómputo disponible; futuros trabajos podrían explorar niveles adicionales de variabilidad en los factores estudiados, incorporar nuevas variables como el estrés o la variabilidad en los horarios de ingesta, o extender el análisis a horizontes de predicción más largos. En este marco, la inclusión de modelos adicionales como Prophet ([Taylor and Letham, 2018](#)) - descartado en este trabajo por restricciones de tiempo— o arquitecturas de aprendizaje profundo como LSTM ([Hochreiter and Schmidhuber, 1997](#)) permitiría una comparativa más completa con el estado del arte.

Finalmente, el análisis de significación estadística de la contribución de cada variable exógena al rendimiento de los modelos, previsto inicialmente como objetivo del trabajo, constituye una extensión directa que permitiría determinar qué variables aportan valor predictivo real y cuáles son prescindibles, con implicaciones tanto para la simplificación del modelo como para el diseño de futuros sistemas de soporte a la decisión clínica en pacientes MDI.

Bibliografía

- Amat Rodrigo, J. and Escobar Ortiz, J. (2024). skforecast: time series forecasting with scikit-learn.
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., and Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control*. Wiley, 5 edition.
- Butt, H., Khosa, I., and Iftikhar, M. A. (2023). Feature transformation for efficient blood glucose prediction in type 1 diabetes mellitus patients. *Diagnostics*, 13(3):340.
- Calvo Ferrer, F., López García, M. J., and Rodríguez Rigual, M. (2004). Diabetes mellitus tipo 1: Tratamiento, seguimiento, complicaciones agudas. In Oyarzabal Irigoyen, M., editor, *Manual de Consenso de la Sociedad Española de Endocrinología Pediátrica*, chapter 23, pages 1–32. Sociedad Española de Endocrinología Pediátrica (SEEP). Coordinador del capítulo: Miren Oyarzabal Irigoyen.
- Cano, J., Hidalgo, J. I., and Garnica, O. (2025). Hardware real-time individualised blood glucose predictor generator based on grammars and Cartesian genetic programming. *Genetic Programming and Evolvable Machines*, 26:3.
- Carvalho, C. F. and Liang, Z. (2024). Glucose prediction with Long Short-Term Memory (LSTM) models in three distinct populations. *Engineering Proceedings*, 82(1):87.
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.

- Cinar, B., van den Boom, L., and Maleshkova, M. (2025). A review on machine learning approaches for the prediction of glucose levels and hypoglycemia. *arXiv preprint*. arXiv:2601.11615. [COMPLETAR] autor(es) completos.
- Clarke, W. L., Cox, D., Gonder-Frederick, L. A., Carter, W., and Pohl, S. L. (1987). Evaluating Clinical Accuracy of Systems for Self-Monitoring of Blood Glucose. *Diabetes Care*, 10(5):622–628. _eprint: <https://diabetesjournals.org/care/article-pdf/10/5/622/515265/10-5-622.pdf>.
- Conde Barreiro, S., González Pelegrín, B., Quevedo Beneyto, B., Feja Solana, C., Malo Aznar, C., Rojo-Martínez, G., Menéndez Torre, E., and Gómez Peralta, F. (2025). Estimation of the incidence and prevalence of type 1 diabetes mellitus in children under 15 years of age in Spain. *Endocrinología, Diabetes Y Nutrición*, 72(7):501591.
- Google (2026). Google colabory. <https://colab.research.google.com/>.
- Gregory, G. A. et al. (2022). Global incidence, prevalence, and mortality of type 1 diabetes in 2021 and projections to 2040. *The Lancet Diabetes & Endocrinology*.
- Grupo de trabajo de la Guía de Práctica Clínica sobre Diabetes Mellitus Tipo 1 (2026). Guía de práctica clínica sobre diabetes mellitus tipo 1. Guías de práctica clínica en el SNS, Ministerio de Sanidad. Servicio de Evaluación del Servicio Canario de Salud.
- Helleputte, S., Yardley, J. E., Scott, S. N., Stautemas, J., Jansseune, L., Marlier, J., De Backer, T., Lapauw, B., and Calders, P. (2023). Effects of postprandial exercise on blood glucose levels in adults with type 1 diabetes: a review. *Diabetologia*, 66(7):1179–1191.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- Liu, K., Li, L., Ma, Y., Jiang, J., Liu, Z., Ye, Z., Liu, S., Pu, C., Chen, C., and Wan, Y. (2023). Machine learning models for blood glucose level prediction in patients with diabetes mellitus: systematic review and network meta-analysis. *JMIR Medical Informatics*, 11:e47833.
- Man, C. D., Micheletto, F., Lv, D., Breton, M., Kovatchev, B., and Cobelli, C. (2014). The UVa/Padova type 1 diabetes simulator: new features. *Journal of Diabetes Science and Technology*, 8(1):26–34.

- Marling, C. and Bunesco, R. (2020). The ohiot1dm dataset for blood glucose level prediction: Update 2020. *CEUR workshop proceedings.*, 2675:71—74.
- Nwokolo, M. and Hovorka, R. (2023). The Artificial Pancreas and Type 1 Diabetes. *The Journal of Clinical Endocrinology and Metabolism*, 108(7):1614–1623.
- Ogle, G. D., Wang, F., Haynes, A., et al. (2025). Global type 1 diabetes prevalence, incidence, and mortality estimates 2025: Results from the International Diabetes Federation Atlas, 11th Edition, and the T1D Index Version 3.0. *Diabetes Research and Clinical Practice*. Global estimate: 9.5 million people living with type 1 diabetes in 2025.
- Pfützner, A., Klonoff, D. C., Pardo, S., and Parkes, J. L. (2013). Technical Aspects of the Parkes Error Grid. *Journal of Diabetes Science and Technology*, 7(5):1275–1281.
- Prioleau, T., Lu, B., and Cui, Y. (2025). Glucose-ml: A collection of longitudinal diabetes datasets for development of robust ai solutions. *arXiv preprint arXiv:2507.14077*, v1.
- Rizos, E. C., Markozannes, G., Charitakis, N., Filis, P., Stoimeni, A. E., Nørgaard, K., Ntzani, E. E., and Tsilidis, K. K. (2025). Continuous Glucose Monitoring in Type 1 Diabetes, Type 2 Diabetes, and Diabetes During Pregnancy: A Systematic Review with Meta-Analysis of Randomized Controlled Trials. *Diabetes Technology & Therapeutics*, 27(7):537–552.
- Roche Diabetes Care (2025). Solución de MCG Accu-Chek SmartGuide. Sitio web corporativo. Consultado en 2025.
- SciPy Contributors (2020). SciPy: fundamental algorithms for scientific computing in Python.
- Sengupta, S., Handoo, A., Haq, I., Dahiya, K., Mehta, S., and Kaushik, M. (2022). Clarke Error Grid Analysis for Performance Evaluation of Glucometers in a Tertiary Care Referral Hospital. *Indian Journal of Clinical Biochemistry*, 37(2):199–205.
- Siket, M., Rashid, M. M., and Cinar, A. (2025). py-mgipsim: An Open-Source Python Library for Simulating Type 1 Diabetes With Diverse Meals and Physical Activities. *Journal of Diabetes Science and Technology*, 19(3):855–856.
- Taylor, S. J. and Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1):37–45.

Bibliografia

Zhao, Q., Zhu, J., Shen, X., Lin, C., Zhang, Y., Liang, Y., Cao, B., Li, J., Liu, X., Rao, W., and Wang, C. (2023). Chinese diabetes datasets for data-driven machine learning. *Scientific Data*, 10(1):35.